
Full-Waveform Inversion

A teoria completa, em três níveis

Volume 2 — Intermediário

As deduções completas, os algoritmos e as contas
que você precisa fazer antes de rodar



*“Um dado sintético errado quase nunca vem com aviso.
Ele vem bonito.”*

12 capítulos · mesma espinha dorsal dos três volumes

16 de setembro de 2026

Sumário

Como usar este volume	4
Parte I — O problema direto	7
1 O que é FWI	7
1.1 Formulação	7
1.2 O orçamento: por que o custo organiza tudo	8
1.3 O que a FWI pode e não pode recuperar	8
2 Do meio elástico à equação acústica	10
2.1 Ponto de partida: elastodinâmica	11
2.2 A aproximação acústica, em quatro consequências	11
2.3 O que se preserva e o que se perde	13
2.4 A fonte: ondaleta de Ricker	14
3 Diferenças finitas: estabilidade e dispersão	16
3.1 O operador espacial e seus coeficientes	16
3.2 Estabilidade: a condição CFL	18
3.3 Dispersão numérica	19
3.4 Receita de dimensionamento	20
4 Bordas, superfície livre e aquisição	22
4.1 Por que as bordas não são detalhe	22
4.2 Superfície livre	23
4.3 Aquisição	24
Parte II — O problema inverso	27
5 Função objetivo e <i>cycle skipping</i>	27
5.1 Formulação e propriedades	27

5.2	Cycle skipping: a explicação e o critério	28
5.3	A estratégia multiescala	29
5.4	O modelo inicial	30
5.5	Além do L_2	30
6	O método do estado adjunto	32
6.1	Por que não diferenças finitas	32
6.2	A dedução	33
6.3	Da fórmula ao código	35
6.4	Armazenamento: <i>checkpointing</i>	36
6.5	Como ler um gradiente	37
7	Verificação do gradiente	38
7.1	O modo de falha silencioso	38
7.2	Teste 1 — diferenças finitas pontuais	38
7.3	Teste 2 — derivada direcional	39
7.4	Teste 3 — teste de Taylor (o conclusivo)	40
7.5	Diagnosticar pelo padrão	41
7.6	Estudo de caso: o <i>bug</i> que estes testes encontraram	41
8	Otimização	42
8.1	O panorama	43
8.2	A busca linear, onde o tempo é gasto	44
8.3	A Hessiana e o pré-condicionamento	44
8.4	Comparação medida	45
9	A FWI completa: fluxo de trabalho	47
9.1	O fluxo	47
9.2	A ondaleta da fonte	47
9.3	Um experimento controlado	48
9.4	Estudo de robustez	48
9.5	Como reportar uma FWI	50
10	Regularização e informação a priori	51
10.1	Por que regularizar	52
10.2	Tikhonov <i>versus</i> Variação Total	52
10.3	Um resultado que contraria a expectativa	53
10.4	Escolhendo λ	54

10.5 Modelo a priori e vínculos	54
Parte III — Os limites	57
11 Os limites da física adotada	57
11.1 O inventário de hipóteses	57
11.2 Limite 1: densidade e a ambiguidade da impedância	57
11.3 Limite 2: elasticidade	58
11.4 Limite 3: atenuação e o fator Q	58
11.5 Como decidir qual física você precisa	61
12 Diagnóstico	63
12.1 A FWI não converge (J não cai)	63
12.2 J cai mas o modelo está errado	63
12.3 Só a parte rasa é atualizada	63
12.4 O campo estoura (NaN)	64
12.5 Cauda oscilatória onde não deveria haver evento	64
12.6 As cinco perguntas antes de acreditar num resultado	64
A Notação	65
B Fórmulas de bolso	66
C Referências	67

Como usar este volume

Esta coleção conta a mesma história três vezes, com profundidade crescente. Os doze capítulos são os mesmos nos três volumes, na mesma ordem, tratando dos mesmos tópicos: o que muda é a complexidade e a completude, nunca o escopo.

Volume	Nível	O que faz
1	Introdutório	As ideias, as figuras e as conclusões. As fórmulas são <i>lidas</i> , não derivadas.
2	Intermediário	Este volume. Todas as deduções, as versões discretas, os algoritmos, as contas de dimensionamento e exercícios resolvidos.
3	Avançado	Formulação em espaços de funções, teoria de espalhamento, estrutura da Hessiana, multiparâmetro, funcionais alternativos, incerteza.

Para quem é

Para quem vai **escrever** ou **operar** um código de FWI. Ao final deste volume você deve ser capaz de: dimensionar uma simulação sem chute; derivar e implementar o gradiente adjunto; provar que o seu gradiente está certo; escolher e ajustar um otimizador; montar um fluxo multiescala; e diagnosticar um resultado ruim pela causa, não por tentativa e erro.

Pré-requisitos: cálculo de várias variáveis, noções de equações diferenciais parciais, álgebra linear, e alguma familiaridade com métodos numéricos. Não é preciso ter visto cálculo variacional — o pouco que é usado está derivado no Capítulo 6.

Como o volume está organizado

Parte	Caps.	Assunto
I	1–4	O problema direto: de onde vem a equação, como discretizá-la sem estragar a física, o que fazer com as bordas
II	5–10	O problema inverso: funcional, gradiente, verificação, otimização, fluxo completo, regularização
III	11–12	Os limites da física adotada e o diagnóstico

Marcas como esta apontam para os outros níveis:

- ▶ *Nível 1, Cap. 6* — a mesma ideia contada sem matemática, se a dedução a seguir ficar abstrata demais.
- ▶ *Nível 3, §6.2* — a mesma dedução em espaços de funções, com a derivada de Fréchet e os termos de fronteira tratados com rigor.

Sobre os números deste volume

Valores numéricos, tabelas medidas e figuras fotográficas vêm do código do curso (`aulas/`, `fwikit/`), executado no ambiente descrito no `README.md` — não foram copiados de livro. Onde um número é apenas ilustrativo, o texto diz.

Parte I — O problema direto

Capítulo 1

O que é FWI

A ideia deste capítulo, em uma frase

FWI é um problema de mínimos quadrados não linear de grande porte, com restrição dada por uma EDP. Cada uma dessas quatro palavras — não linear, grande porte, restrição, EDP — corresponde a uma dificuldade específica e a um capítulo deste volume.

Antes de usar: norma, mínimos quadrados e “arg min”

Três objetos aparecem na primeira fórmula do livro e reaparecem em todas as outras. Vale fixá-los antes.

Norma. Para um vetor $\mathbf{v} = (v_1, \dots, v_n)$, a norma euclidiana (L_2) é

$$\|\mathbf{v}\| = \sqrt{\sum_i v_i^2}, \quad \text{e para uma função} \quad \|v\|_{L_2} = \left(\int_0^T v(t)^2 dt \right)^{1/2}.$$

Ela mede “tamanho”. Um sismograma é um vetor de amostras; a passagem da soma para a integral é apenas a versão contínua da mesma ideia, e no código a integral volta a ser uma soma multiplicada por Δt .

Produto interno. $\langle \mathbf{u}, \mathbf{v} \rangle = \sum_i u_i v_i$ (ou $\int uv dt$), com $\|\mathbf{v}\|^2 = \langle \mathbf{v}, \mathbf{v} \rangle$. Ele é a ferramenta que permite “passar um operador para o outro lado” — ideia central do Capítulo 6.

Mínimos quadrados. Minimizar $\frac{1}{2} \|F(\mathbf{m}) - \mathbf{d}_{\text{obs}}\|^2$ é pedir que o modelo explique o dado *no sentido de mínima soma de erros ao quadrado*. Essa escolha não é neutra: elevar ao quadrado dá peso desproporcional aos maiores erros, o que torna o L_2 sensível a valores atípicos — e é uma das razões de existirem os funcionais alternativos do Capítulo 5.

arg min. $\arg \min_x g(x)$ não é o valor mínimo de g : é o *ponto* x onde esse mínimo ocorre. “min” devolve a altura; “arg min” devolve a posição. O que interessa em FWI é a posição — o modelo.

1.1 Formulação

Seja $\mathbf{m} \in \mathbb{R}^N$ o vetor de parâmetros do modelo (tipicamente $N = n_z n_x$ valores de velocidade, um por célula) e $\mathbf{d}_{\text{obs}}$ o dado observado. O operador de modelagem F resolve a equação da onda e amostra a solução nos receptores. A FWI resolve

$$\mathbf{m}^* = \arg \min_{\mathbf{m}} J(\mathbf{m}), \quad J(\mathbf{m}) = \frac{1}{2} \|F(\mathbf{m}) - \mathbf{d}_{\text{obs}}\|^2 = \frac{1}{2} \sum_s \sum_r \int_0^T [d_{\text{cal}}^{sr}(t) - d_{\text{obs}}^{sr}(t)]^2 dt. \quad (1.1)$$

Os índices importam e serão usados o volume inteiro: s percorre os **tiros** (disparos da fonte), r percorre os **receptores** de cada tiro, e t o tempo de registro. A soma sobre s é o que torna o gradiente uma soma de contribuições independentes — fato que domina a estratégia de paralelização (§1.2).

A iteração tem sempre a forma

$$\mathbf{m}_{k+1} = \mathbf{m}_k + \alpha_k \mathbf{d}_k, \quad (1.2)$$

com $\mathbf{d}_k$ a direção de busca construída a partir do gradiente (Cap. 8) e α_k o passo obtido por busca linear. Praticamente tudo em FWI é uma escolha dentro desta equação.

Três propriedades de J , e o que cada uma proíbe

Não linear. F depende de $\mathbf{m}$ de forma não linear: a velocidade aparece *dentro* do operador de onda, e o tempo de trânsito depende dela de maneira integral. Não há solução fechada; a iteração (1.2) é obrigatória.

Não convexa. Há mínimos locais, e um otimizador local converge para o mais próximo do ponto de partida. Isso proíbe confiar no resultado de uma única rodada, e obriga à estratégia multiescala (Cap. 5).

Mal posta. Partes do modelo não afetam os dados de forma mensurável. Ali o gradiente é ≈ 0 e o modelo permanece onde estava — ou é preenchido por artefatos vindos da regularização (Cap. 10).

1.2 O orçamento: por que o custo organiza tudo

O custo total de uma FWI é, em boa aproximação,

$$\text{custo} \approx n_{\text{iter}} \times n_{\text{bandas}} \times n_{\text{tiros}} \times \left(\underbrace{2}_{\text{direto} + \text{adjunto}} + \underbrace{n_{\text{busca}}}_{\text{busca linear}} \right) \times \text{custo}_{\text{modelagem}}. \quad (1.3)$$

O 2 é o preço do gradiente adjunto (Cap. 6); cada avaliação da busca linear custa mais uma modelagem direta, e n_{busca} costuma valer entre 1 e 3 (Cap. 8). (Uma busca que imponha a condição de curvatura de Wolfe precisa do gradiente em cada tentativa, e custa o dobro por avaliação.) Com 30 iterações, 3 bandas, 200 tiros e busca linear de 2 avaliações, isso dá cerca de $30 \times 3 \times 200 \times (2 + 2) = 72\,000$ modelagens completas. Se cada uma custa 10 segundos, são 8,3 dias de máquina — em um núcleo.

As duas alavancas que mudam ordens de grandeza

Paralelismo por tiro. O gradiente é uma *soma* sobre tiros (§6.2), e portanto os tiros são independentes. É paralelismo trivial, escala quase linearmente, e é a primeira coisa a fazer.

Subconjunto aleatório de tiros por iteração. Em vez de 200 tiros, sorteie 20 a cada iteração. O gradiente fica ruidoso, mas o *valor esperado* da direção continua correto, e o custo cai 10×. É a versão FWI do gradiente estocástico.

1.3 O que a FWI pode e não pode recuperar

Duas relações quantitativas delimitam o resultado antes de qualquer código rodar.

Resolução lateral e vertical. Para uma onda de frequência f em meio de velocidade c ,

$$\delta_{\min} \approx \frac{\lambda}{2} = \frac{c}{2f}. \quad (1.4)$$

Com o espectro de uma Ricker, a frequência que governa a resolução é a banda a -6 dB, aproximadamente $1,6f_0$ (§2.4).

Profundidade de investigação. Governada pela abertura — a profundidade típica de penetração das ondas mergulhantes (Morgan *et al.*, 2013):

$$z_{\max} \approx \frac{x_{\text{off}}^{\max}}{6} \text{ a } \frac{x_{\text{off}}^{\max}}{3}. \quad (1.5)$$

Além disso, os comprimentos de onda *muito longos* do modelo — a tendência regional — não são recuperáveis a partir de dado com o espectro sísmico usual: eles precisam vir do modelo inicial. O Capítulo 5 quantifica o quanto esse modelo inicial pode errar.

Exercícios

1. Um levantamento tem afastamento máximo de 6 km. Qual a profundidade máxima em que você confiaria no resultado?
2. O alvo está a 3 km, o meio tem $c \approx 2500$ m/s, e a fonte tem $f_0 = 8$ Hz. Qual o menor detalhe resolvível?
3. Você tem orçamento para 50 000 modelagens. Com 100 tiros e 3 bandas, quantas iterações por banda cabem, supondo busca linear de 2 avaliações?

Respostas. (1) Entre 1 e 2 km. (2) A banda útil vai até $\approx 1,6 \times 8 = 12,8$ Hz; $\delta_{\min} = 2500/(2 \cdot 12,8) \approx 98$ m. (3) De (1.3): $50\,000 = n_{\text{iter}} \times 3 \times 100 \times (2 + 2) \Rightarrow n_{\text{iter}} \approx 41$ por banda.

Capítulo 2

Do meio elástico à equação acústica

A ideia deste capítulo, em uma frase

Uma única hipótese — $\mu = 0$ — reduz cinco equações acopladas a uma equação escalar. Este capítulo faz essa redução passo a passo, para que se saiba exatamente o que foi descartado e onde a conta volta.

Antes de usar: notação indicial, tensor de tensões e os operadores ∇

Notação indicial. v_i representa a componente i de um vetor, com $i \in \{x, z\}$ em 2D. A **convenção de soma**: um índice repetido no mesmo termo está somado. Assim $\partial\sigma_{ij}/\partial x_j$ significa $\partial\sigma_{ix}/\partial x + \partial\sigma_{iz}/\partial z$. O δ_{ij} (delta de Kronecker) vale 1 se $i = j$ e 0 caso contrário.

Tensão. σ_{ij} é a força por unidade de área, na direção i , exercida sobre uma face cuja normal aponta em j . As componentes com $i = j$ (*normais*) comprimem ou tracionam; as com $i \neq j$ (*cisalhantes*) deslizam. Num fluido só existem as normais, e elas são todas iguais — é a pressão. Guardar esta frase economiza metade do capítulo.

Os três operadores. Para um campo escalar f e um campo vetorial $\mathbf{v}$:

$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial z} \right) \quad \text{aponta para onde } f \text{ cresce;}$$

$$\nabla \cdot \mathbf{v} = \frac{\partial v_x}{\partial x} + \frac{\partial v_z}{\partial z} \quad \text{o quanto “sai” do ponto;}$$

$$\nabla^2 f = \nabla \cdot (\nabla f) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial z^2} \quad \text{compara } f \text{ com a média dos vizinhos.}$$

A última interpretação é a que dá intuição física: o laplaciano é positivo onde o ponto está “num vale” em relação à vizinhança. Na equação da onda é ele que faz um vizinho empurrar o outro — e é exatamente essa média local que o estêncil de diferenças finitas do Capítulo 3 calcula.

2.1 Ponto de partida: elastodinâmica

A sismologia de exploração começa com dois ingredientes: a segunda lei de Newton para um meio contínuo e uma lei constitutiva (Hooke, meio elástico, isotrópico):

$$\rho \frac{\partial v_i}{\partial t} = \frac{\partial \sigma_{ij}}{\partial x_j} + f_i, \quad (2.1)$$

$$\frac{\partial \sigma_{ij}}{\partial t} = \lambda \delta_{ij} \frac{\partial v_k}{\partial x_k} + \mu \left(\frac{\partial v_i}{\partial x_j} + \frac{\partial v_j}{\partial x_i} \right). \quad (2.2)$$

Aqui v_i é a velocidade de **partícula** — não a velocidade de onda —, σ_{ij} o tensor de tensões, ρ a densidade, e λ, μ os parâmetros de Lamé. O módulo de cisalhamento μ é o que resiste a deformação sem mudança de volume.

Em 2D, (2.1)–(2.2) formam um sistema de **cinco** equações acopladas nas incógnitas

$$(v_x, v_z, \sigma_{xx}, \sigma_{zz}, \sigma_{xz}).$$

Desse sistema saem as duas velocidades de onda:

$$v_p = \sqrt{\frac{\lambda + 2\mu}{\rho}}, \quad v_s = \sqrt{\frac{\mu}{\rho}}. \quad (2.3)$$

Onde isso aparece na prática

Muitos códigos elásticos de diferenças finitas (entre eles o PyFWI, usado no curso que acompanha esta coleção) resolvem exatamente (2.1)–(2.2) na forma *velocidade–tensão* de primeira ordem, em malha intercalada. Neles, o regime acústico é obtido **zerando v_s no modelo**, não trocando de solver.

2.2 A aproximação acústica, em quatro consequências

A hipótese é uma só:

$$\mu = 0 \iff v_s = 0 \quad (2.4)$$

Substituindo em (2.2), as consequências são imediatas e vale segui-las uma a uma:

1. $\partial_t \sigma_{xz} = \mu(\partial_z v_x + \partial_x v_z) = 0$. Partindo do repouso, $\sigma_{xz} \equiv 0$: **não existe tensão cisalhante**.
2. As duas tensões normais passam a obedecer à *mesma* equação, $\partial_t \sigma_{xx} = \partial_t \sigma_{zz} = \lambda(\partial_x v_x + \partial_z v_z)$. Como partem de zero, permanecem iguais em todo instante: $\sigma_{xx} = \sigma_{zz}$, e o tensor é **isotrópico**.
3. Um tensor isotrópico é descrito por um único escalar. Define-se a **pressão** como esse escalar com sinal trocado:

$$p = -\frac{\sigma_{xx} + \sigma_{zz}}{2} = -\sigma_{xx} = -\sigma_{zz}. \quad (2.5)$$

4. Com $\mu = 0$, λ passa a ser o módulo de compressibilidade K , e $v_p = \sqrt{K/\rho}$ por (2.3).

O sistema de cinco equações colapsa em três:

$$\rho \frac{\partial \mathbf{v}}{\partial t} = -\nabla p, \quad \frac{\partial p}{\partial t} = -K \nabla \cdot \mathbf{v} + s(t) \delta(\mathbf{x} - \mathbf{x}_s). \quad (2.6)$$

O sinal de p em códigos de produção

Muitos códigos elásticos devolvem, quando se pede “pressão”, a média das tensões normais $(\sigma_{xx} + \sigma_{zz})/2$, que por (2.5) é $-\mathbf{p}$. Num L_2 puramente sintético a polaridade se cancela e o erro passa despercebido; ao comparar com outro código — ou com dado real de hidrofone — ela aparece como correlação *negativa*.

Confira a convenção antes de comparar qualquer coisa.

Redução à segunda ordem

Derivando a segunda equação de (2.6) no tempo e substituindo a primeira,

$$\frac{1}{K} \frac{\partial^2 p}{\partial t^2} = \nabla \cdot \left(\frac{1}{\rho} \nabla p \right) + \frac{1}{K} \frac{\partial s}{\partial t} \delta(\mathbf{x} - \mathbf{x}_s), \quad (2.7)$$

e, com densidade constante (e reabsorvendo constantes na fonte),

$$\frac{1}{c(\mathbf{x})^2} \frac{\partial^2 p}{\partial t^2} - \nabla^2 p = s(t) \delta(\mathbf{x} - \mathbf{x}_s) \quad (2.8)$$

O s das duas equações não é o mesmo

Quase todo texto omite isto, e custa horas de depuração. Ao derivar $\partial_t p$ para eliminar $\mathbf{v}$, o termo-fonte de (2.6) vira $(1/K) \partial_t s$. Escrever “+ s ” em (2.8) é *redefinir* a fonte — prática padrão, com uma consequência concreta:

a ondaleta efetiva das duas formulações difere por uma derivada temporal.

É por isso que dois códigos **corretos** — um em velocidade-tensão e outro em pressão — produzem traços de forma diferente alimentados pela mesma Ricker. O curso mediu: a correlação bruta entre os dois é de +0,12, e sobe para +0,85 depois de derivar um deles no tempo. Sem nenhum parâmetro de ajuste.

Por que inverter em $m = 1/c^2$

A equação (2.8) é **linear** no parâmetro $m(\mathbf{x}) = 1/c(\mathbf{x})^2$ — a vagariedade ao quadrado — e *não* é linear em c .

Isso torna a derivada do operador em relação ao parâmetro trivial (∂_m do operador = ∂_{tt}), e o gradiente adjunto sai limpo. A conversão para velocidade é a regra da cadeia:

$$\frac{\partial J}{\partial c} = \frac{\partial J}{\partial m} \cdot \frac{dm}{dc} = \frac{\partial J}{\partial m} \cdot \left(-\frac{2}{c^3} \right). \quad (2.9)$$

Note o sinal negativo: ele **inverte** o sentido da atualização entre os dois parâmetros. Trocar g_m por g_c sem aplicar (2.9) produz uma inversão que anda para o lado errado com total confiança.

2.3 O que se preserva e o que se perde

Fenômeno	Acústico	Comentário
Tempo de trânsito P	preservado	é o que a FWI mais usa
Difração, <i>multipath</i>	preservado	vantagem sobre tomografia de raio
Reflexão (ângulo baixo)	aproximado	coeficiente razoável
Reflexão (ângulo alto)	errado	AVO exige v_s
Onda S	ausente	não existe no modelo
Conversão P–S	ausente	contaminante em dado terrestre
Onda de superfície	ausente	domina o terrestre raso
Atenuação (Q)	ausente	amplitude e fase erradas
Anisotropia	ausente	exige VTI/TTI




Figura 2.1: Verificação numérica de (2.4) em um solver elástico de produção: a mesma simulação com $v_s = v_p/\sqrt{3}$ e com $v_s = 0$. No caso acústico, $\|\sigma_{xx} - \sigma_{zz}\|/\|\sigma_{xx}\|$ cai para $4,5 \times 10^{-7}$ (zero em `float32`) e σ_{xz} dá exatamente 0. O painel inferior direito mostra a diferença entre elástico e acústico — ondas S e conversões P–S, com norma comparável à do próprio dado.

Antes de usar: a transformada de Fourier, em meia página

Qualquer sinal de energia finita pode ser escrito como soma de senoides:

$$W(f) = \int_{-\infty}^{\infty} w(t) e^{-2\pi i f t} dt, \quad w(t) = \int_{-\infty}^{\infty} W(f) e^{+2\pi i f t} df.$$

$|W(f)|$ é quanta energia há na frequência f — o **espectro de amplitude**; o argumento de $W(f)$ é a **fase**.

Quatro propriedades bastam para tudo o que se faz nesta coleção:

1. **Derivar no tempo = multiplicar por $i\omega$** ($\omega = 2\pi f$). Daí sai o espectro da Ricker, logo abaixo — e daí também a armadilha da fonte da página anterior: uma derivada temporal a mais é uma multiplicação por $i\omega$, que muda a forma do pulso sem mudar a física.

2. **Deslocar no tempo = girar a fase:** $w(t - t_0)$ tem espectro $W(f)e^{-2\pi i f t_0}$, com a *mesma* amplitude. É por isso que um erro de tempo de trânsito é um erro puramente de **fase** — o mecanismo do *cycle skipping* (Cap. 5).
3. **Relação recíproca:** pulso estreito no tempo $\Leftrightarrow$ espectro largo. Não existe pulso curto e de banda estreita.
4. **Convolução vira produto:** filtrar um traço é multiplicar o espectro dele pelo do filtro — é o que a multiescala faz a cada banda.

2.4 A fonte: ondaleta de Ricker

Em trabalho sintético usa-se quase sempre a Ricker, a segunda derivada de uma gaussiana:

$$w(t) = \left[1 - 2(\pi f_0(t - t_0))^2\right] \exp\left[-(\pi f_0(t - t_0))^2\right]. \quad (2.10)$$

O espectro, e de onde vem a banda

Com $a = (\pi f_0)^2$, (2.10) é $w(t) = -\frac{1}{2a} \frac{d^2}{dt^2} e^{-at^2}$. Como $\mathcal{F}\{e^{-at^2}\} = \sqrt{\pi/a} e^{-\omega^2/4a}$ e a derivada segunda vira $(i\omega)^2 = -\omega^2$,

$$|W(f)| = \frac{2}{\sqrt{\pi}} \frac{f^2}{f_0^3} e^{-f^2/f_0^2}. \quad (2.11)$$

O máximo de (2.11) está em $f = f_0$: daí o nome frequência de **pico**. Normalizando e resolvendo $|W(f)|/|W(f_0)| = \eta$ com $u = (f/f_0)^2$, chega-se a $u e^{1-u} = \eta$, cujas raízes $u > 1$ dão

$$\eta = 0,5 \text{ (-6 dB)} : f \approx 1,64f_0, \quad \eta = 0,1 \text{ (-20 dB)} : f \approx 2,21f_0.$$

Medindo numericamente no código do curso, a banda confirma a conta:

f_0 (Hz)	pico medido	f a -6 dB	$/f_0$	$/f_0$ a -20 dB
5	4,9	8,1	1,61	2,20
10	10,0	16,1	1,61	2,20
15	14,9	24,4	1,63	2,20
25	24,9	40,8	1,63	2,21
40	40,0	65,2	1,63	2,21

Duas bandas, dois usos — não confunda

A banda a **-6 dB** ($\approx 1,6f_0$) é a faixa que *move a inversão*: use-a para raciocinar sobre **resolução**.

A banda a **-20 dB** ($\approx 2,2f_0$) ainda tem energia suficiente para *dispersar numericamente*: use-a para dimensionar a **malha**, arredondando para $2,5f_0$ por segurança.

$$\lambda_{\min} = \frac{c_{\min}}{f_{\max}} \quad (\text{malha : } f_{\max} = 2,5f_0), \quad \delta_{\min} \approx \frac{\lambda}{2} \quad (\text{resolução : } f \approx 1,6f_0). \quad (2.12)$$

O atraso t_0

A Ricker (2.10) é não causal: tem energia em $t < t_0$. O atraso padrão $t_0 = 1/f_0$ não é arbitrário — é onde a amplitude truncada em $t < 0$ cai abaixo de 0,1% do pico. Com $t_0 = 0,6/f_0$ sobra 17,5%; com $0,8/f_0$, 2,1%; com $1,0/f_0$, 0,10%. Truncar cedo demais injeta um degrau na fonte — e um degrau tem espectro largo, que dispersa.

Exercícios

1. Mostre, a partir de (2.3), que o limite $\mu \rightarrow 0$ dá $v_p \rightarrow \sqrt{K/\rho}$.
2. Um código em pressão e outro em velocidade–tensão, alimentados com a mesma Ricker, produzem traços com correlação +0,12. Antes de suspeitar da física, que três perguntas você faz?
3. Para $f_0 = 15$ Hz, qual $f_{\max}$ você usaria para dimensionar a malha, e qual para estimar a resolução?

Respostas. (1) Com $\mu = 0$, $\lambda = K$ e $v_p = \sqrt{(\lambda + 2\mu)/\rho} = \sqrt{K/\rho}$. (2) A formulação é de primeira ou segunda ordem? A fonte entra na pressão, na tensão ou na velocidade de partícula? Há divisão por Δh^2 na discretização da delta? Cada escolha muda a ondaleta efetiva, e nenhuma vem etiquetada no sismograma. (3) Malha: $2,5 \times 15 = 37,5$ Hz; resolução: $1,6 \times 15 = 24$ Hz.

Capítulo 3

Diferenças finitas: estabilidade e dispersão

A ideia deste capítulo, em uma frase

Duas restrições independentes governam a discretização. A **estabilidade** decide se a simulação roda; a **dispersão** decide se ela está certa. Cada uma tem uma fórmula fechada, e as duas juntas determinam Δh e Δt sem nenhum chute.

Antes de usar: série de Taylor e a ideia de “ordem”

Toda a discretização deste capítulo sai de uma única ferramenta. Se f é suave,

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{6}f'''(x) + \dots$$

— o valor num ponto vizinho é o valor aqui, mais correções que encolhem como potências de h .

Ordem de aproximação. Dizer que um esquema é $\mathcal{O}(h^n)$ significa que o erro cai como h^n : reduzir h pela metade divide o erro por 2^n . É uma afirmação sobre a *taxa*, não sobre o *valor* — um esquema de ordem 8 pode ser pior que um de ordem 2 para h grande, e é imbatível para h pequeno.

Como se mede na prática. Rode com h e com $h/2$ e calcule $\log_2(\text{erro}_h/\text{erro}_{h/2})$: esse número deve dar n . É *exatamente* o mesmo procedimento que o teste de Taylor do Capítulo 7 usa para validar o gradiente, com α no lugar de h .

Por que estênceis centrados têm ordem par. Somando $f(x+h)$ com $f(x-h)$, todos os termos de potência *ímpar* se cancelam. O erro começa em h^2 — de graça, só pela simetria.

3.1 O operador espacial e seus coeficientes

A derivada segunda é aproximada por um estêncil centrado de $2N+1$ pontos:

$$\left. \frac{\partial^2 f}{\partial x^2} \right|_i \approx \frac{1}{h^2} \left[c_0 f_i + \sum_{j=1}^N c_j (f_{i+j} + f_{i-j}) \right]. \quad (3.1)$$

De onde saem os coeficientes

Expandamos $f_{i\pm j} = f(x_i \pm jh)$ em série de Taylor e some os pares:

$$f_{i+j} + f_{i-j} = 2 \sum_{\ell=0}^{\infty} \frac{(jh)^{2\ell}}{(2\ell)!} f_i^{(2\ell)} = 2f_i + (jh)^2 f_i'' + \frac{(jh)^4}{12} f_i^{(4)} + \dots$$

(os termos ímpares se cancelam, que é a razão de o estêncil centrado ter ordem par). Substituindo em (3.1) e exigindo que o resultado reproduza f_i'' com erro $\mathcal{O}(h^{2N})$, obtêm-se as **condições de momento**:

$$c_0 + 2 \sum_{j=1}^N c_j = 0, \quad 2 \sum_{j=1}^N j^2 c_j = 2, \quad \sum_{j=1}^N j^{2\ell} c_j = 0 \quad (\ell = 2, \dots, N). \quad (3.2)$$

São $N+1$ equações lineares em $N+1$ incógnitas — sistema de Vandermonde, sempre solúvel. A primeira condição diz que o estêncil anula constantes; a segunda o normaliza; as demais matam os termos de erro sucessivos.

Ordem	Pontos	Coeficientes ($c_0, c_1, \dots$)
$\mathcal{O}(h^2)$	3	-2; +1
$\mathcal{O}(h^4)$	5	-5/2; +4/3; -1/12
$\mathcal{O}(h^8)$	9	-205/72; +8/5; -1/5; +8/315; -1/560

Verificação numérica em $f(x) = \sin(kx)$, com o *mesmo* h : o erro relativo medido pelo código do curso é $7,5 \times 10^{-3}$ na ordem 2, $8,9 \times 10^{-5}$ na ordem 4 e $2,0 \times 10^{-8}$ na ordem 8 — cinco ordens de grandeza entre os extremos.

Ordem alta não é luxo: é economia — e a conta completa

O ganho não é “mais preciso”, é **mais preciso para o mesmo** h , e portanto permite h *maior*. Para um *mesmo* esquema, o custo em 2D escala com h^{-3} — dois eixos espaciais e, via CFL, o eixo do tempo.

Ao *trocar* de esquema, porém, três fatores mudam ao mesmo tempo, e vale fechar a conta com todos. Trocando $\mathcal{O}(2)$ por $\mathcal{O}(8)$, a exigência de G cai de ~ 15 – 20 para ~ 4 – 5 , o que permite Δh cerca de $3\times$ maior:

Fator	Efeito	Origem
pontos da malha	$\div 9$	Δh $3\times$ maior, em 2D
passos de tempo	$\div 2,4$	$\Delta t \propto C_{\text{lim}} \Delta h$, com C_{lim} caindo de 0,71 a 0,55
operações por ponto	$\times 3,4$	estêncil de 17 pontos em vez de 5
saldo	$\div 6$	

Ou seja: a ordem alta compensa, e por uma margem grande — mas o fator não é o h^{-3} ingênuo. Se Δh fosse apenas dobrado em vez de triplicado, o saldo cairia para cerca de $\div 1,8$.

Antes de usar: modos de Fourier na malha e o fator de amplificação

A análise de estabilidade a seguir usa um truque que vale entender uma vez e reconhecer para sempre.

A ideia. O esquema é linear e, em meio homogêneo, tem coeficientes constantes. Então ele

não mistura modos de Fourier: se você o alimentar com uma única onda plana $p_i^n = \xi^n e^{i\mathbf{k} \cdot \mathbf{x}_i}$, ela continua sendo uma única onda plana após um passo, apenas multiplicada por um número ξ — o **fator de amplificação**.

O critério. Após n passos, a amplitude vale ξ^n . Logo:

$$|\xi| \leq 1 \text{ para todo } \mathbf{k} \implies \text{estável}; \quad |\xi| > 1 \text{ para algum } \mathbf{k} \implies \text{cresce exponencialmente.}$$

Como basta *um* modo instável para arruinar tudo, a condição é sempre um *pior caso* sobre $\mathbf{k}$ — e o pior caso é o modo mais curto que a malha representa, de comprimento de onda $2\Delta h$, isto é $k\Delta h = \pi$.

A conta que aparece a seguir. A discretização de ∂_{tt} produz uma equação do segundo grau $\xi^2 - (2 - X)\xi + 1 = 0$. Como o produto das raízes vale 1, ou as duas têm módulo 1 (raízes complexas: o modo *oscila*, que é o que uma onda deve fazer), ou uma tem módulo maior que 1 (raízes reais: o modo *cresce*). A fronteira entre os dois casos é o discriminante zero — e é ela que dá a condição CFL.

Dispersão, com a mesma ferramenta. Trocando $\xi = e^{-i\omega\Delta t}$ — isto é, exigindo que o modo oscile com frequência ω —, a mesma equação passa a relacionar ω com k : é a *relação de dispersão*. Estabilidade e dispersão saem da mesma conta, feita duas vezes com perguntas diferentes.

3.2 Estabilidade: a condição CFL

No tempo usa-se o esquema *leap-frog* de segunda ordem:

$$p_i^{n+1} = 2p_i^n - p_i^{n-1} + c_i^2 \Delta t^2 \left([\nabla_h^2 p^n]_i + s_i^n \right). \quad (3.3)$$

Análise de von Neumann

Procure soluções da forma $p_i^n = \xi^n e^{i\mathbf{k} \cdot \mathbf{x}_i}$ em meio homogêneo, sem fonte. O operador (3.1) aplicado a $e^{i\mathbf{k} \cdot \mathbf{x}}$ devolve

$$\frac{1}{h^2} \left[c_0 + 2 \sum_j c_j \cos(j k_x h) \right] = -\frac{S(k_x h)}{h^2}, \quad S(\theta) \equiv -\left[c_0 + 2 \sum_j c_j \cos(j\theta) \right] \geq 0. \quad (3.4)$$

Substituindo em (3.3) e escrevendo $\xi + \xi^{-1} = 2 - X$, com

$$X = \frac{c^2 \Delta t^2}{\Delta h^2} [S(k_x \Delta h) + S(k_z \Delta h)],$$

obtem-se $\xi^2 - (2 - X)\xi + 1 = 0$. As raízes têm produto 1, logo $|\xi| = 1$ (não amplifica) **se e somente se** as raízes forem complexas conjugadas, o que exige $|2 - X| \leq 2$, isto é $0 \leq X \leq 4$. Se $X > 4$, uma raiz tem módulo > 1 e o esquema *amplifica exponencialmente*.

(O índice j percorre o estêncil; não confundir com o número de onda k_x , que entra apenas através de $\theta = k_x h$.)

O pior caso é $\theta = \pi$ em cada eixo — o modo mais curto que a malha representa —, onde $S(\pi) = |c_0| + 2 \sum_j |c_j|$ para os estênceis desta tabela. Com n_{dim} dimensões:

$$C \equiv \frac{c_{\max} \Delta t}{\Delta h} \leq C_{\lim} = \frac{2}{\sqrt{n_{\dim}(|c_0| + 2 \sum_j |c_j|)}} \quad (3.5)$$

Ordem espacial	$ c_0 + 2 \sum_j c_j $	$C_{\lim}$ (2D)	$C_{\lim}$ (3D)
$\mathcal{O}(2)$	4,000	0,7071	0,5774
$\mathcal{O}(4)$	5,333	0,6124	0,5000
$\mathcal{O}(8)$	6,502	0,5546	0,4529

Duas leituras contraintuitivas

(a) **Ordem espacial maior *reduz* $\Delta t_{\max}$.** O estêncil mais largo tem $S(\pi)$ maior, e (3.5) aperta. Ganha-se em Δh e perde-se em Δt — com saldo favorável, mas a conta precisa ser feita.

(b) **O limite depende de $c_{\max}$, não de c típico.** Uma única célula rápida — sal, basalto, um artefato de interpolação — derruba Δt do modelo inteiro. Vale inspecionar $\max(c)$ antes de rodar.

A transição não é gradual: com $C_{\lim} = 0,6124$, o curso mediu $C = 0,306$ e $C = 0,551$ estáveis, e $C = 0,625$ e $C = 0,704$ produzindo NaN. Use margem de 10–20%.

3.3 Dispersão numérica

Estabilidade garante que a solução não explode; não garante que ela esteja certa. No esquema discreto, a velocidade de fase depende do número de onda: as componentes curtas viajam com velocidade errada e o pulso desenvolve uma cauda oscilatória.

A relação de dispersão completa

Repetindo a análise de von Neumann com $\xi = e^{-i\omega\Delta t}$ (solução propagante), $\xi + \xi^{-1} = 2 \cos(\omega\Delta t)$, e usando $2 - 2 \cos \theta = 4 \sin^2(\theta/2)$:

$$\frac{4}{\Delta t^2} \sin^2\left(\frac{\omega\Delta t}{2}\right) = \frac{c^2}{\Delta h^2} [S(k_x\Delta h) + S(k_z\Delta h)] \quad (3.6)$$

A velocidade de fase numérica é $c_{\text{num}} = \omega/k$, e a grandeza diagnóstica é a razão c_{num}/c , que deveria valer 1.

Tomando $\Delta t \rightarrow 0$ em (3.6) recupera-se a curva *semi-discreta* (só o erro espacial), que é a curva mostrada na maioria dos livros.

O controle prático é o número de pontos por comprimento de onda:

$$G = \frac{\lambda_{\min}}{\Delta h} = \frac{c_{\min}}{f_{\max} \Delta h}, \quad G \gtrsim \begin{cases} 15-20 & \mathcal{O}(2) \\ 8-10 & \mathcal{O}(4) \\ 4-5 & \mathcal{O}(8) \end{cases} \quad (3.7)$$

A curva espacial *não* é conservadora

Este ponto quase nunca aparece, e inverte a conclusão usual.

A discretização temporal acrescenta um erro próprio de sinal **oposto**: o estêncil espacial *atrasa* a fase, o *leap-frog* a *adianta*. O quanto um compensa o outro depende de C .

Medidas do curso, para $\mathcal{O}(4)$ com $G = 6$: a curva espacial prevê $c_{\text{num}}/c = 0,9939$ (erro de 0,6%). O esquema completo (3.6) dá 0,9980 com $C = 0,3$ — *melhor* que o previsto — mas 1,0081 com $C = 0,551$: erro real de 0,8%, já **maior** que o previsto pela curva.

Em $\mathcal{O}(8)$ o efeito é dramático: com $G = 5$ e $C = 0,9$ $C_{\text{lim}} \approx 0,50$ a curva espacial promete 0,07% e o esquema completo entrega 1,6% — porque o erro espacial praticamente sumiu e sobrou o temporal, sozinho.

Conclusão: perto do limite CFL, e sobretudo em ordem alta, quem dita a dispersão é Δt . Dimensione por (3.6), não pela curva espacial.




Figura 3.1: Esquerda: dispersão do operador espacial isolado, por ordem. Direita: traço a 2,3 km da fonte em meio homogêneo, com $G = 9,5$ e $G = 2,4$. A cauda do traço vermelho não existe na física — e *parece* geologia.

O teste de cinco minutos

Num meio **homogêneo** não há o que refletir. Qualquer oscilação depois do primeiro pulso é erro numérico. Rode esse teste antes de qualquer inversão: é o único jeito barato de separar artefato de sinal.

3.4 Receita de dimensionamento

```

1  1. f_max = 2.5 * f0                                # banda conservadora da Ricker
2  2. dh    = c_min / (G * f_max)                     # G = 8 (O4) ou 5 (O8)
3  3. dt    = 0.9 * C_lim * dh / c_max                # margem de 10% (O8: reduza C)
4  4. nt    = tempo_de_registro / dt
5  5. n_abs >= 0.5 * c_max / (f_min * dh)            # moldura -- Capitulo 4

```

O conflito embutido

Δh é ditado por c_{min} (menor comprimento de onda) e Δt por c_{max} (onda mais rápida). Um modelo com grande contraste — água a 1500 e sal a 4500 — é caro dos *dois* lados simultaneamente. É a razão prática de existirem malhas de espaçamento variável e esquemas implícitos.

Escalação do custo: reduzir Δh pela metade quadruplica o número de pontos em 2D e dobra o número de passos (via CFL): $8\times$ em 2D, $16\times$ em 3D.

Exercícios

1. Verifique que o estêncil $\mathcal{O}(4)$ satisfaz as três condições de momento.
2. Modelo com $c \in [1500, 4500]$ m/s, $f_0 = 10$ Hz, ordem 8, 2D. Calcule Δh , Δt e o número de passos para 4 s de registro.
3. A sua simulação em ordem 8 com $G = 5$ mostra mais dispersão que a curva prometia. Qual é a primeira suspeita, e qual o conserto mais barato?

Respostas. (1) $c_0 + 2(c_1 + c_2) = -5/2 + 2(4/3 - 1/12) = -5/2 + 5/2 = 0$; $2(1^2 c_1 + 2^2 c_2) = 2(4/3 - 4/12) = 2$; $1^4 c_1 + 2^4 c_2 = 4/3 - 16/12 = 0$. (2) $f_{\max} = 25$ Hz; $\lambda_{\min} = 60$ m; $\Delta h = 60/5 = 12$ m; $\Delta t = 0,9 \times 0,5546 \times 12/4500 \approx 1,33$ ms; $n_t \approx 3000$. (3) O erro temporal dominando — veja a caixa acima. O conserto mais barato é reduzir C (usar Δt menor), não refinar a malha.

Capítulo 4

Bordas, superfície livre e aquisição

A ideia deste capítulo, em uma frase

O domínio truncado reflete; a moldura absorvente existe para apagar esse eco. O topo é diferente: ali há uma interface real, e o que se escolhe não é numérico, é físico. E a geometria de aquisição define, antes de qualquer algoritmo, o que será possível recuperar.

4.1 Por que as bordas não são detalhe

Truncar o domínio transforma a borda num espelho. Em modelagem isso é feio; em FWI é pior: o resíduo passa a conter eventos que a física do modelo nunca vai explicar, e o gradiente tenta explicá-los mexendo na velocidade.

Técnica	Como	Custo	Qualidade
Truncar	nada	zero	inaceitável
Cerjan (<i>sponge</i>)	<i>taper</i> multiplicativo na moldura	baixo	razoável
Cond. absorvente	equação unidirecional na face	baixo	boa em incidência normal
CPML	coordenadas complexas esticadas	médio	excelente

Cerjan: a fórmula e o ótimo

O *sponge* multiplica o campo, a cada passo, por um fator que decai para dentro da moldura:

$$w(d) = \exp\left[-(\beta d)^2\right], \quad d = \text{distância à borda do domínio físico}, \quad (4.1)$$

com d contado em células, de 0 (início da moldura) a n_{abs} .

Existe um ótimo, e ele não é “o mais forte possível”

Taper fraco demais não absorve: a onda atravessa a moldura, bate na parede e volta. *Taper* forte demais cria um degrau de impedância na *entrada* da moldura, que ele mesmo reflete. O ótimo medido fica em $\beta \approx 0,25/n_{abs}$ — ou seja, o *taper* deve ser dimensionado **em função da espessura**, e não fixado. Um valor de β calibrado para 20 células fica fraco demais em 45 e forte demais em 10.

Por que este curso usa Cerjan mesmo sendo inferior

O *sponge* é um operador **diagonal**, portanto **auto-adjunto**. Isso preserva a validade do teste de gradiente do Capítulo 7 sem exigir que você derive o adjunto de uma CPML — que é trabalhoso e uma fonte clássica de erro silencioso.

Em produção usa-se CPML e deriva-se o seu adjunto (ou aceita-se o erro e documenta-se).

Medindo de verdade

Para medir reflexão de borda é preciso uma **referência sem borda**: a mesma simulação num domínio muito maior, onde nada reflete dentro da janela de tempo. A diferença entre os dois traços é, por construção, só artefato.

Cerjan		CPML	
n_{abs}	reflexão	n_{pml}	reflexão
0	−6,9 dB	0	−11,2 dB
10	−8,5 dB	5	−20,1 dB
20	−13,3 dB	10	−51,5 dB
30	−16,5 dB	20	−69,6 dB
45	−18,4 dB	30	−77,3 dB

Como comparar honestamente

Os valores são relativos à onda direta de *cada* experimento, e as duas geometrias diferem. A linha $n = 0$ é o espelho — reflexão de 100%, já atenuada pelo espalhamento geométrico — e a comparação justa desconta esse valor: o Cerjan com 45 pontos fica 11,5 dB abaixo do seu espelho; a CPML com 10 pontos fica 40,3 dB abaixo do dela.

A conclusão não muda, só fica precisa: **CPML com 10 pontos supera com folga Cerjan com 45**. É por isso que códigos de produção usam CPML.

Dimensionamento: a moldura precisa de pelo menos meio comprimento de onda da *menor* frequência usada. Como a FWI multiescala começa nas bandas baixas, dimensione por $f_{\min}$ — nunca por f_0 .

4.2 Superfície livre

No topo há uma decisão que não é numérica:

Superfície livre ($p = 0$ em $z = 0$) representa a interface com o ar. A onda reflete com polaridade invertida e produz as *múltiplas* de superfície e o *ghost* — eventos reais do dado.

Borda absorvente no topo representa um meio que continua para cima. Não é físico, mas elimina múltiplas do sintético.

Implementar $p = 0$ corretamente: o método das imagens

A tentação é zerar as N primeiras linhas da malha (o alcance do estêncil). Isso está **errado**: põe a superfície efetiva em $z = (N - 1)\Delta h$, e não em $z = 0$ — um erro de posicionamento que desloca todas as múltiplas.

O correto é a **imagem antissimétrica**: estender o campo para $z < 0$ com

$$p(-z, t) = -p(z, t), \quad (4.2)$$

o que impõe $p = 0$ *exatamente* em $z = 0$ por simetria, e alimenta o estêncil com valores consistentes. É assim que o propagador do curso faz.

O erro de consistência

Se o dado observado contém múltiplas e o sintético não, esse resíduo inteiro vai para o gradiente, e a FWI tenta reproduzir as múltiplas mexendo na velocidade. As saídas são duas: modelar a superfície livre, ou remover as múltiplas do dado antes. Ignorar não é opção.

4.3 Aquisição

A FWI trabalha em *shot gathers*, e a razão é conceitual: F simula tiros, então o resíduo $F(\mathbf{m}) - \mathbf{d}_{\text{obs}}$ tem de ser calculado nessa organização — um tiro por vez ou, para acelerar, somas codificadas de tiros que o simulador reproduz exatamente (Krebs *et al.*, 2009; Nível 3, Cap. 8). O que ela não usa é o dado empilhado do processamento: o empilhamento descarta a dependência com o afastamento, que é justamente a informação que separa velocidade de profundidade.




Figura 4.1: Anatomia de um *shot gather* com as curvas teóricas sobrepostas: onda direta (reta pela origem) e reflexões (hipérboles).

Anatomia, com as fórmulas

- **Onda direta:** $t = x/c_1$ — reta de inclinação $1/c_1$ passando pela origem. Não carrega informação de profundidade; frequentemente é removida.
- **Refrações (*head waves*):** retas de inclinação $1/c_2$. Dois números diferentes as caracterizam, e confundi-los é comum:

$$x_{\text{crit}} = 2h_1 \tan \theta_c, \quad \sin \theta_c = c_1/c_2 \quad (\text{onde ela começa a existir}) \quad (4.3)$$

$$x_{\text{cross}} = 2h_1 \sqrt{\frac{c_2 + c_1}{c_2 - c_1}} \quad (\text{onde ultrapassa a direta}) \quad (4.4)$$

A segunda é bem maior que a primeira — no modelo da aula 04 do curso, 2291 m contra 1006 m. As refrações dominam o afastamento longo e são a fonte mais rica de informação sobre velocidade de grande escala.

- **Reflexões:** $t(x)^2 \approx t_0^2 + x^2/v_{\text{rms}}^2$ — hipérboles cuja curvatura revela a velocidade RMS até o refletor (exata para uma camada; em meio estratificado, aproximação de afastamento pequeno).
- **Difrações:** hipérboles de ápice deslocado, geradas por pontos isolados.

Abertura e profundidade de investigação

$$z_{\text{max}} \approx \frac{x_{\text{off}}^{\text{max}}}{6} \text{ a } \frac{x_{\text{off}}^{\text{max}}}{3}$$

A razão é geométrica: para separar velocidade de posição é preciso iluminar cada ponto com *ângulos variados*, e isso exige raios vindos de longe. Afastamento curto só gera incidência quase normal, que é ambígua — mais lento e mais raso produz o mesmo tempo que mais rápido e mais fundo.

Consequência: para melhorar a recuperação em profundidade, aumente o afastamento. Receptores mais densos combatem *aliasing*; mais tiros melhoram sinal/ruído; frequência maior melhora resolução — nenhum deles ilumina mais fundo.

Amostragem espacial e ruído

$$\Delta x_{\text{rec}} < \frac{c_{\text{ap}}}{2f_{\text{max}}} \quad (4.5)$$

Acima disso há *aliasing* espacial: eventos inclinados deixam de ser contínuos entre traços. Em FWI isso é especialmente perverso, porque a inversão tenta explicar o padrão serrilhado com estrutura no modelo.

Quanto a ruído, a FWI tolera bem o **aleatório**: ele não soma coerentemente no gradiente quando se empilham muitos tiros. O que ela não tolera é ruído **coerente** e erro de modelagem sistemático — esses somam em fase e viram estrutura.

Exercícios

1. Vai começar a multiescala em 3 Hz, com $c_{\text{max}} = 4000$ m/s e $\Delta h = 10$ m. Quantas células de moldura, no mínimo?
2. Por que um *sponge* diagonal simplifica a verificação do gradiente?
3. Camada de 800 m com $c_1 = 1800$ sobre $c_2 = 3000$ m/s. Calcule a distância crítica e a de cruzamento.

Respostas. (1) $\lambda_{\text{max}} = 4000/3 \approx 1333$ m; meia onda ≈ 667 m; $n_{\text{abs}} \geq 67$ células. (2) Porque um operador diagonal é o seu próprio adjunto: nenhum termo extra precisa entrar no caminho de volta do gradiente, e o teste do Cap. 7 continua válido sem trabalho adicional. (3) $\sin \theta_c = 0,6 \Rightarrow \theta_c = 36,87^\circ$; crítica = $2 \cdot 800 \cdot \tan(36,87^\circ) = 1200$ m; cruzamento = $1600\sqrt{4800/1200} = 3200$ m.

Parte II — O problema inverso

Capítulo 5

Função objetivo e *cycle skipping*

A ideia deste capítulo, em uma frase

A não convexidade de J tem causa única e quantificável: diferença de fase maior que meio período. Dessa única observação decorrem, sem hipótese adicional, a estratégia multiescala, o critério de qualidade do modelo inicial e a motivação de todos os funcionais alternativos.

Antes de usar: convexidade, mínimo local e bacia de atração

Convexa é a função cujo gráfico fica *abaixo* de qualquer corda: $g(\theta a + (1 - \theta)b) \leq \theta g(a) + (1 - \theta)g(b)$ para $\theta \in [0, 1]$. A propriedade que interessa é a consequência: **numa função convexa, todo mínimo local é global** (e, se ela for *estritamente* convexa, o minimizador é único). Um método de descida bem projetado chega a ele, venha de onde vier.

Sem convexidade, o gradiente carrega apenas informação *local*: diz para que lado descer *aqui*, e nada sobre onde fica o fundo verdadeiro. O algoritmo pára no primeiro ponto com $\nabla J = 0$ — um **mínimo local**.

Bacia (ou vale) de atração de um mínimo é o conjunto de pontos de partida a partir dos quais a descida chega *nele*. Toda a estratégia prática da FWI — multiescala, modelo inicial, funcionais alternativos — consiste em garantir que o ponto de partida caia na bacia **certa**. Este capítulo mostra que, em FWI, a largura dessa bacia tem fórmula fechada.

Período e fase. Um sinal de frequência f repete-se a cada $T = 1/f$ segundos. Dois pulsos idênticos separados de δt estão defasados de $2\pi \delta t/T$ radianos; quando $|\delta t|$ passa de $T/2$, o ciclo do observado mais próximo do sintético deixa de ser o correspondente e passa a ser o *vizinho*. É literalmente essa troca de vizinho que produz os mínimos locais.

5.1 Formulação e propriedades

Com F o operador direto:

$$\mathbf{d}_{\text{cal}} = F(\mathbf{m}), \quad (5.1)$$

$$\mathbf{r}(\mathbf{m}) = F(\mathbf{m}) - \mathbf{d}_{\text{obs}}, \quad (5.2)$$

$$J(\mathbf{m}) = \frac{1}{2} \|\mathbf{r}\|^2 = \frac{1}{2} \sum_s \sum_r \int_0^T r^2(x_r, t; s) dt. \quad (5.3)$$




Figura 5.1: $J(c)$ varrido inteiro para quatro frequências, em meio homogêneo com $c_{\text{verd}} = 2000$ m/s — possível apenas porque há um único parâmetro. Em baixa frequência, um mínimo único e largo; em alta, um vale estreito cercado de mínimos locais.

5.2 Cycle skipping: a explicação e o critério

Se o modelo está errado, o evento sintético chega deslocado de δt em relação ao observado. Para um pulso aproximadamente harmônico de período T :

- $|\delta t| < T/2$: sintético e observado ainda se sobrepõem no *mesmo* ciclo. O resíduo aponta na direção certa.
- $|\delta t| > T/2$: o sintético se alinha ao ciclo *vizinho*. O resíduo diminui ao empurrar o modelo para o lado **errado**.

$$|\delta t| < \frac{T}{2} = \frac{1}{2f} \quad (5.4)$$

De (5.4) à tolerância em velocidade

Para um percurso de comprimento L atravessado com velocidade c , o tempo é $t = L/c$. Com um erro δc no modelo,

$$\delta t = L \left(\frac{1}{c_{\text{ini}}} - \frac{1}{c_{\text{verd}}} \right) \approx -\frac{L \delta c}{c^2} \quad (\delta c \ll c).$$

Substituindo em (5.4):

$$|\delta c| < \frac{c^2}{2fL} \quad (5.5)$$

Note as três dependências: a tolerância cai com a *frequência* e com o *comprimento do percurso*, e cresce com o *quadrado* da velocidade. Alvos profundos em meio lento são os mais difíceis.

f (Hz)	$T/2$ (ms)	$ \delta c _{\max}$ (m/s)	em %
2	250,0	667	33,3
3	166,7	444	22,2
5	100,0	267	13,3
10	50,0	133	6,7
20	25,0	67	3,3
40	12,5	33	1,7

($L = 1500$ m, $c = 2000$ m/s)

Validação numérica do critério

O curso mediu o **vale de atração** de cada frequência — o conjunto de velocidades iniciais que converge para o mínimo certo — e comparou com (5.5), usando o percurso médio fonte–receptor da geometria do experimento ($L \approx 1580$ m):

f_0 (Hz)	vale medido (m/s)	semilargura prevista	semilargura medida
3,0	1710 a 2489	422	389
6,0	1858 a 2192	211	167
12,0	1908 a 2118	105	105
25,0	1945 a 2069	51	62

Uma conta de meia linha reproduz a largura medida e a dependência $1/f$ ao longo de uma faixa de $8\times$ em frequência. É raro uma regra prática ser tão bem comportada.

Meio período é uma aproximação, e dá para medir o quão boa

O critério (5.4) vale exatamente para um pulso harmônico. Para uma ondaleta de banda finita, calcule J em função do deslocamento puro: para uma Ricker, a divisa entre “corrige certo” e “corrige errado” cai em $\delta t \approx 0,43 T$, e existe um **mínimo local espúrio** em $\delta t \approx 0,9 T$ — que é, literalmente, o vale errado em que a inversão fica presa. Ou seja: (5.4) é ligeiramente **otimista**. Use margem.

Use isto antes de rodar

Estime a frequência mais alta com que *pode começar*, dada a incerteza do modelo inicial. Se a tomografia tem 5% de erro e o percurso típico é 2 km, com $c = 2000$ m/s:

$$\delta c = 100 \text{ m/s} \implies f_{\max} = \frac{c^2}{2 \delta c L} = \frac{2000^2}{2 \cdot 100 \cdot 2000} = 10 \text{ Hz.}$$

Começar acima disso é desperdício de tempo de máquina.

5.3 A estratégia multiescala

Daí decorre, sem mais nenhuma hipótese, a receita de Bunks *et al.* (1995): inverta primeiro nas frequências baixas, onde o vale é largo; use o resultado como modelo inicial da banda seguinte; repita subindo.

```

1 m = m_inicial
2 para cada banda f em [f_baixa ... f_alta]:
3     d_filt = passa_baixa(d_obs, corte=f)      # Butterworth, tipicamente
4     para it em 1..n_iter[f]:
5         g = gradiente(m, d_filt)              # Capítulo 6
6         d_k = direcao(g, historico)           # Capítulo 8
7         a = busca_linear(m, d_k)              # Capítulo 8
8         m = m + a * d_k
9     # reinicie o historico do l-BFGS ao trocar de banda

```

Filtre os dois lados

O filtro passa-baixa tem de ser aplicado ao dado observado e ao sintético, com *exatamente* o mesmo filtro, dentro da avaliação de J . Filtrar só um dos dois introduz uma diferença de fase sistemática que a inversão vai interpretar como estrutura.

O limite honesto da multiescala

A estratégia só resgata o que a banda **mais baixa** já alcança. Se o modelo inicial estiver fora do vale de atração da menor frequência *disponível no dado*, nenhuma ordem de bandas salva — e o Capítulo 9 mostra um caso medido em que isso acontece.

O remédio seria começar mais baixo ainda, o que exige dado com energia nessas frequências. Daí o esforço da indústria em fontes de baixa frequência: elas compram vale de atração.

5.4 O modelo inicial

O modelo inicial precisa de uma única coisa: estar dentro do vale de atração da menor frequência utilizável. Isso significa acertar os **grandes** comprimentos de onda, não os detalhes.

Sobre testes sintéticos

Usar o modelo verdadeiro suavizado como inicial é um teste **generoso**: ele já começa dentro do vale por construção.

Não está errado usá-lo para validar código. Mas não confunda isso com avaliar a *robustez* do método. Para isso, degrade o modelo inicial de propósito e descubra onde ele quebra.

5.5 Além do L_2

Como o problema é de fase, boa parte da pesquisa consiste em trocar o funcional. As formas mais usadas, com a ideia de cada uma:

Funcional	Ideia	Preço
L_2 clássico	$\frac{1}{2} \int (d_{\text{cal}} - d_{\text{obs}})^2$	<i>cycle skipping</i>
Envoltória	compara só a envoltória $E = \sqrt{d^2 + (\mathcal{H}d)^2}$ ($\mathcal{H}$: transformada de Hilbert), insensível à fase fina	perde resolução
Correlação cruzada	mede o <i>deslocamento</i> ΔT que maximiza a correlação e penaliza ΔT^2	precisa janelar
Transporte ótimo	distância de Wasserstein entre sinais tratados como distribuições de massa: convexa em relação a deslocamentos	exige positividade
Adaptativa (AWI)	estima o filtro de Wiener u que leva o sintético ao observado e penaliza $\ t u\ ^2 / \ u\ ^2$	mais parâmetros

► *Nível 3, Cap. 5* — cada funcional com a sua **fonte adjunta** derivada — que é a única coisa que muda no código — e a discussão de convexidade em relação a deslocamento.

Ordem de prioridade quando a FWI não converge

1. Baixe a frequência inicial. 2. Melhore o modelo inicial. 3. *Só então* troque o funcional. Trocar o funcional é a solução mais cara e a que mais introduz parâmetros novos. Ela resolve casos em que 1 e 2 já foram esgotados.

Exercícios

1. Deduza (5.5) a partir de (5.4) e justifique a aproximação usada.
2. O seu modelo inicial tem 8% de erro, $c \approx 2500$ m/s, percursos de 3 km. Qual a maior frequência inicial defensável?
3. Por que filtrar apenas o dado observado (e não o sintético) corrompe a inversão?

Respostas. (1) $\delta t = L(1/c_{\text{ini}} - 1/c_{\text{verd}})$; expandindo em torno de c e mantendo o primeiro termo, $\delta t \approx -L\delta c/c^2$, válido para $\delta c \ll c$ — exatamente o regime em que se está perto de convergir. (2) $\delta c = 200$ m/s; $f = c^2/(2\delta c L) = 6,25 \times 10^6/(1,2 \times 10^6) \approx 5,2$ Hz. (3) Porque o filtro tem resposta de fase própria; aplicado a um só lado, ele cria um atraso sistemático entre sintético e observado que a inversão interpreta como erro de velocidade.

Capítulo 6

O método do estado adjunto

A ideia deste capítulo, em uma frase

Uma única ideia — escolher o multiplicador de Lagrange de modo a anular o termo caro — reduz o custo do gradiente de N simulações para **duas**, independentemente de N . Este capítulo faz a dedução completa e a traduz linha a linha para código.

6.1 Por que não diferenças finitas

O custo da abordagem ingênua é N modelagens *por iteração*:

Modelo	N	modelagens/iter	tempo (a 0,4 s cada)
100×100	10 000	10 000	1,1 hora
200×400	80 000	80 000	8,9 horas
500×1000	500 000	500 000	2,3 dias
3D 300 ³	27 000 000	27 000 000	125 dias

Antes de usar: multiplicadores de Lagrange, derivada funcional e operador adjunto

A dedução a seguir usa três ferramentas. Nenhuma é difícil, mas a combinação delas é o que torna a FWI possível — vale gastar uma página antes.

1. Multiplicadores de Lagrange, em dimensão finita. Para minimizar $f(\mathbf{x})$ sujeito a $\mathbf{c}(\mathbf{x}) = 0$, constrói-se

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{c}(\mathbf{x}).$$

Como $\mathbf{c} = 0$ na solução, $\mathcal{L} = f$ ali para *qualquer* $\boldsymbol{\lambda}$. Essa liberdade é o ponto: podemos escolher $\boldsymbol{\lambda}$ do jeito que for mais conveniente.

2. O truque do adjunto, ainda em dimensão finita. É aqui que a economia aparece. A versão contínua, adiante, é esta mesma conta com integrais no lugar de matrizes.

Queremos minimizar $f(\mathbf{u})$, com $\mathbf{u}$ não livre: ele resolve um sistema que depende dos parâmetros $\mathbf{q}$,

$$A(\mathbf{q}) \mathbf{u} = \mathbf{b}.$$

Pela regra da cadeia, $\frac{df}{dq_j} = \frac{\partial f}{\partial \mathbf{u}} \frac{d\mathbf{u}}{dq_j}$, e derivando a restrição, $\frac{d\mathbf{u}}{dq_j} = -A^{-1} \frac{\partial A}{\partial q_j} \mathbf{u}$.

Calcular du/dq_j exige **uma resolução de sistema por parâmetro** — é exatamente a força bruta da §6.1. Mas observe a estrutura: o que queremos é o *produto* $\frac{\partial f}{\partial \mathbf{u}} A^{-1}(\cdots)$, e um produto de três fatores pode ser associado de outro jeito. Definindo $\boldsymbol{\lambda}$ por

$$A^T \boldsymbol{\lambda} = - \left(\frac{\partial f}{\partial \mathbf{u}} \right)^T \quad (\text{uma resolução, com a matriz transposta}),$$

o gradiente inteiro sai de uma vez:

$$\frac{df}{dq_j} = \boldsymbol{\lambda}^T \frac{\partial A}{\partial q_j} \mathbf{u}.$$

Duas resoluções — uma direta e uma transposta — em vez de N . O custo deixou de depender de N . Tudo o que vem a seguir é esta conta, escrita para uma EDP.

3. Derivada funcional e integração por partes. Quando a incógnita é uma *função*, a derivada vira **derivada funcional**: perturbe $p \rightarrow p + \epsilon \delta p$ e recolha o termo proporcional a ϵ . Se o resultado tem a forma $\int \Phi \delta p \, dt \, d\mathbf{x}$, então $\delta \mathcal{L}/\delta p = \Phi$; e exigir que a derivada se anule para *toda* perturbação equivale a exigir $\Phi = 0$ ponto a ponto.

Para chegar a essa forma é preciso tirar as derivadas de cima de δp . A ferramenta é a integração por partes,

$$\int_0^T \lambda \partial_{tt} \delta p \, dt = [\lambda \partial_t \delta p - \partial_t \lambda \delta p]_0^T + \int_0^T \partial_{tt} \lambda \delta p \, dt,$$

e, no espaço, a segunda identidade de Green,

$$\int_{\Omega} (\lambda \nabla^2 \delta p - \delta p \nabla^2 \lambda) \, d\mathbf{x} = \oint_{\partial\Omega} (\lambda \partial_n \delta p - \delta p \partial_n \lambda) \, dS.$$

Os colchetes e a integral de contorno são os **termos de fronteira**. Não são detalhe técnico: são o que define as condições do problema adjunto.

4. Operador adjunto. A^* é definido por $\langle Au, v \rangle = \langle u, A^*v \rangle$ para todos u, v . Em dimensão finita e com o produto interno usual, $A^* = A^T$. A integração por partes acima é o cálculo do adjunto: cada vez que uma derivada muda de lado, está se aplicando a definição.

Um operador é **auto-adjunto** se $A^* = A$. O laplaciano com condições de contorno homogêneas é; ∂_{tt} também é; mas ∂_t **não** é — ele troca de sinal, $\partial_t^* = -\partial_t$. Essa última observação explica, sozinha, por que a equação acústica sem atenuação é reversível no tempo, e a viscoacústica — que tem uma derivada primeira — não é.

6.2 A dedução

Trabalhamos com $m(\mathbf{x}) = 1/c(\mathbf{x})^2$, porque a equação é linear nele. O problema direto entra como **restrição**:

$$\mathcal{F}(p, m) \equiv m \frac{\partial^2 p}{\partial t^2} - \nabla^2 p - s = 0, \quad p = \partial_t p = 0 \text{ em } t = 0. \quad (6.1)$$

Passo 1 — o Lagrangiano

A restrição vale para todo $\mathbf{x}$ e todo t , então o multiplicador é um *campo* $\lambda(\mathbf{x}, t)$:

$$\mathcal{L}(p, m, \lambda) = J(p) + \int_{\Omega} \int_0^T \lambda [m \partial_{tt} p - \nabla^2 p - s] dt d\mathbf{x}. \quad (6.2)$$

Como a restrição é satisfeita pela solução do problema direto, $\mathcal{L} = J$ para qualquer λ — e podemos derivar $\mathcal{L}$ em vez de J , com a vantagem de podermos *escolher* λ para eliminar o termo difícil.

Qual é o termo difícil

Pela regra da cadeia, $dJ/dm = (\partial J/\partial p)(\partial p/\partial m) + \partial J/\partial m$. O fator $\partial p/\partial m$ é uma matriz (campo de onda) $\times$ (parâmetros): calculá-la coluna a coluna é exatamente a força bruta. O truque do Lagrangiano é nunca calcular esse fator: escolhe-se λ de modo que o coeficiente que o multiplica seja *zero*.

Passo 2 — variação em relação a p

Escrevendo J com deltas de Dirac nos receptores, $J = \frac{1}{2} \iint \sum_r \delta(\mathbf{x} - \mathbf{x}_r) (p - d_{\text{obs}})^2$, a sua variação é $\iint \sum_r \delta(\mathbf{x} - \mathbf{x}_r) r \delta p$, com $r = p - d_{\text{obs}}$ avaliado no receptor.

Na integral de (6.2), integre por partes **duas vezes no tempo** e **duas vezes no espaço**:

$$\int_0^T \lambda m \partial_{tt} \delta p dt = \underbrace{\left[\lambda m \partial_t \delta p - m \partial_t \lambda \delta p \right]_0^T}_{(*)} + \int_0^T m \partial_{tt} \lambda \delta p dt, \quad (6.3)$$

$$- \int_{\Omega} \lambda \nabla^2 \delta p d\mathbf{x} = - \underbrace{\oint_{\partial\Omega} (\lambda \partial_n \delta p - \delta p \partial_n \lambda) dS}_{(**)} - \int_{\Omega} \nabla^2 \lambda \delta p d\mathbf{x}. \quad (6.4)$$

Os termos de fronteira, que quase todo texto omite

($\star$) some em $t = 0$ porque as condições iniciais são fixas ($\delta p = \partial_t \delta p = 0$), e some em $t = T$ se impusermos $\lambda = \partial_t \lambda = 0$ em $t = T$. **Essa é a origem das condições finais** do problema adjunto: elas não são uma convenção, são o que faz a conta fechar.

($\star\star$) some se λ obedecer, na fronteira de Ω , ao *adjunto* da condição de contorno do problema direto. Para condições de Dirichlet ($p = 0$, superfície livre) ou Neumann homogêneas, a condição adjunta é a mesma — o operador é auto-adjunto. Para uma CPML, **não é**, e ignorar isso é uma fonte clássica de erro silencioso no gradiente.

Restando apenas os termos proporcionais a δp :

$$\frac{\delta \mathcal{L}}{\delta p} = [m \partial_{tt} \lambda - \nabla^2 \lambda] + \sum_r r(t) \delta(\mathbf{x} - \mathbf{x}_r). \quad (6.5)$$

Passo 3 — escolher λ : a equação adjunta

Exigindo $\delta \mathcal{L}/\delta p = 0$:

$$\boxed{m \frac{\partial^2 \lambda}{\partial t^2} - \nabla^2 \lambda = - \sum_r r(t) \delta(\mathbf{x} - \mathbf{x}_r)} \quad \lambda = \partial_t \lambda = 0 \text{ em } t = T. \quad (6.6)$$

Leia a equação adjunta

É a *mesma* equação de onda do problema direto. Mudam duas coisas:

(1) A fonte não é mais a ondaleta no ponto de tiro: é o **resíduo**, com sinal trocado, injetado em *todos* os receptores simultaneamente. Cada receptor vira uma fonte.

(2) As condições são *finais* : resolve-se de trás para frente.

Interpretação física: pega-se o erro que sobrou nos receptores e joga-se de volta para dentro da Terra, para ver de onde ele veio.

Como a equação acústica sem atenuação é **auto-adjunta** (invariante por reversão temporal), basta rodar o mesmo propagador ao contrário. Em meios dissipativos essa simetria se perde — veja §11.4.

Passo 4 — variação em relação a m

Com λ escolhido, o único termo que sobra em $\delta\mathcal{L}$ é o explícito em m :

$$\frac{\partial J}{\partial m}(\mathbf{x}) = \int_0^T \lambda(\mathbf{x}, t) \frac{\partial^2 p}{\partial t^2}(\mathbf{x}, t) dt \quad (6.7)$$

e, somando sobre os tiros, na forma discreta com os pesos de quadratura:

$$\frac{\partial J}{\partial m_i} = \Delta h^2 \Delta t \sum_s \sum_n \lambda_i^n (\partial_{tt} p)_i^n. \quad (6.8)$$

Os pesos de quadratura não são decorativos

Esquecer $\Delta h^2 \Delta t$ em (6.8) produz um gradiente com a *forma* certa e a *escala* errada. A inversão ainda converge (a busca linear compensa com o passo), mas o teste do Capítulo 7 reprova, e qualquer comparação quantitativa fica sem sentido.

O que essa fórmula é

Uma **correlação cruzada de defasagem zero** entre o campo direto (sua segunda derivada temporal) e o campo adjunto, ponto a ponto.

O gradiente é grande onde os dois campos coincidem no tempo e no espaço — isto é, nos pontos onde uma perturbação do modelo teria afetado o dado.

Essa mesma estrutura é a condição de imagem da migração RTM. Em essência, a RTM é a primeira iteração de uma FWI.

6.3 Da fórmula ao código

```

1  for s in tiros:
2      # (1) DIRETO: resolve e guarda d2p/dt2
3      d_calc, extras = solver.modelar(c, geom, wavelet, i_fonte=s,
4                                     guardar_campo=True)
5      # (2) RESIDUO
6      Js, r = misfit_l2(d_calc, d_obs[:, :, s], dt); J += Js
7      # (3) ADJUNTO: mesma equacao, fonte = -residuo, de tras para frente
8      lam = solver.retropropagar(c, geom, r)
9      # (4) GRADIENTE: correlacao cruzada de defasagem zero
10     g_ext += np.einsum("tzz,tzx->zx", lam, extras["dtt"]) * (dt * dh**2)
11
12 # (5) volta ao dominio fisico -- ADJUNTO da extensao de bordas

```

```

13 g_m = solver.contrair_adjunto(g_ext)
14 # (6) regra da cadeia para velocidade
15 g_c = g_m * (-2.0 / c**3)

```

O passo (5), que quase ninguém lembra

O modelo físico é estendido com a moldura absorvente antes de propagar, e essa extensão *replica* os pixels de borda. Isso é um operador linear E , e o gradiente precisa de E^T — a sensibilidade acumulada dentro da moldura tem de ser **somada de volta** sobre o pixel de borda que a gerou, não descartada com um recorte.

```

1 # ERRADO -- descarta a sensibilidade acumulada na moldura
2 g_m = g_ext[topo:topo+nz, n:n+nx]
3
4 # CERTO -- E^T: dobra a moldura de volta sobre as bordas
5 g[topo] += g[:topo].sum(axis=0)
6 g[topo+nz-1] += g[topo+nz:].sum(axis=0)
7 g[:, n] += g[:, :n].sum(axis=1)
8 g[:, n+nx-1] += g[:, n+nx:].sum(axis=1)

```

Na montagem do curso, esse detalhe valia **9% de erro** na derivada direcional.

A regra geral

Toda operação aplicada ao modelo antes de propagar precisa do seu adjunto no caminho de volta do gradiente: extensão de bordas, interpolação entre malhas, suavização, reparametrização, mudança de unidade.

Formalmente: se $\mathbf{m}_{\text{propaga}} = E \mathbf{m}$, então $\nabla_{\mathbf{m}} J = E^T \nabla_{\mathbf{m}_{\text{propaga}}} J$. Esquecer E^T é o erro mais comum em códigos de FWI caseiros.

6.4 Armazenamento: *checkpointing*

O gradiente (6.8) exige o campo direto e o adjunto no *mesmo* instante — mas o direto avança e o adjunto retrocede.

Estratégia	Memória	Computação	Uso
Guardar tudo	$n_t n_z n_x$	1 modelagem	2D pequeno
Recomputar	1 campo	$\sim n_t$	nunca
<i>Checkpointing</i>	$n_{chk} n_z n_x$	~ 2	o padrão
Reversão de campo	contorno	2	só sem atenuação

Em 3D isso deixa de ser acadêmico

Um modelo $500 \times 500 \times 300$ com $n_t = 5000$ exigiria **1,5 TB por tiro** para guardar tudo. Por isso todo código de FWI 3D usa *checkpointing*.

E a reversão de campo exige que o operador seja reversível no tempo. Sem atenuação, é. Com atenuação, não — reconstruir o campo direto rodando um meio dissipativo ao contrário amplifica ruído exponencialmente (§11.4).




Figura 6.1: Gradiente adjunto: um tiro (esquerda), sete tiros somados (centro) e suavizado (direita). Um tiro isolado produz arcos ambíguos; é a soma sobre tiros que localiza a anomalia.

6.5 Como ler um gradiente

1. **O sinal — e em qual parâmetro.** A atualização é $\mathbf{m} \leftarrow \mathbf{m} - \alpha \mathbf{g}$, e o sentido físico depende do parâmetro. Em **velocidade**, $g_c < 0$ faz c aumentar. Em **vagarosidade ao quadrado** — a forma em que (6.7) sai — o sentido se **inverte**, porque $dm/dc = -2/c^3 < 0$: é $g_m > 0$ que faz c aumentar. Confira sempre contra uma perturbação conhecida.
2. **Artefato perto de fontes e receptores.** O campo tem amplitude enorme ali e a correlação explode. Não é informação: é geometria. Mascare.
3. **Os arcos.** Um par fonte–receptor espalha a sensibilidade por uma faixa. Ondas *transmitidas* produzem a “banana” ligando fonte e receptor; ondas *espalhadas* produzem um arco de elipse — a isócrona — com focos na fonte e no receptor. A espessura, nos dois casos, é a zona de Fresnel. Resolução finita é consequência direta disso.
4. **Iluminação decrescente com a profundidade.** Medida no curso: razão raso/profundo de $181\times$. Sem correção, a FWI só atualiza a parte rasa.

Exercícios

1. Por que as condições do problema adjunto são *finais* e não iniciais? Aponte o termo exato da dedução.
2. Escreva $\partial J/\partial c$ diretamente, sem passar por m , e explique por que a forma em m é preferível.
3. O seu código suaviza o modelo com um filtro gaussiano S antes de propagar. O que precisa mudar no gradiente?

Respostas. (1) O termo $(\star)$ avaliado em $t = T$: impor $\lambda = \partial_t \lambda = 0$ ali é o que o anula, já que δp em $t = T$ é livre. (2) $\partial J/\partial c = (-2/c^3) \int \lambda \partial_{tt} p dt$; a forma em m é preferível porque a equação é linear em m , de modo que $\partial \mathcal{F}/\partial m = \partial_{tt} p$ sai sem regra da cadeia. (3) O gradiente precisa de S^T — que, para um filtro gaussiano simétrico, é o próprio S ; mas isso *precisa* ser aplicado, não presumido.

Capítulo 7

Verificação do gradiente

A ideia deste capítulo, em uma frase

Um gradiente errado não gera erro nem trava o programa: gera uma inversão que roda até o fim e devolve um modelo plausível e errado. Existem três testes, de custo baixo, que separam “o código roda” de “o código está certo” — e o terceiro deles é conclusivo.

7.1 O modo de falha silencioso

Por que o erro não aparece

Um gradiente errado geralmente ainda é uma direção de descida *aproximada*. A busca linear encontra um passo que reduz J , a curva de convergência desce, e o modelo final tem estrutura. Nenhum dos sintomas normais aparece. Você descobre quando alguém tenta reproduzir — ou quando o resultado não bate com um poço. Por isso a verificação é **obrigatória**, e antes da primeira inversão.

7.2 Teste 1 — diferenças finitas pontuais

Compara $\partial J / \partial m_i$ em alguns pixels com a mexida bruta:

$$\frac{\partial J}{\partial m_i} \stackrel{?}{\approx} \frac{J(\mathbf{m} + \varepsilon \mathbf{e}_i) - J(\mathbf{m} - \varepsilon \mathbf{e}_i)}{2\varepsilon}. \quad (7.1)$$

Serve para **localizar** onde o gradiente erra — não para aprovar ou reprovar. Resultado medido pelo curso:

Ponto	$ g $ relativo	Adjunto	Dif. finitas	Razão
(0, 50)	1,0	$4,7484 \times 10^1$	$4,7489 \times 10^1$	0,9999
(17, 89)	$5,1 \times 10^{-1}$	$-2,4217 \times 10^1$	$-2,4219 \times 10^1$	0,9999
(34, 89)	$2,1 \times 10^{-1}$	9,8459	9,8452	1,0001
(14, 21)	$8,7 \times 10^{-2}$	-4,1222	-4,1195	1,0006
(38, 27)	$1,0 \times 10^{-7}$	$4,86 \times 10^{-6}$	$4,28 \times 10^{-3}$	0,0011

A última linha é instrutiva, e não é um *bug*

Num ponto de gradiente desprezível, numerador e denominador são ambos da ordem do ruído de `float32`, e a razão entre eles não significa nada. Isso **não** é erro de gradiente: é o limite de precisão do próprio teste.

Sempre pondere o teste pontual pela magnitude local de $|g|$, e nunca reprove um código por causa de um ponto de sensibilidade nula.

7.3 Teste 2 — derivada direcional

Compara $\langle \mathbf{g}, \mathbf{h} \rangle$ com a diferença centrada ao longo de uma direção $\mathbf{h}$:

$$\rho(\alpha) = \frac{\langle \mathbf{g}, \mathbf{h} \rangle}{[J(\mathbf{m} + \alpha \mathbf{h}) - J(\mathbf{m} - \alpha \mathbf{h})]/2\alpha} \stackrel{?}{\rightarrow} 1. \quad (7.2)$$

Testa o gradiente *inteiro* em um número só, e custa 2 modelagens por α . É o teste do dia a dia.

α	Numérico (centrado)	Razão
0,4	$4,56559876 \times 10^{-6}$	1,000661
0,2	$4,56776551 \times 10^{-6}$	1,000186
0,1	$4,56870921 \times 10^{-6}$	0,999980
0,05	$4,56812642 \times 10^{-6}$	1,000107
0,02	$4,57093344 \times 10^{-6}$	0,999493
0,01	$4,56566693 \times 10^{-6}$	1,000646

Erro máximo: 0,07%.

A escolha da direção $\mathbf{h}$

Uma direção *aleatória* é quase ortogonal ao gradiente (que é suave), o que deixa $\langle \mathbf{g}, \mathbf{h} \rangle$ pequeno e o teste dominado por arredondamento e pelos termos de ordem superior (a curvatura em si se cancela na diferença centrada). Use uma direção **suave** — o próprio gradiente normalizado é a escolha mais confiável.

Antes de usar: ordem de convergência, e como lê-la num gráfico log-log

Este teste não compara *valores*: compara *taxas*. A ferramenta é a mesma da §3.1, usada de outro jeito.

Se um erro se comporta como $E(\alpha) = C\alpha^n$, então $\log E = \log C + n \log \alpha$: em eixos logarítmicos, é uma **reta de inclinação** n . Medir n é medir a inclinação — ou, numericamente,

$$n \approx \frac{\log(E(\alpha_1)/E(\alpha_2))}{\log(\alpha_1/\alpha_2)}.$$

A graça do método é que a inclinação **não depende de C** : você não precisa saber o valor certo da derivada, nem a escala do problema, nem calibrar nada. Basta que a reta tenha a inclinação prevista pela teoria. É o que torna este teste conclusivo, e não apenas indicativo.

7.4 Teste 3 — teste de Taylor (o conclusivo)

Não compara valores: compara **taxas de convergência**.

$$E_0(\alpha) = |J(\mathbf{m} + \alpha \mathbf{h}) - J(\mathbf{m})| \sim \mathcal{O}(\alpha), \quad (7.3)$$

$$E_1(\alpha) = |J(\mathbf{m} + \alpha \mathbf{h}) - J(\mathbf{m}) - \alpha \langle \mathbf{g}, \mathbf{h} \rangle| \sim \mathcal{O}(\alpha^2). \quad (7.4)$$

Por que $\mathcal{O}(\alpha^2)$ prova que o gradiente é exato

Por Taylor, $J(\mathbf{m} + \alpha \mathbf{h}) = J(\mathbf{m}) + \alpha \langle \nabla J, \mathbf{h} \rangle + \frac{\alpha^2}{2} \mathbf{h}^T H \mathbf{h} + \mathcal{O}(\alpha^3)$. Então

$$E_1(\alpha) = \left| \alpha \langle \nabla J - \mathbf{g}, \mathbf{h} \rangle + \frac{\alpha^2}{2} \mathbf{h}^T H \mathbf{h} + \dots \right|.$$

Se $\mathbf{g} = \nabla J$, o termo linear desaparece e sobra $\mathcal{O}(\alpha^2)$. Se $\mathbf{g} \neq \nabla J$, o termo linear sobrevive e $E_1 \sim \mathcal{O}(\alpha)$.

Este é o diagnóstico mais informativo que existe, e não exige conhecer a resposta certa: basta observar a inclinação em escala log-log.

α	E_0	E_1	ordem E_0	ordem E_1
0,4	$2,285 \times 10^{-6}$	$4,578 \times 10^{-7}$	—	—
0,2	$1,028 \times 10^{-6}$	$1,146 \times 10^{-7}$	1,15	2,00
0,1	$4,855 \times 10^{-7}$	$2,867 \times 10^{-8}$	1,08	2,00
0,05	$2,355 \times 10^{-7}$	$7,116 \times 10^{-9}$	1,04	2,01
0,025	$1,160 \times 10^{-7}$	$1,756 \times 10^{-9}$	1,02	2,02




Figura 7.1: Esquerda: teste de Taylor em log-log, com as retas de referência $\mathcal{O}(\alpha)$ e $\mathcal{O}(\alpha^2)$. Direita: razão da derivada direcional; faixa verde de $\pm 2\%$.

7.5 Diagnosticar pelo padrão

Padrão	Diagnóstico
$\rho \approx 1$, estável	gradiente correto
ρ estável mas $\neq 1$	erro sistemático : fator de escala esquecido, sinal trocado, peso de quadratura (Δt , Δh^2) faltando, termo ausente no adjunto, ou adjunto de um pré-processamento omitido. Valor estável é boa notícia: o <i>bug</i> é determinístico
ρ instável	ruído numérico: α pequeno demais para a precisão usada. Aumente α ou use precisão dupla
$E_1 \sim \mathcal{O}(\alpha)$	o gradiente <i>não</i> é a derivada: sobrou termo de primeira ordem

7.6 Estudo de caso: o *bug* que estes testes encontraram

Vale o relato completo, porque mostra os três testes se complementando.

O propagador do curso **reprovou** no teste da derivada direcional, com razão 0,9118 em *todos* os α , ao longo de uma faixa de $40\times$:

α	numérico	razão
0,4	$2,41766 \times 10^{-6}$	0,911797
0,2	$2,41808 \times 10^{-6}$	0,911639
0,1	$2,41747 \times 10^{-6}$	0,911871
0,05	$2,41784 \times 10^{-6}$	0,911728
0,02	$2,41946 \times 10^{-6}$	0,911119
0,01	$2,41739 \times 10^{-6}$	0,911900

Estabilidade perfeita descarta ruído numérico e aponta erro sistemático. O teste **pontual** localizou a região: razão $\approx 0,99$ no miolo do modelo e $\approx 0,72$ perto da superfície. O erro estava nas bordas — era exatamente o E^T omitido, descrito no Capítulo 6. Com a correção, a razão passou de 0,9118 para 1,0001.

Protocolo mínimo, a rodar sempre que o código mudar

1. Modelo pequeno (50×100 basta), poucos tiros, f_0 moderado.
2. Direcional com 5–6 valores de α cobrindo duas ordens de grandeza. Se $\rho \neq 1$, **pare e conserte**.
3. Taylor: confirme inclinação 2 em log-log.
4. Pontual apenas se 2 ou 3 falharem, para localizar.

Custa minutos. Um gradiente errado custa semanas.

Capítulo 8

Otimização

A ideia deste capítulo, em uma frase

Todos os métodos têm a forma $\mathbf{m}_{k+1} = \mathbf{m}_k + \alpha_k \mathbf{d}_k$. O que muda é quanta informação de **curvatura** se usa para construir $\mathbf{d}_k$ — e, como a Hessiana é impensável neste tamanho, toda a arte está em aproximá-la de graça.

Antes de usar: o modelo quadrático local: gradiente, Hessiana e direção de descida

Todo método de otimização responde à mesma pergunta: se eu só enxergo a vizinhança do ponto onde estou, qual é o melhor palpite sobre onde fica o fundo?

O modelo local. Expandindo J em torno de $\mathbf{m}$:

$$J(\mathbf{m} + \delta) \approx J(\mathbf{m}) + \langle \mathbf{g}, \delta \rangle + \frac{1}{2} \delta^T H \delta, \quad \mathbf{g} = \nabla J, \quad H_{ij} = \frac{\partial^2 J}{\partial m_i \partial m_j}.$$

O **gradiente** é a inclinação; a **Hessiana** é a curvatura. Minimizar o lado direito dá o passo de Newton $\delta = -H^{-1}\mathbf{g}$, e todos os métodos deste capítulo são aproximações dele.

Direção de descida. $\mathbf{d}$ é direção de descida se $\langle \mathbf{g}, \mathbf{d} \rangle < 0$ — andar um pouquinho nela reduz J . O gradiente negativo sempre serve; qualquer $-P\mathbf{g}$ com P **positiva definida** também serve, porque $\langle \mathbf{g}, -P\mathbf{g} \rangle = -\mathbf{g}^T P \mathbf{g} < 0$. É por isso que toda aproximação da inversa da Hessiana precisa ser mantida positiva definida: é o que garante que o método continue descendo.

Positiva definida significa $\mathbf{v}^T P \mathbf{v} > 0$ para todo $\mathbf{v} \neq 0$ — geometricamente, que a superfície local é uma tigela em todas as direções, sem sela nem vale plano.

Condicionamento. A razão entre o maior e o menor autovalor de H é o *número de condição*, e mede o quão alongado é o vale: condição 1 é uma tigela circular (a descida máxima acerta de primeira); condição 10^4 é um desfiladeiro (ela ziguezagueia). **Pré-condicionar é tentar deixar o vale mais redondo** — nada além disso.

8.1 O panorama

Método	$\mathbf{d}_k$	Memória	Em FWI
Newton	$-H^{-1}\mathbf{g}$	N^2	impossível
Gauss–Newton	$-(J'^T J')^{-1}\mathbf{g}$	N^2	só truncado
Descida máxima	$-\mathbf{g}$	N	barato, lento
Grad. conjugado	$-\mathbf{g} + \beta_k \mathbf{d}_{k-1}$	$2N$	bom custo/benefício
l-BFGS	$-H_{\text{aprox}}\mathbf{g}$	$2\ell N$	o padrão

Com $N = 10^6$, a Hessiana tem 10^{12} entradas: 4 TB em `float32`. Não se monta, não se armazena, não se inverte.

Mas a Hessiana **importa**: na diagonal, a iluminação de cada ponto; fora dela, o acoplamento entre pontos do modelo (e, em multiparâmetro, entre parâmetros). Os métodos quase-Newton existem para capturar parte disso sem montar a matriz.

Gradiente conjugado não linear

$$\mathbf{d}_k = -\mathbf{g}_k + \beta_k \mathbf{d}_{k-1}, \quad \beta_k^{\text{FR}} = \frac{\|\mathbf{g}_k\|^2}{\|\mathbf{g}_{k-1}\|^2}, \quad \beta_k^{\text{PR}} = \frac{\langle \mathbf{g}_k, \mathbf{g}_k - \mathbf{g}_{k-1} \rangle}{\|\mathbf{g}_{k-1}\|^2}. \quad (8.1)$$

Na prática usa-se Polak–Ribière com salvaguarda $\beta_k = \max(\beta_k^{\text{PR}}, 0)$, o que equivale a *reiniciar* o método (voltar à descida máxima) sempre que a fórmula produziria uma direção ruim.

l-BFGS: a recursão de dois laços

O l-BFGS constrói uma aproximação da *inversa* da Hessiana usando apenas os últimos ℓ pares $\mathbf{s}_k = \mathbf{m}_{k+1} - \mathbf{m}_k$ e $\mathbf{y}_k = \mathbf{g}_{k+1} - \mathbf{g}_k$, sem nunca formar matriz alguma:

```

1  # entrada: g (gradiente atual), pares (s_i, y_i), i = k-1 ... k-l
2  q = g
3  for i in [k-1, ..., k-l]:
4      rho_i = 1.0 / dot(y_i, s_i)
5      alpha_i = rho_i * dot(s_i, q)
6      q = q - alpha_i * y_i
7
8  gamma = dot(s_{k-1}, y_{k-1}) / dot(y_{k-1}, y_{k-1})
9  r = gamma * q
10
11 for i in [k-1, ..., k-l]:
12     beta_i = rho_i * dot(y_i, r)
13     r = r + s_i * (alpha_i - beta_i)
14
15 d = -r
```

O custo é $4\ell N$ operações e $2\ell N$ de memória; com $\ell = 5$ a 20, isso é desprezível diante de uma modelagem.

Dois cuidados que resolvem a maioria dos problemas

1. **Reinicie o histórico ao trocar de banda de frequência** na multiescala. Os pares $(\mathbf{s}, \mathbf{y})$ descrevem a curvatura do problema *antigo*; mantidos, atrapalham.
2. **Rejeite pares com $\langle \mathbf{y}, \mathbf{s} \rangle \leq 0$** . A condição de curvatura $\langle \mathbf{y}, \mathbf{s} \rangle > 0$ é o que garante que a aproximação seja positiva definida — e, portanto, que $\mathbf{d}_k$ seja direção de descida. Ela é satisfeita automaticamente se a busca linear cumprir as condições de Wolfe.

8.2 A busca linear, onde o tempo é gasto

Achar a direção é metade do trabalho; decidir *quanto andar* é a outra. Em FWI cada tentativa custa uma modelagem completa de todos os tiros.

$$\text{(Armijo, decréscimo suficiente)} \quad J(\mathbf{m} + \alpha \mathbf{d}) \leq J(\mathbf{m}) + c_1 \alpha \langle \mathbf{g}, \mathbf{d} \rangle, \quad (8.2)$$

$$\text{(curvatura, 2ª cond. de Wolfe)} \quad \langle \nabla J(\mathbf{m} + \alpha \mathbf{d}), \mathbf{d} \rangle \geq c_2 \langle \mathbf{g}, \mathbf{d} \rangle, \quad (8.3)$$

tipicamente $c_1 = 10^{-4}$ e $c_2 = 0,9$.

Duas estratégias, e quando usar cada uma

Retrocesso (*backtracking*). Tente α ; se Armijo falhar, $\alpha \leftarrow \alpha/2$. Simples e robusto, gasta 5–10 avaliações. Use quando o gradiente ainda não é confiável.

Ajuste parabólico. Já se conhece $J(0)$ e a inclinação $\langle \mathbf{g}, \mathbf{d} \rangle$; com *uma* avaliação extra fica determinada a parábola

$$q(\alpha) = J_0 + \langle \mathbf{g}, \mathbf{d} \rangle \alpha + c \alpha^2, \quad \alpha^* = -\frac{\langle \mathbf{g}, \mathbf{d} \rangle}{2c},$$

cujo mínimo dá o passo. Acerta em ~ 2 avaliações. É o padrão depois que o código está verificado.

O chute inicial do passo

O critério com significado físico: *não altere o modelo em mais de 1–3% de uma vez*. Isso é mais confiável que qualquer estimativa puramente matemática, porque respeita a escala do problema. Em prática:

$$\alpha_0 = \frac{0,02 \max|\mathbf{m}|}{\max|\mathbf{d}|}.$$

8.3 A Hessiana e o pré-condicionamento

A estrutura da Hessiana de mínimos quadrados

Com $J = \frac{1}{2} \|\mathbf{r}(\mathbf{m})\|^2$ e $J' = \partial \mathbf{r} / \partial \mathbf{m}$ (a matriz de sensibilidade, ou jacobiana),

$$\mathbf{g} = J'^T \mathbf{r}, \quad H = \underbrace{J'^T J'}_{H_{\text{GN}}} + \underbrace{\sum_i r_i \nabla^2 r_i}_{\text{termo de segunda ordem}}. \quad (8.4)$$

A aproximação de **Gauss–Newton** descarta o segundo termo, o que é justificável quando os resíduos são pequenos ou o problema é quase linear. H_{GN} é sempre semidefinida positiva — daí a sua popularidade.

Em FWI, o termo descartado contém a informação sobre *múltiplo espalhamento*: ele é o que distingue uma reflexão de segunda ordem de uma estrutura nova. Ignorá-lo é barato e quase sempre aceitável; saber que foi ignorado é obrigatório.

O que o pré-condicionamento realmente é

A atualização ideal de Newton seria $\delta \mathbf{m} = -H^{-1} \mathbf{g}$. O pré-condicionador P é uma aproximação *barata* de H^{-1} .

A diagonal de H_{GN} é bem aproximada pela **energia do campo direto** em cada ponto — a iluminação. A aproximação tem nome e referência: é o *pseudo-Hessiano* de Shin *et al.* (2001), que fica só com a diagonal (despreza o acoplamento entre pontos) e ainda despreza a propagação de cada ponto até os receptores.

É uma aproximação, não uma identidade — a diagonal exata de $J'^T J'$ envolve também essa função de Green até os receptores. Mas é boa o bastante, e barata o bastante, para ser o pré-condicionador padrão:

$$P_{ii}^{-1} \approx \int_0^T [\partial_{tt} p(\mathbf{x}_i, t)]^2 dt + \epsilon, \quad \tilde{\mathbf{g}} = P \mathbf{g}. \quad (8.5)$$

O ϵ evita divisão por zero em regiões não iluminadas — onde, justamente, não se deve amplificar nada.

O que ele **não** faz: não corrige *cycle skipping*, não inventa informação onde não houve iluminação, e não substitui um bom modelo inicial.

Efeito medido no curso (correlação do gradiente com a perturbação verdadeira):

Versão do gradiente	Correlação
bruto	+0,0390
mascarado (faixa de fonte/receptor)	+0,0830
mascarado + suavizado	+0,0842
+ compensação de profundidade	+0,0898
balanço de energia + suavização (código de produção)	+0,0880

Como ler esses valores

Os números absolutos são baixos, e isso está *certo*. Um gradiente não é o modelo: é uma direção de busca, espalhada nos arcos de Fresnel e comparada aqui com uma anomalia de ~ 300 pixels em 10 000. Esperar correlação alta seria esperar que a FWI terminasse numa iteração.

O que importa é a variação *relativa*: o tratamento mais que dobra a correlação, e esse ganho, repetido a cada iteração, muda a convergência da inversão inteira.

Receita, em ordem de importância: (1) mascare a faixa de fonte/receptor; (2) compense a iluminação; (3) suavize ($\sigma = 1$ a 3 células); (4) limite o modelo a uma caixa física.

8.4 Comparação medida

Problema real de FWI, malha 60×100 , 5 tiros, $f_0 = 8$ Hz, 12 iterações, mesmo pré-condicionamento (erro do modelo inicial: 4,71%):

Método	J_{final}/J_0	erro final	ganho	avaliações
Descida máxima	0,1035	3,82%	+19,0%	30
Gradiente conjugado	0,0493	3,29%	+30,1%	28
l-BFGS	0,0419	3,26%	+30,7%	28




Figura 8.1: Comparação dos três otimizadores. Os dois painéis inferiores à direita contam histórias diferentes: por iteração e por custo.

Compare por CUSTO, não por iteração

Por *iteração*, o l-BFGS quase sempre vence, porque cada iteração usa curvatura acumulada. Por *custo* — número de modelagens — a comparação pode mudar, porque o número de avaliações da busca linear varia de método para método. Neste experimento ficou praticamente empatado (30, 28 e 28), mas não conte com isso.

Sempre que comparar otimizadores num relatório, mostre o eixo de custo.

Exercícios

1. Mostre que $\mathbf{g} = J^T \mathbf{r}$ para $J = \frac{1}{2} \|\mathbf{r}\|^2$, e identifique onde o estado adjunto entra nessa expressão.
2. Por que rejeitar pares com $\langle \mathbf{y}, \mathbf{s} \rangle \leq 0$ no l-BFGS?
3. A sua busca linear devolve $\alpha = 0$ na terceira iteração. Liste três causas, em ordem de probabilidade.

Respostas. (1) $\nabla_{\mathbf{m}}(\frac{1}{2} \mathbf{r}^T \mathbf{r}) = (\partial \mathbf{r} / \partial \mathbf{m})^T \mathbf{r} = J^T \mathbf{r}$. O estado adjunto é exatamente o algoritmo que aplica J'^T a um vetor sem formar J' . (2) Porque $\langle \mathbf{y}, \mathbf{s} \rangle > 0$ é a condição que garante positividade definida da aproximação, e portanto que a direção seja de descida. (3) Gradiente errado (verifique primeiro); pré-condicionamento exagerado deixando a direção quase ortogonal a $-\mathbf{g}$; histórico do l-BFGS contaminado por uma troca de banda sem reinitialização.

Capítulo 9

A FWI completa: fluxo de trabalho

A ideia deste capítulo, em uma frase

Um fluxo de FWI é uma sequência de decisões, quase todas tomadas *antes* da primeira iteração. Este capítulo monta o fluxo, e mostra — com números medidos — como ele pode falhar produzindo um resultado que parece bom.

9.1 O fluxo

```
1  # ----- antes de qualquer inversao -----
2  1. preparar dado:    remover onda direta (se nao modelada),
3                      decidir sobre multiplas, estimar a wavelet
4  2. modelo inicial:  tomografia / analise de velocidade / pocos
5  3. dimensionar:     dh, dt, n_abs          (Caps. 3 e 4)
6  4. VERIFICAR o gradiente          (Cap. 7)
7
8  # ----- multiescala -----
9  5. para cada banda f em [f_baixa ... f_alta]:
10     d_filt = passa_baixa(d_obs, f)
11     reiniciar historico do l-BFGS
12     para it em 1..n_iter[f]:
13         g = gradiente(m, d_filt)          # Cap. 6
14         g = preconditionar(g)             # Cap. 8
15         d = direcao(g, historico)         # Cap. 8
16         a = busca_linear(m, d)            # Cap. 8
17         m = projetar_na_caixa(m + a*d)    # Cap. 10
18
19  # ----- depois -----
20  6. diagnosticar e reportar              (Caps. 9 e 12)
```

A ordem dos passos 3 e 4 não é negociável

Verificar o gradiente *depois* de rodar a inversão é inútil: se ele estava errado, tudo o que foi produzido até ali precisa ser refeito. O teste custa minutos (Cap. 7).

9.2 A ondaleta da fonte

Em dado sintético a fonte é conhecida. Em dado real, **não** — e um erro de ondaleta entra no resíduo exatamente como um erro de modelo.

A saída padrão é estimá-la por mínimos quadrados, aproveitando que J é *quadrática* na ondaleta (o problema é linear nela, mesmo sendo não linear em $\mathbf{m}$). No domínio da frequência, para cada

ω :

$$w(\omega) = \frac{\sum_r \overline{g_r(\omega)} d_{\text{obs},r}(\omega)}{\sum_r |g_r(\omega)|^2 + \epsilon}, \quad (9.1)$$

com $g_r(\omega)$ a resposta do modelo atual a uma fonte unitária. Isto é, na prática, um filtro de casamento entre sintético e observado.

Como usar (9.1) sem se enganar

Reestime a ondaleta **a cada troca de banda**, não a cada iteração — reestimar sempre deixa a fonte absorver o erro de modelo, e a inversão pára de melhorar o modelo.

E desconfie de uma ondaleta estimada que muda muito entre bandas: isso indica que ela está compensando física faltante, não a assinatura da fonte.

9.3 Um experimento controlado

Mesmo modelo inicial, mesmo otimizador, *mesmo número total de iterações* (12). A única diferença é a ordem em que a informação entra:

Métrica	Inicial	Mono (25 Hz)	Multi (5/12/25)
Erro relativo do modelo	8,00%	7,35%	7,20%
Ganho sobre o inicial	—	+8,1%	+10,0%
Correlação	0,9333	0,9173	0,9296
R^2	0,7284	0,7708	0,7799
Tempo	—	3,8 min	5,7 min

Erro relativo dos *dados*: 0,2573 (inicial) $\rightarrow$ 0,0719 (final).

Leia este resultado com honestidade

A vantagem da multiescala aqui é real mas **modesta** — 0,15 pontos percentuais. E isso é esperado: o próprio monoescala *melhorou* o modelo, sinal de que o inicial já estava dentro do vale de atração de 25 Hz. Quando o monoescala não sofre *cycle skipping*, não há muito para o multiescala resgatar.

Note que isso *não* se deduz dos 8% por (5.5): a 25 Hz, com $c \approx 2300$ m/s e percursos de 1–2 km, a tolerância seria de 2–5%. A diferença é que (5.5) fala de erro *cinemático* acumulado no percurso, enquanto o erro relativo de modelo é uma norma global que mistura todas as escalas — um inicial suave pode ter 8% de erro relativo e cinemática quase certa.

Note também a linha da correlação: ela *piorou* em relação ao inicial nos dois casos, enquanto o erro relativo melhorou. Métricas diferentes medem coisas diferentes — por isso se reporta mais de uma.

9.4 Estudo de robustez

O teste que mede o valor real da estratégia é degradar o inicial de propósito. Quatro modelos iniciais, com uma variante do mesmo fluxo (4 tiros em vez de 6; 12 iterações no total em ambos os casos, de modo que os números não coincidem com os da tabela anterior):

Modelo inicial	erro ini.	mono 25 Hz	multi 5/12/25	vantagem
linear suave	7,96%	7,34%	7,07%	+0,27 pp
linear lento (viesado)	16,68%	17,57%	17,34%	+0,24 pp
constante	16,32%	16,10%	16,06%	+0,04 pp
suavizado forte	4,95%	4,01%	3,70%	+0,31 pp

Quatro leituras, e a segunda é a mais importante

Primeira: a multiescala venceu em *todos* os casos. A vantagem é consistente, ainda que modesta nesta escala de problema.

Segunda — olhe a linha “linear lento”. O erro inicial era 16,68% e a FWI terminou em 17,57% (mono) e 17,34% (multi): **a inversão piorou o modelo**. Ela não travou, não deu erro, e a função objetivo caiu direitinho. Convergiu para um mínimo local e, no caminho, degradou o que já se sabia.

Este é o fracasso mais perigoso da FWI, porque *não se parece com fracasso*. É por isso que reportar o erro do modelo **inicial** não é formalidade.

Terceira: o melhor resultado absoluto (3,70%) veio do inicial “suavizado forte” — o modelo verdadeiro filtrado, inicial privilegiado que só existe em teste sintético. Compare com “constante”, que termina em 16%: a diferença não está no algoritmo, está no que já se sabia antes de começar.

Quarta — a que contraria a expectativa: a vantagem *não* cresceu quando o inicial piorou. Pela tolerância (5.5), com $c \approx 2300$ m/s e percursos de 1 a 2 km, o vale a 5 Hz fica entre $\sim 11\%$ e $\sim 23\%$. Um erro de $\sim 16\%$ está na borda desse vale, ou fora dele, *já na primeira banda* — e aí nenhuma ordem de bandas salva. O remédio seria começar em 2–3 Hz, o que exige dado com energia lá.




Figura 9.1: Monoescala *versus* multiescala: modelos recuperados, mapas de erro e perfil vertical.

9.5 Como reportar uma FWI

O mínimo que sustenta uma conclusão

Uma figura de “antes e depois” não sustenta nada. Reporte:

- **erro relativo de modelo** $\|\mathbf{m}_{\text{est}} - \mathbf{m}_{\text{verd}}\| / \|\mathbf{m}_{\text{verd}}\|$ — e o mesmo número para o modelo *inicial*;
- **curva de convergência** de J , com eixo de *custo*;
- **perfis verticais** comparando verdadeiro, inicial e invertido;
- **mapa de erro** $\mathbf{m}_{\text{est}} - \mathbf{m}_{\text{verd}}$, que revela *onde* o método falhou;
- **comparação de sismogramas** observado $\times$ final, e o **resíduo** — ele é mais informativo que o valor de J .

Uma FWI que sai de 2% para 1,5% não demonstra quase nada; uma que sai de 20% para 5% demonstra muito. Sem o ponto de partida, o número final não significa nada.

Capítulo 10

Regularização e informação a priori

A ideia deste capítulo, em uma frase

Onde o dado não restringe o modelo, alguma coisa vai preencher o vazio. Regularizar é escolher *o quê*, explicitamente, em vez de deixar a escolha para o ruído.

Antes de usar: problema mal posto, espaço nulo, e a diferença entre L_1 e L_2

Bem posto, no sentido de Hadamard, exige três coisas: a solução *existe*, é *única*, e *depende continuamente* dos dados. A FWI falha nas duas últimas — e cada falha produz um sintoma diferente.

Falha de unicidade → **espaço nulo**. Se existe $\delta \mathbf{m} \neq 0$ tal que $F(\mathbf{m} + \delta \mathbf{m}) = F(\mathbf{m})$ (ou difere menos que o ruído), o dado é *indiferente* a $\delta \mathbf{m}$. Esse conjunto de direções é o espaço nulo prático do problema. Nele o gradiente é nulo e o algoritmo não tem opinião — o valor final ali vem do modelo inicial ou da regularização, **nunca do dado**.

Falha de continuidade → **amplificação de ruído**. Nas direções de sensibilidade pequena mas não nula, uma perturbação minúscula no dado exige uma perturbação enorme no modelo: ruído vira estrutura de grande amplitude.

Regularizar é somar um termo que dá uma opinião exatamente onde o dado não tem nenhuma.

L_1 contra L_2 : por que a escolha muda a geologia do resultado. Para um vetor de variações $\mathbf{u}$,

$$\|\mathbf{u}\|_2^2 = \sum_i u_i^2, \quad \|\mathbf{u}\|_1 = \sum_i |u_i|.$$

Elevar ao quadrado pune *desproporcionalmente* os valores grandes: concentrar toda a variação em um ponto fica caríssimo, e diluí-la fica barato. A norma L_1 cobra o mesmo total dos dois jeitos.

Consequência: minimizar a L_2 da variação produz soluções **suaves**; minimizar a L_1 produz soluções **esparsas em variação** — quase constantes por pedaços, com saltos nítidos. É a mesma matemática que, em outro contexto, faz o LASSO selecionar poucas variáveis.

Derivada de um funcional integral. Para $R(m) = \int G(\nabla m) \, d\mathbf{x}$, perturbando $m \rightarrow m + \delta m$ e integrando por partes,

$$\delta R = - \int \nabla \cdot \left[\frac{\partial G}{\partial (\nabla m)} \right] \delta m \, d\mathbf{x} \quad \implies \quad \nabla R = - \nabla \cdot \left[\frac{\partial G}{\partial (\nabla m)} \right].$$

As duas fórmulas de gradiente da próxima seção são casos particulares desta, com $G =$

$$\frac{1}{2}|\nabla m|^2 \text{ e } G = |\nabla m|.$$

10.1 Por que regularizar

A FWI é mal posta em dois sentidos. **Espaço nulo:** existem perturbações que praticamente não mudam os dados — regiões não iluminadas, estruturas menores que $\lambda/2$, combinações de parâmetros que se cancelam. **Amplificação de ruído:** nas direções de baixa sensibilidade, um resíduo pequeno exige perturbação grande do modelo.

$$J_{\text{total}}(\mathbf{m}) = J_{\text{dados}}(\mathbf{m}) + \lambda R(\mathbf{m}), \quad \nabla J_{\text{total}} = \nabla J_{\text{dados}} + \lambda \nabla R. \quad (10.1)$$

Uma distinção que evita confusão

Regularização **não** existe para melhorar o ajuste dos dados: comparando os minimizadores *globais* com e sem ela, por construção, J_{dados} só pode ficar igual ou *pior*. O que ela faz é escolher, entre os muitos modelos que ajustam os dados igualmente bem, aquele mais plausível segundo um critério que *você* definiu.

(Num problema não convexo, com otimização local, a comparação prática pode sair ao contrário: partindo do mesmo inicial, a regularização pode desviar a trajetória de um mínimo local e terminar com ajuste melhor — Esser *et al.* (2018) usam restrições de TV exatamente com esse fim. É efeito de trajetória, não de ajuste no ótimo.)

Isso significa que a escolha de R é uma afirmação sobre a geologia, e precisa ser justificada como tal.

10.2 Tikhonov *versus* Variação Total

$$R_{\text{Tik}}(\mathbf{m}) = \frac{1}{2} \int_{\Omega} |\nabla m|^2 \, d\mathbf{x}, \quad \nabla R_{\text{Tik}} = -\nabla^2 m, \quad (10.2)$$

$$R_{\text{TV}}(\mathbf{m}) = \int_{\Omega} |\nabla m| \, d\mathbf{x} \approx \int_{\Omega} \sqrt{|\nabla m|^2 + \varepsilon^2} \, d\mathbf{x}, \quad \nabla R_{\text{TV}} = -\nabla \cdot \left(\frac{\nabla m}{\sqrt{|\nabla m|^2 + \varepsilon^2}} \right). \quad (10.3)$$

O ε em (10.3) existe porque $|\nabla m|$ não é diferenciável onde o gradiente se anula — ou seja, em toda região homogênea, que é a maior parte do modelo. Escolha $\varepsilon \sim 10^{-2}$ do contraste típico de m : grande demais e a TV vira Tikhonov, pequeno demais e o gradiente fica instável.

Por que L_1 preserva interfaces e L_2 não

Compare o custo de acomodar uma variação total de 1:

	L_2 (Tikhonov)	L_1 (TV)
Um salto de 1 em um ponto	1,00	1,00
A mesma variação em 10 passos de 0,1	0,10	1,00

A L_2 é *barata* para muitas variações pequenas e cara para um salto grande: por isso ela **suaviza**, borrando interfaces. A L_1 cobra o mesmo nos dois casos: por isso tolera saltos nítidos enquanto ainda pune oscilação de ruído.

Escolha: alvo estratificado com contatos nítidos pede TV; variação gradual pede Tikhonov.

Versão anisotrópica

Frequentemente se quer penalizar mais a variação em uma direção que na outra — típico em meio estratificado, onde a estrutura é horizontal:

$$R = \frac{1}{2} \int \left[a_x (\partial_x m)^2 + a_z (\partial_z m)^2 \right] dx, \quad \nabla R = -(a_x \partial_{xx} + a_z \partial_{zz}) m. \quad (10.4)$$

Peso **maior** em a_z penaliza mais a variação *vertical* e produz um modelo mais suave na vertical. É fácil inverter os dois na implementação e obter exatamente o oposto do pretendido; verifique com um modelo de teste que tenha estrutura só em uma direção.

10.3 Um resultado que contraria a expectativa

O experimento do curso usa dado com relação sinal/ruído de **0 dB** (ruído com a mesma energia do sinal), 3 tiros e 18 iterações:

Variante	Erro final	Correlação
modelo inicial	4,75%	0,9554
gradiente cru, sem regularização	3,60%	0,9699
gradiente cru + Tikhonov	4,42%	0,9595
gradiente cru + TV	4,39%	0,9613
só suavização do gradiente	3,56%	0,9709

Por que a regularização explícita perdeu aqui

O modelo inicial já é suave, e com 18 iterações a inversão não tem tempo de gerar estrutura de alta frequência. O erro que sobra **não é rugosidade**: é falta de *contraste* — os degraus de velocidade ainda não foram recuperados em amplitude.

Tikhonov e TV penalizam exatamente o gradiente espacial, ou seja, penalizam o contraste que ainda falta construir. Estão puxando na direção errada *para este problema*.

E note a última linha: apenas suavizando o gradiente, sem termo algum no funcional, chega-se ao melhor resultado da tabela. Uma operação de uma linha.

Regularização implícita

Existe muita regularização em FWI que raramente é reconhecida como tal:

- suavização do gradiente a cada iteração;
- modelo inicial suave — ele já restringe onde a solução pode chegar;
- estratégia multiescala — as bandas baixas impõem suavidade;
- parada antecipada — poucas iterações não produzem alta frequência;
- projeção em caixa.

Somar regularização explícita a tudo isso frequentemente **sobre-regulariza**. O sintoma é o da tabela: o modelo fica mais suave e o erro *aumenta*.

A conclusão não é “não use regularização”, e sim: **diagnostique antes de escolher R** . Se o erro residual é rugosidade, Tikhonov e TV ajudam; se é falta de contraste ou resolução, atrapalham.

10.4 Escolhendo λ

Calibre λ de modo que λR valha uma fração conhecida de J_{dados} no ponto inicial (2%, por exemplo):

$$\lambda = \eta \frac{J_{\text{dados}}(\mathbf{m}_0)}{R(\mathbf{m}_0)}, \quad \eta \approx 0,02. \quad (10.5)$$

Isso torna a escolha independente de unidades e reproduzível — muito melhor que testar potências de 10 às cegas.

Depois refine pela **curva em L**: para vários λ , ponha J_{dados} em x e R em y , ambos em log. A curva tem forma de L, e o λ bom fica no *cotovelo* — o ponto de maior curvatura, onde se deixa de comprar suavidade barata e se começa a pagar com ajuste.




Figura 10.1: Curva em L medida pelo código do curso (J_{dados} no eixo horizontal, R no vertical; os rótulos são λ/λ_0). O cotovelo é o compromisso: no ramo vertical, à esquerda (λ pequeno), R cresce sem ganho de ajuste — ruído entrando no modelo; no ramo horizontal, à direita (λ grande), sobre-regularização, com ajuste sacrificado.

Uma exigência de honestidade

Em problema *sintético* você conhece o modelo verdadeiro e poderia escolher λ pelo menor erro de modelo. Em dado **real** isso é impossível — você só tem J_{dados} e R . É para isso que existe a curva em L.

Se reportar resultados escolhendo λ pelo erro de modelo, diga isso explicitamente. Caso contrário o resultado parece melhor do que seria na prática.

10.5 Modelo a priori e vínculos

$$R_{\text{priori}}(\mathbf{m}) = \frac{1}{2} \|W(\mathbf{m} - \mathbf{m}_{\text{priori}})\|^2, \quad \nabla R_{\text{priori}} = W^T W(\mathbf{m} - \mathbf{m}_{\text{priori}}). \quad (10.6)$$

A matriz W diz *onde* você confia no modelo a priori. Uso clássico: peso alto ao longo de um poço, onde há perfil sônico medido, e zero longe dele.

Vínculo	Como	Quando
Caixa ($v_{\min}, v_{\max}$)	clip após cada passo	sempre
Água fixa	zerar o gradiente na lâmina d'água	dado marinho
Máscara de profundidade	zerar abaixo da penetração	evita artefato
Modelo a priori	$R = \ W(\mathbf{m} - \mathbf{m}_p)\ ^2$	há poço/tomografia
Relação entre parâmetros	vincular v_s, ρ a v_p	multiparâmetro

Onde clicar — e é mais cedo do que se pensa

Clipe *também dentro* da avaliação de J , e não apenas após a atualização. A busca linear avalia $J(\mathbf{m} + \alpha \mathbf{d})$ **antes** de a projeção ser aplicada, e um passo exagerado pode violar a CFL e estourar a simulação ali. O curso encontrou esse *overflow* exatamente assim.

Exercícios

1. Derive $\nabla R_{\text{Tik}} = -\nabla^2 m$ a partir de (10.2).
2. Por que a TV precisa de ε , e o que acontece se ε for grande demais?
3. O seu resíduo final é dominado por oscilação de curto comprimento de onda no modelo. Tikhonov, TV, ou nenhum dos dois?

Respostas. (1) $\delta R = \int \nabla m \cdot \nabla \delta m = -\int (\nabla^2 m) \delta m$ após integrar por partes (termo de fronteira nulo com condições homogêneas), logo $\nabla R = -\nabla^2 m$. (2) Porque $|\nabla m|$ não é diferenciável em $\nabla m = 0$, que é a situação de toda região homogênea; com $\varepsilon \gg |\nabla m|$, $\sqrt{|\nabla m|^2 + \varepsilon^2} \approx \varepsilon + |\nabla m|^2/(2\varepsilon)$ — a menos de uma constante, Tikhonov com peso $1/\varepsilon$ — e a TV degenera em Tikhonov. (3) Qualquer um dos dois ajuda — este é o caso em que a regularização é apropriada. TV se você quiser preservar interfaces reais no meio da oscilação.

Parte III — Os limites

Capítulo 11

Os limites da física adotada

A ideia deste capítulo, em uma frase

Toda a Parte I adotou uma física simplificada. Este capítulo apresenta a fatura: quanto cada hipótese custa, como o custo aparece no resultado, e como decidir se vale a pena pagar por física melhor.

11.1 O inventário de hipóteses

Hipótese	Onde entrou	Quando quebra
$\mu = 0$	Cap. 2	terrestre, contrastes de v_s
densidade constante	Cap. 2	contrastos de impedância
sem atenuação ($Q \rightarrow \infty$)	Cap. 2	meio dissipativo, banda larga
isotropia	Cap. 2	folhelhos, fraturas
2D	volume inteiro	estrutura fora do plano
fonte conhecida	Cap. 9	dado real: a ondaleta é estimada
ruído gaussiano branco	Cap. 5	ruído coerente, múltiplas

O princípio que vale mais que a tabela

O que a FWI não consegue explicar pela física, ela explica mexendo no modelo. Não existe válvula de escape. Se o dado contém um efeito que o operador não reproduz, esse efeito entra inteiro no resíduo, e o gradiente o converte em estrutura de velocidade. O modelo final absorve o erro de física — e parece um modelo, não um erro.

11.2 Limite 1: densidade e a ambiguidade da impedância

O que controla a reflexão não é a velocidade, é a **impedância** $Z = \rho c$. Em incidência normal,

$$R = \frac{Z_2 - Z_1}{Z_2 + Z_1} = \frac{\rho_2 c_2 - \rho_1 c_1}{\rho_2 c_2 + \rho_1 c_1}. \quad (11.1)$$

Meio 1	Meio 2	R
$c = 2000, \rho = 2,00$	$c = 2400, \rho = 2,00$	+0,0909
$c = 2000, \rho = 2,00$	$c = 2000, \rho = 2,40$	+0,0909
$c = 2000, \rho = 2,00$	$c = 2400, \rho = 1,67$	+0,0010

As duas primeiras linhas produzem *exatamente* a mesma reflexão por causas diferentes. A terceira é pior: velocidade 20% maior com densidade 17% menor dá reflexão praticamente **nula** em incidência normal — nas reflexões de afastamento curto, a interface não aparece. Ela só é vista pela cinemática das ondas que a atravessam, ou pela variação de R com o ângulo, que exige afastamento.

É o exemplo mais limpo de ambiguidade velocidade–densidade, e a raiz do *crosstalk* em inversão multiparâmetro.

► *Nível 3, §2.3 e Cap. 11* — o tratamento quantitativo disso: padrões de radiação, que mostram *em quais ângulos* cada parâmetro imprime a sua assinatura — e portanto que aquisição os separa.

11.3 Limite 2: elasticidade

Medido no Capítulo 2: a diferença entre o sismograma elástico e o acústico tem norma **comparável à do próprio dado**. São ondas S e conversões P–S. Essa energia não some do dado real: ou você a modela, ou a remove no processamento, ou ela vai para o resíduo.

Extensão	Parâmetros	Custo	Resolve
Acústica	v_p	1×	cinemática P
Acústica + ρ	v_p, ρ	1×	amplitude de reflexão
Viscoacústica	v_p, Q	2–4×	dissipação e dispersão
Elástica	v_p, v_s, ρ	3–5×	ondas S, conversões, AVO
Viscoelástica	+ Q_p, Q_s	6–10×	tudo acima
Anisotrópica (VTI)	+ ϵ, δ	2–3×	folhelhos

Os fatores de custo são na mesma malha

A malha é dimensionada pela *menor* velocidade (receita do Cap. 3), e na elástica ela é v_s . Como o custo 2D escala com Δh^{-3} e o 3D com Δh^{-4} , a razão v_p/v_s entra *além* do fator da tabela: com $v_p/v_s = 2$, mais 8× em 2D e 16× em 3D. Em sedimento raso e mole, com v_s muito baixo, a diferença chega a ordens de grandeza.

11.4 Limite 3: atenuação e o fator Q

Antes de usar: causalidade, e por que ela amarra amplitude a fase

Este é o ponto conceitual mais importante do capítulo, e vale prepará-lo antes de qualquer fórmula.

Resposta em frequência. Um meio linear age sobre uma onda multiplicando cada componente de frequência por um número complexo: o módulo muda a *amplitude*, o argumento muda a *fase*. Atenuar é reduzir o módulo; atrasar é girar o argumento.

Causalidade. Nenhum sinal pode chegar antes de ser emitido. Isso parece óbvio e tem uma consequência matemática forte: se a resposta é causal, a sua transformada é analítica num semiplano complexo de frequência (o inferior, com a convenção de Fourier deste volume; o superior, com a convenção oposta $e^{+i\omega t}$, comum em física), e as partes real e imaginária deixam de ser independentes — ficam ligadas pelas relações de **Kramers–Kronig**, que expressam uma como integral da outra.

O que isso significa em português. Você *não pode* projetar um meio que absorva energia de forma dependente da frequência e não mude a velocidade de fase. As duas coisas são a mesma coisa vista de dois ângulos. Dissipação e dispersão vêm sempre juntas.

Lei de potência. Adiante aparece $c(\omega) \propto \omega^\gamma$ com γ minúsculo ($\sim 10^{-3}$). Uma potência com expoente tão pequeno é quase uma constante — e é justamente por isso que o efeito passa despercebido em modelagem, e reaparece como erro de tempo de trânsito acumulado em percursos longos.

O fator de qualidade Q é, aproximadamente, o número de ciclos que uma onda percorre antes de a amplitude cair por $e^{-\pi}$. Valores típicos: água > 1000 ; rocha consolidada 100–300; sedimento não consolidado 20–50; sedimento raso saturado ou com gás 10–30.

Dissipação e dispersão são inseparáveis

Consequência prática da caixa acima: **não adianta “corrigir a amplitude” de um dado atenuado e continuar usando uma equação sem perdas.** Ao atenuar, o meio também mudou a *fase* — e a FWI é um método governado por fase. Um operador sem dissipação está errado nas duas contas ao mesmo tempo.

O modelo constant- Q de Kjartansson

Entre as representações da dissipação, a de Kjartansson (1979) é a mais usada quando se quer Q aproximadamente constante na banda sísmica. Ela parte de uma lei constitutiva de potência, e o expoente se relaciona a Q por

$$\gamma = \frac{1}{\pi} \arctan\left(\frac{1}{Q}\right), \quad (11.2)$$

com velocidade de fase e amplitude dadas por

$$c(\omega) = c_0 \left(\frac{\omega}{\omega_{\text{ref}}}\right)^\gamma, \quad A(\omega) = \exp\left[-\frac{\omega L}{2Q c(\omega)}\right]. \quad (11.3)$$

Precisão da forma usada

O fator de atenuação em (11.3) usa $1/(2Q)$, válido para $Q \gg 1$. A forma exata de Kjartansson traz $\tan(\pi\gamma/2)$ no lugar. A diferença medida é de 0,25% em $Q = 10$ e 0,06% em $Q = 20$ — irrelevante na faixa sísmica, mas vale saber que a expressão é uma aproximação.

No domínio do tempo, essa dependência de potência conduz a operadores de ordem **fracionária** — por isso a implementação viscoacústica é substancialmente mais trabalhosa que a acústica, e costuma ser feita com laplacianos fracionários ou com uma soma de mecanismos de relaxação (modelo SLS).

O que Q faz com um pulso

Aplicando (11.3) a uma Ricker de $f_0 = 20$ Hz, $c_0 = 2000$ m/s, $L = 1500$ m (frequência de pico do espectro contínuo; a FFT da aula 14, com resolução de 0,24 Hz, arredonda o caso $Q = 200$ para 18,8 Hz):

Q	γ	amplitude rel.	f de pico (Hz)
10 000	$3,2 \times 10^{-5}$	1,0000	20,0
200	$1,59 \times 10^{-3}$	0,7738	18,9
100	$3,18 \times 10^{-3}$	0,6008	17,8
50	$6,37 \times 10^{-3}$	0,3713	15,9
20	$1,59 \times 10^{-2}$	0,1056	11,5




Figura 11.1: Efeito do modelo constant- Q : pulso no tempo, espectro e dispersão da velocidade de fase. Três efeitos simultâneos, nenhum presente na equação acústica.

Quando ignorar Q provoca *cycle skipping*

Aqui as peças do volume se encaixam. Modelando com c_0 constante mas tendo dado de um meio dispersivo, o erro de tempo de trânsito é

$$\delta t(f) = \frac{L}{c_0} - \frac{L}{c(f)} = \frac{L}{c_0} \left[1 - \left(\frac{f}{f_{\text{ref}}} \right)^{-\gamma} \right], \quad (11.4)$$

e o critério de meio ciclo (5.4) decide se isso importa:

Q	L (m)	f (Hz)	$ \delta t $ (ms)	$T/2$ (ms)	
100	1000	10	1,10	50,0	ok
100	6000	60	10,47	8,3	cycle skipping
50	6000	60	20,91	8,3	cycle skipping
20	1000	60	8,66	8,3	cycle skipping
20	6000	10	33,25	50,0	ok
10	6000	10	66,70	50,0	cycle skipping
10	6000	60	102,76	8,3	cycle skipping

($c_0 = 2000$ m/s, $f_{\text{ref}} = 20$ Hz)

O padrão é claro: o risco cresce com percurso *longo*, frequência *alta* e Q *baixo*, os três juntos. Com $Q = 200$ e percursos curtos, a aproximação sem perdas é perfeitamente defensável.

O que a tabela não cobre

Ela contabiliza apenas o erro de *fase* por dispersão. O erro de *amplitude* por dissipação é adicional, e afeta diretamente qualquer funcional que compare amplitudes — como o L_2 usado no volume inteiro.

O adjunto de um meio dissipativo**Duas coisas que costumam ser confundidas**

A equação acústica sem perdas é auto-adjunta, e por isso o mesmo propagador serve para o direto e para o adjunto. Com atenuação isso muda, e é preciso separar dois enunciados:

(1) A propagação adjunta é estável. O operador viscoacústico contém uma derivada *primeira* no tempo, e $\partial_t^* = -\partial_t$. Quando o problema adjunto é escrito na variável de tempo revertida $\tau = T - t$, essa troca de sinal se cancela com a inversão do sentido do tempo: o campo adjunto obedece a uma equação *dissipativa* em τ , e integra-se sem problema.

(2) Reconstruir o campo direto de trás para frente é que explode. A técnica de economia de memória que recupera o campo direto propagando-o ao contrário a partir do estado final exige rodar a dissipação *ao contrário* — isto é, amplificar. Isso amplifica também o erro de arredondamento, exponencialmente.

Conclusão prática: em meio atenuante, use *checkpointing* para o campo direto. Não é o adjunto que é instável; é a reconstrução do direto.

11.5 Como decidir qual física você precisa

A decisão se faz olhando para o dado e para o **resíduo**, não por gosto nem por disponibilidade de código.

1. **Olhe o resíduo**, não só o valor de J . Resíduo com estrutura *coerente* é a assinatura de física faltando. Resíduo que parece ruído aleatório significa que você chegou ao limite do dado.
2. **Compare espectros** de observado e sintético em função do afastamento. Se o sintético mantém alta frequência que o dado real já perdeu em afastamentos longos, há atenuação não modelada.
3. **Verifique amplitude $\times$ afastamento**. Decaimento mais rápido no dado real aponta dissipação ou espalhamento.
4. **Procure eventos ausentes**. Energia no dado real em tempos onde o sintético acústico não produz nada: ondas S, conversões ou múltiplas.
5. **Teste a sensibilidade**. Gere dado sintético com a física mais completa e inverta com a mais simples. O erro de modelo resultante é a medida direta do custo da aproximação — e o experimento mais informativo que existe para justificar (ou dispensar) uma extensão.

O caminho inverso também tem custo

Adicionar física sem necessidade traz mais parâmetros, mais *crosstalk*, mais mínimos locais, mais tempo de máquina e mais dificuldade em atribuir um resultado a uma causa.

Uma FWI acústica bem feita, com bom modelo inicial e multiescala honesta, costuma render mais que uma viscoelástica mal condicionada. A pergunta certa não é “qual a física mais

completa?”, e sim “**qual é a física mais simples que explica o meu dado?**”

Capítulo 12

Diagnóstico

A ideia deste capítulo, em uma frase

FWI quase nunca falha com uma mensagem de erro: falha produzindo um resultado bonito. Este capítulo é a lista de sintomas, a causa de cada um, e a ordem em que investigar.

12.1 A FWI não converge (J não cai)

1. O gradiente está correto? Rode o teste de Taylor (Cap. 7). **Antes de qualquer outra coisa.**
2. A busca linear está retornando $\alpha = 0$? A direção não é de descida — verifique $\langle \mathbf{g}, \mathbf{d} \rangle < 0$.
3. O sinal do gradiente está certo? Compare $-\mathbf{g}$ com uma perturbação conhecida, e confira em qual parâmetro ele está escrito (Eq. 2.9).
4. O passo inicial é razoável? Deve alterar o modelo em 1–3%.

12.2 J cai mas o modelo está errado

1. **Cycle skipping.** Recomece de uma frequência mais baixa. Se o resultado mudar, era isso.
2. Modelo inicial fora do vale de atração — verifique com (5.5).
3. Física faltando: o resíduo final tem estrutura coerente?
4. Bordas: artefatos de reflexão entrando no resíduo.
5. Ondaleta da fonte mal estimada: ela absorve erro de modelo e trava o progresso.

12.3 Só a parte rasa é atualizada

1. Falta máscara na faixa de fonte/receptor.
2. Falta compensação de iluminação (Cap. 8).
3. Afastamento insuficiente para a profundidade desejada — e isso nenhum ajuste de algoritmo resolve.

12.4 O campo estoura (NaN)

1. CFL: $c_{\max}\Delta t/\Delta h$ acima do limite (3.5).
2. O modelo saiu da caixa física durante a busca linear — clipe *também dentro* da avaliação de J .

12.5 Cauda oscilatória onde não deveria haver evento

1. Dispersão numérica: G insuficiente. Reduza Δh , aumente a ordem espacial, ou baixe f_0 .
2. Se G já está alto e o problema persiste: **é o Δt** — reduza C (veja a caixa da §3.3).
3. Confirme sempre com uma simulação em meio homogêneo.

12.6 As cinco perguntas antes de acreditar num resultado

1. **Qual era o erro do modelo inicial?** Sem isso, o erro final não significa nada.
2. **O gradiente foi verificado?** Se não, nada mais na lista importa.
3. **O resíduo final parece ruído ou tem estrutura?** Estrutura coerente indica física faltando, não convergência.
4. **O resultado muda se eu começar de uma frequência mais baixa?** Se muda, o primeiro resultado estava num mínimo local.
5. **O resultado muda se eu começar de outro modelo inicial?** Se muda muito, quem está determinando a resposta é o modelo inicial, não o dado.

Capítulo A

Notação

Símbolo	Significado
$\mathbf{m}$	vetor de parâmetros do modelo
$m = 1/c^2$	vagarosidade ao quadrado (parâmetro de inversão)
c, v_p	velocidade de onda P (m/s)
v_s	velocidade de onda S (m/s)
ρ	densidade
λ, μ	parâmetros de Lamé (μ = módulo de cisalhamento)
K	módulo de compressibilidade
p	pressão
σ_{ij}	tensor de tensões
F	operador de modelagem direta
J'	jacobiana $\partial \mathbf{r} / \partial \mathbf{m}$ (matriz de sensibilidade)
J	funcional objetivo
$\mathbf{r}$	vetor residual
$\mathbf{g}$	gradiente
H, H_{GN}	Hessiana e sua aproximação de Gauss–Newton
$\lambda(\mathbf{x}, t)$	campo adjunto (multiplicador de Lagrange)
α	comprimento do passo
$\Delta h, \Delta t$	espaçamento da malha e passo de tempo
C, C_{lim}	número de Courant e seu limite
G	pontos por comprimento de onda
$S(\theta)$	símbolo do estêncil espacial
f_0	frequência de pico da fonte
Q	fator de qualidade
γ	expoente de Kjartansson
E	operador de extensão do modelo para a moldura

Três colisões de símbolo, herdadas da literatura

λ é parâmetro de Lamé (Cap. 2), campo adjunto (Cap. 6), peso de regularização (Cap. 10) e comprimento de onda. J é o funcional e J' a jacobiana do *resíduo*, não a derivada de J . μ é módulo de cisalhamento. O contexto resolve, mas vale saber que a colisão é da área, não deste texto.

Capítulo B

Fórmulas de bolso

Para	Use
Banda da fonte	$f_{\max} \approx 2,5f_0$ (malha); $f \approx 1,6f_0$ (resolução)
Resolução	$\delta_{\min} \approx \lambda/2 = c/2f$
Penetração	$z_{\max} \approx x_{\text{off}}^{\max}/6$ a $x_{\text{off}}^{\max}/3$
Malha	$\Delta h = c_{\min}/(Gf_{\max})$, $G = 8$ (O4) ou 5 (O8)
Passo de tempo	$\Delta t = 0,9 C_{\text{lim}} \Delta h / c_{\max}$; $C_{\text{lim}} = 0,61$ (O4), $0,55$ (O8) em 2D
Moldura	$n_{\text{abs}} \geq 0,5 c_{\max} / (f_{\min} \Delta h)$
Amostragem de receptores	$\Delta x_{\text{rec}} < c_{\text{ap}} / 2f_{\max}$
Tolerância do modelo inicial	$ \delta c < c^2 / (2fL)$
Gradiente	$\partial J / \partial m = \int_0^T \lambda \partial_{tt} p \, dt$, discreto com peso $\Delta h^2 \Delta t$
Conversão de parâmetro	$\partial J / \partial c = (-2/c^3) \partial J / \partial m$
Passo inicial	$\alpha_0 = 0,02 \max \mathbf{m} / \max \mathbf{d} $
Peso de regularização	$\lambda = 0,02 J_{\text{dados}}(\mathbf{m}_0) / R(\mathbf{m}_0)$, refinado pela curva em L
Custo total	$n_{\text{iter}} n_{\text{bandas}} n_{\text{tiros}} \cdot (2 + n_{\text{busca}})$ modelagens
Kjartansson	$\gamma = \arctan(1/Q)/\pi$; $c(\omega) = c_0(\omega/\omega_{\text{ref}})^\gamma$

Capítulo C

Referências

1. ASNAASHARI, A.; BROSSIER, R.; GARAMBOIS, S.; AUDEBERT, F.; THORE, P.; VIRIEUX, J. *Regularized seismic full waveform inversion with prior model information*. Geophysics, v. 78, n. 2, p. R25–R36, 2013.
2. BUNKS, C.; SALECK, F. M.; ZALESKI, S.; CHAVENT, G. *Multiscale seismic waveform inversion*. Geophysics, v. 60, n. 5, p. 1457–1473, 1995.
3. CARCIONE, J. M. *Wave Fields in Real Media*. 4. ed. Elsevier, 2022.
4. CERJAN, C.; KOSLOFF, D.; KOSLOFF, R.; RESHEF, M. *A nonreflecting boundary condition for discrete acoustic and elastic wave equations*. Geophysics, v. 50, n. 4, p. 705–708, 1985.
5. ESSER, E.; GUASCH, L.; VAN LEEUWEN, T.; ARAVKIN, A. Y.; HERRMANN, F. J. *Total variation regularization strategies in full-waveform inversion*. SIAM Journal on Imaging Sciences, v. 11, n. 1, p. 376–406, 2018.
6. KJARTANSSON, E. *Constant-Q wave propagation and attenuation*. Journal of Geophysical Research, v. 84, p. 4737–4748, 1979.
7. KREBS, J. R. *et al.* *Fast full-wavefield seismic inversion using encoded sources*. Geophysics, v. 74, n. 6, p. WCC177–WCC188, 2009.
8. MARDAN, A.; GIROUX, B.; FABIEN-OUELLET, G. *PyFWI: A Python package for full-waveform inversion and reservoir monitoring*. SoftwareX, v. 22, art. 101384, 2023.
9. MORGAN, J. *et al.* *Next-generation seismic experiments: wide-angle, multi-azimuth, three-dimensional, full-waveform inversion*. Geophysical Journal International, v. 195, n. 3, p. 1657–1678, 2013.
10. NOCEDAL, J.; WRIGHT, S. J. *Numerical Optimization*. 2. ed. Springer, 2006.
11. PLESSIX, R.-E. *A review of the adjoint-state method for computing the gradient of a functional with geophysical applications*. Geophysical Journal International, v. 167, n. 2, p. 495–503, 2006.
12. SHIN, C.; JANG, S.; MIN, D.-J. *Improved amplitude preservation for prestack depth migration by inverse scattering theory*. Geophysical Prospecting, v. 49, n. 5, p. 592–606, 2001.
13. TARANTOLA, A. *Inversion of seismic reflection data in the acoustic approximation*. Geophysics, v. 49, n. 8, p. 1259–1266, 1984.
14. VIRIEUX, J.; OPERTO, S. *An overview of full-waveform inversion in exploration geophysics*. Geophysics, v. 74, n. 6, p. WCC1–WCC26, 2009.

15. VIRIEUX, J.; ASNAASHARI, A.; BROSSIER, R.; MÉTIVIER, L.; RIBODETTI, A.; ZHOU, W. *An introduction to full waveform inversion*. In: *Encyclopedia of Exploration Geophysics*. Tulsa: Society of Exploration Geophysicists, 2014. p. R1-1–R1-40. DOI 10.1190/1.9781560803027.entry6.