

Full-Waveform Inversion

A teoria completa, em três níveis

Volume 3 — Avançado

Por que funciona, quando falha,
e o que ainda não se sabe



*“O que a FWI não consegue explicar pela física,
ela explica mexendo no modelo.”*

12 capítulos · mesma espinha dorsal dos três volumes

16 de setembro de 2026

Sumário

Como usar este volume	4
Parte I — O problema direto	7
1 FWI como problema inverso não linear	7
1.1 Formulação	8
1.2 Mal posto, em sentido preciso	8
1.3 Cobertura de número de onda: o que é recuperável, e por quê	9
1.4 As três dificuldades, reenunciadas	11
2 Física, parametrização e o limite acústico	13
2.1 A hierarquia	14
2.2 Parametrização: a decisão que a literatura subestima	14
2.3 Padrões de radiação: a dedução	15
2.4 A fonte como incógnita	16
3 Análise numérica do problema direto	18
3.1 Estênceis: Taylor <i>versus</i> otimização de banda	18
3.2 Estabilidade e dispersão, na forma completa	19
3.3 Energia discreta e conservação	20
3.4 Adjunto discreto <i>versus</i> adjunto contínuo	20
4 Domínio truncado e aquisição	22
4.1 PML clássica, e por que ela falha em incidência rasante	22
4.2 O adjunto de uma camada absorvente	23
4.3 Superfície livre	24
4.4 Aquisição como amostragem do espaço de números de onda	24

Parte II — O problema inverso	27
5 Geometria do funcional e funcionais alternativos	27
5.1 O L_2 e o critério de meio ciclo	28
5.2 Funcionais alternativos e suas fontes adjuntas	28
5.3 Domínio estendido: mudar o espaço em vez do funcional	30
6 Estado adjunto, Born e núcleos de sensibilidade	32
6.1 O operador de Born, explicitamente	33
6.2 A dedução pelo Lagrangiano, com os termos de fronteira	33
6.3 Núcleos de sensibilidade	34
6.4 Decomposição do gradiente: tomográfico e de migração	35
6.5 Gradiente multiparâmetro	36
6.6 Adjunto do programa e <i>checkpointing</i>	36
7 Verificação	39
7.1 Os quatro testes, e o que cada um pega	39
7.2 Os números de um caso real	40
8 Otimização de segunda ordem e a Hessiana	42
8.1 Estrutura da Hessiana	42
8.2 Produto Hessiana-vetor pelo adjunto de segunda ordem	43
8.3 Função de espalhamento de ponto e resolução	43
8.4 Pré-condicionamento, revisitado	44
8.5 Otimização estocástica e codificação de fontes	44
9 Fluxo completo, escalabilidade e reprodutibilidade	46
9.1 Domínio do tempo <i>versus</i> domínio da frequência	47
9.2 O fluxo, e a ordem que não muda	47
9.3 Resultados medidos, e o fracasso que não parece fracasso	48
9.4 Reprodutibilidade	48
10 Regularização, priors e inferência	50
10.1 Tradução: regularizador $\leftrightarrow$ prior	51
10.2 A curva em L, e o resultado que contraria a expectativa	51
10.3 O que é honesto dizer sobre incerteza em FWI	52

Parte III — Os limites	55
11 Multiparâmetro, atenuação e anisotropia	55
11.1 <i>Crosstalk</i> , definido com precisão	55
11.2 Extensões da física: o que cada uma custa	56
11.3 O adjunto viscoacústico	57
11.4 O princípio que organiza o capítulo	58
12 Diagnóstico e o que ainda não se sabe	60
12.1 A hierarquia de diagnósticos	60
12.2 Sintomas e causas	61
12.3 O que se sabe que não se sabe	61
A Notação	63
B Identidades usadas	64
C Referências	65

Como usar este volume

Esta coleção conta a mesma história três vezes, com profundidade crescente. Os doze capítulos são os mesmos nos três volumes, na mesma ordem, tratando dos mesmos tópicos. O que cresce é a complexidade e a completude, nunca o escopo.

Volume	Nível	O que faz
1	Introdutório	As ideias, as figuras e as conclusões, sem dedução.
2	Intermediário	Todas as deduções clássicas, os algoritmos e as contas de dimensionamento.
3	Avançado	Este volume. Formulação em espaços de funções, teoria de espalhamento, cobertura de número de onda, estrutura da Hessiana, inversão multiparâmetro, funcionais alternativos com suas fontes adjuntas, e inferência.

Para quem é, e o que pressupõe

Para quem vai *pesquisar* FWI, avaliar criticamente a literatura, ou implementar métodos de segunda ordem e multiparâmetro.

Pré-requisitos: análise real e complexa, EDPs, análise funcional básica (espaços de Hilbert, operadores lineares limitados), otimização numérica, e probabilidade. Cada ferramenta usada aparece apresentada numa caixa *Antes de usar* antes da sua primeira aplicação — não para substituir um curso, mas para fixar notação e destacar exatamente a propriedade que será explorada.

O que este volume acrescenta, capítulo a capítulo

Cap. O salto em relação ao Volume 2

- 1 F como aplicação entre espaços de Hilbert; derivada de Fréchet; o que “mal posto” significa formalmente
- 2 O limite acústico como perturbação *singular*; reparametrização e o seu efeito sobre o condicionamento
- 3 Teorema de equivalência de Lax; símbolo do operador; coeficientes otimizados; anisotropia numérica
- 4 Dedução da PML por estiramento complexo de coordenada; o adjunto de uma PML
- 5 Geometria dos funcionais; fontes adjuntas de envoltória, correlação cruzada, AWI e transporte ótimo; domínio estendido
- 6 Aproximação de Born, integral de espalhamento, núcleos de sensibilidade, cobertura de número de onda, adjunto discreto
- 7 Teste do produto escalar; verificação multiparâmetro
- 8 Hessiana completa, adjunto de segunda ordem, Newton truncado, função de espalhamento de ponto
- 9 *Revolve*; domínio do tempo *versus* da frequência; codificação de fontes
- 10 Formulação bayesiana; MAP; covariância a posteriori pela Hessiana; o que é honesto dizer sobre incerteza
- 11 Padrões de radiação *deduzidos*; *crosstalk*; adjunto viscoacústico; anisotropia
- 12 Análise de resolução; o que se sabe que não se sabe

► *Nível 2, Cap. n* — a versão clássica e operacional do mesmo capítulo, com os algoritmos prontos para implementar.

► *Nível 1, Cap. n* — a mesma ideia sem matemática, útil para recuperar a intuição quando o formalismo a esconder.

Parte I — O problema direto

Capítulo 1

FWI como problema inverso não linear

A ideia deste capítulo, em uma frase

FWI é a minimização de um funcional de desajuste sobre um espaço de parâmetros de dimensão infinita, restrita por uma EDP hiperbólica. As três dificuldades práticas — custo, não convexidade, dimensão — são manifestações de três propriedades matemáticas distintas, e misturar as três é a origem de boa parte da confusão na literatura aplicada.

Antes de usar: espaços de Hilbert, operadores, e a noção de derivada em dimensão infinita

Espaço de Hilbert. Um espaço vetorial completo com produto interno. Os dois que interessam aqui:

$$\mathcal{M} \subset L^2(\Omega) \text{ (modelos),} \quad \mathcal{D} = L^2([0, T])^{n_s n_r} \text{ (dados).}$$

Completude garante que sequências de Cauchy convergem *dentro* do espaço — é o que legitima falar em limite de iterações. O produto interno é o que permite definir *adjunto*, e é por isso que a escolha de $\mathcal{M}$ e $\mathcal{D}$ não é decorativa: mudar o produto interno muda o gradiente.

Derivada de Gâteaux (direcional): se o limite

$$dF(m; \delta m) = \lim_{\epsilon \rightarrow 0} \frac{F(m + \epsilon \delta m) - F(m)}{\epsilon}$$

existe para toda direção δm , F é Gâteaux-diferenciável. É fraco demais para garantir as propriedades que queremos.

Derivada de Fréchet: existe um operador *linear limitado* $F'(m) : \mathcal{M} \rightarrow \mathcal{D}$ tal que

$$\|F(m + \delta m) - F(m) - F'(m) \delta m\|_{\mathcal{D}} = o(\|\delta m\|_{\mathcal{M}}). \quad (1.1)$$

Isto é a definição rigorosa de “linearizar”. O operador $F'(m)$ é o que a geofísica chama de **operador de Born**, e o seu adjunto $F'(m)^*$ é o que o método do estado adjunto calcula — Capítulo 6.

Por que a distinção importa aqui. O teste de Taylor do Capítulo 7 mede exatamente (1.1): a afirmação “ $E_1 = \mathcal{O}(\alpha^2)$ ” é a verificação empírica de que o resto é $o(\|\delta m\|)$ e de que o operador usado é de fato F' .

Adjunto de um operador não quadrado. Para $A : \mathcal{H}_1 \rightarrow \mathcal{H}_2$ linear limitado, A^* é o único operador com $\langle Au, v \rangle_{\mathcal{H}_2} = \langle u, A^*v \rangle_{\mathcal{H}_1}$. Em FWI, F' leva perturbações de modelo em

perturbações de dado (uma modelagem de Born), e F'^* leva resíduos de dado em “imagens” no modelo (uma migração). **Migração é o adjunto da modelagem linearizada** — e não a sua inversa. Toda a discussão sobre “inversão de mínimos quadrados da migração” nasce dessa distinção.

1.1 Formulação

Seja $\Omega \subset \mathbb{R}^d$ o domínio, $m \in \mathcal{M}$ o campo de parâmetros e u o campo de onda. O problema direto é o operador solução da EDP, seguido de amostragem:

$$\mathcal{A}(m)u = f, \quad F(m) = Ru = R\mathcal{A}(m)^{-1}f, \quad (1.2)$$

com R o operador de restrição aos receptores. A FWI resolve

$$\min_{m \in \mathcal{M}_{\text{adm}}} J(m) = \frac{1}{2} \|F(m) - d_{\text{obs}}\|_{\mathcal{D}}^2 + \lambda R_{\text{reg}}(m). \quad (1.3)$$

Duas formulações equivalentes, com consequências algorítmicas diferentes

Forma reduzida (a de (1.3)): elimina-se u resolvendo a EDP exatamente, e J é função apenas de m . Toda a Parte II desta coleção usa esta forma. Vantagem: o espaço de busca é pequeno (só m) e a restrição é satisfeita por construção. Desvantagem: a não convexidade fica concentrada em J .

Forma “tudo de uma vez” (*all-at-once*): trata-se (m, u) como incógnitas conjuntas, com $\mathcal{A}(m)u = f$ como restrição relaxada:

$$\min_{m, u} \frac{1}{2} \|Ru - d_{\text{obs}}\|^2 + \frac{\mu}{2} \|\mathcal{A}(m)u - f\|^2.$$

Vantagem: o espaço de busca é muito maior, e o caminho até o mínimo pode contornar barreiras que a forma reduzida não contorna — é a base da *Wavefield Reconstruction Inversion* (§5.3). Desvantagem: memória proibitiva em 3D, e μ vira mais um parâmetro livre.

A escolha entre as duas é uma das poucas decisões verdadeiramente estruturais em FWI.

1.2 Mal posto, em sentido preciso

Os três critérios de Hadamard, e como a FWI falha em cada um

Um problema é bem posto se a solução (i) existe, (ii) é única e (iii) depende continuamente do dado.

(i) **Existência.** Com dado ruidoso, em geral *não* existe m com $F(m) = d_{\text{obs}}$ exatamente: o dado não está na imagem de F . A formulação de mínimos quadrados (1.3) contorna isso pedindo proximidade em vez de igualdade — é a primeira regularização do método, e ela já está lá antes de qualquer R_{reg} .

(ii) **Unicidade.** Falha de duas maneiras distintas:

- **não unicidade estrutural:** $F'(m)$ tem núcleo não trivial. Há direções δm que não produzem dado nenhum — zonas de sombra, escalas fora da banda de número de onda coberta (§1.3), combinações de parâmetros que se cancelam (Cap. 11);
- **não unicidade por não convexidade:** vários mínimos locais de J , cada um com a sua

bacia. É o *cycle skipping* (Cap. 5).

Os dois são chamados de “mal posto” na literatura aplicada, e são fenômenos completamente diferentes: o primeiro é propriedade do *operador linearizado* e não melhora com melhor otimizador; o segundo é propriedade da *geometria de J* e não melhora com melhor regularização. **(iii) Continuidade.** $F'(m)$ é um operador compacto (na idealização contínua), com valores singulares que decaem a zero. A inversa de um operador compacto é não limitada: ruído em componentes de valor singular pequeno é amplificado sem limite. É o argumento formal por trás de toda a regularização do Capítulo 10.

A consequência prática mais ignorada

Como (ii) e (iii) têm causas diferentes, **têm remédios diferentes**, e trocar um pelo outro é o erro metodológico mais comum na literatura aplicada:

Sintoma	Causa	Remédio
modelo com estrutura implausível	espaço nulo / ruído amplificado	regularizar, restringir
modelo plausível e errado	mínimo local	baixar frequência, melhorar m_0 , trocar J

Regularizar mais *não* tira uma inversão de um mínimo local: apenas deixa o modelo errado mais suave.

1.3 Cobertura de número de onda: o que é recuperável, e por quê

O resultado desta seção é o de Wu & Toksöz (1987) em tomografia de difração, retomado por Sirgue & Pratt (2004) para FWI.

Esta seção é o resultado mais útil do volume, e cabe em uma figura. Ela responde, quantitativamente, à pergunta “quais escalas do modelo o meu experimento pode enxergar?”.

O número de onda do modelo amostrado por um par fonte–receptor

Considere um espalhador pontual em $\mathbf{x}$, iluminado por uma onda plana de vetor de onda $\mathbf{k}_i$ ($|\mathbf{k}_i| = \omega/c$) e observado na direção $\mathbf{k}_s$, com $|\mathbf{k}_s| = \omega/c$. Na aproximação de Born (Cap. 6), a contribuição ao dado é proporcional a

$$\int \delta m(\mathbf{x}) e^{i(\mathbf{k}_i - \mathbf{k}_s) \cdot \mathbf{x}} d\mathbf{x} = \widehat{\delta m}(\mathbf{k}_m), \quad \mathbf{k}_m = \mathbf{k}_s - \mathbf{k}_i.$$

Isto é: **cada par (fonte, receptor, frequência) mede uma única componente de Fourier do modelo.** Com θ o ângulo de espalhamento (entre $\mathbf{k}_i$ e $\mathbf{k}_s$),

$$|\mathbf{k}_m| = \frac{2\omega}{c} \sin \frac{\theta}{2} = \frac{4\pi f}{c} \sin \frac{\theta}{2} = \frac{4\pi}{\lambda} \sin \frac{\theta}{2} \quad (1.4)$$

Equivalentemente, em termos do ângulo de *abertura* ϑ entre os raios que vão do espalhador à fonte e ao receptor ($\vartheta = \pi - \theta$): $|\mathbf{k}_m| = (2\omega/c) \cos(\vartheta/2)$ — a forma que aparece na maior parte da literatura.

Duas convenções de “ângulo de espalhamento” na literatura

Este é o tropeço mais comum ao confrontar (1.4) com artigos, e vale fixá-lo antes de usar a fórmula.

Aqui, θ é o ângulo entre as *direções de propagação* incidente e espalhada — a convenção da física de espalhamento. Com ela, $\theta = \pi$ é retroespalhamento (reflexão em incidência quase normal, afastamento curto) e $\theta = 0$ é transmissão.

Boa parte da literatura de FWI chama de “ângulo de espalhamento” (ou de difração, ou de abertura) o ângulo $\vartheta = \pi - \theta$ — o ângulo entre o campo direto e o campo *adjunto* no ponto, ou equivalentemente entre os raios que vão do espalhador à fonte e ao receptor. Nessa convenção, ϑ *pequeno* é reflexão e ϑ *grande* é transmissão; as fórmulas aparecem com $\cos(\vartheta/2)$ no lugar de $\sin(\theta/2)$, e os fatores $(1 - \cos \cdot)$ e $(1 + \cos \cdot)$ trocam de lugar entre velocidade e impedância (§2.3).

Nenhuma das duas é errada, e as duas convivem na mesma literatura. **Como não errar:** não decore a fórmula — decore o fato físico. Reflexão dá número de onda *alto* e restringe *impedância*; transmissão dá número de onda *baixo* e restringe *velocidade*. Depois confira qual convenção reproduz isso.

As três consequências de (1.4)

1. Transmissão constrói o fundo; reflexão constrói as interfaces. Com $\theta \rightarrow 0$ (espalhamento para a frente: ondas mergulhantes, transmitidas, afastamento longo), $|\mathbf{k}_m| \rightarrow 0$ — essas ondas restringem os *grandes* comprimentos de onda do modelo. Com $\theta \rightarrow \pi$ (retroespalhamento: reflexão em incidência quase normal, afastamento curto), $|\mathbf{k}_m| \rightarrow 2\omega/c = 4\pi/\lambda$ — o máximo, correspondente a uma estrutura de meio comprimento de onda. Daí o limite de resolução $\lambda/2$: ele *sai* de (1.4), não é uma regra de bolso.


2. A lacuna espectral. Um experimento com banda $[f_{\min}, f_{\max}]$ e ângulos de espalhamento em $[\theta_{\min}, \theta_{\max}]$ cobre a coroa

$$\frac{4\pi f_{\min}}{c} \sin \frac{\theta_{\min}}{2} \leq |\mathbf{k}_m| \leq \frac{4\pi f_{\max}}{c} \sin \frac{\theta_{\max}}{2}.$$

Abaixo do limite inferior não há informação *nenhuma*: é o buraco que o modelo inicial tem de preencher. Essa é a formulação precisa da afirmação “a FWI não recupera os comprimentos de onda longos”.

3. Frequência baixa e afastamento longo são substitutos parciais. Em (1.4), f e $\sin(\theta/2)$ entram como *produto*. Baixar a frequência por um fator 2 tem, sobre o $|\mathbf{k}_m|$ acessível, o mesmo efeito que reduzir $\sin(\theta/2)$ pela metade — isto é, abrir a aquisição. É por isso que levantamentos de afastamento muito longo conseguem, em parte, o que fontes de baixíssima frequência conseguiriam.

$$|k_m|_{\max} = 4\pi/\lambda_{\min} \quad (\text{reflexão}, \theta = \pi)$$



abaixo disto: **nenhuma informação**
(o modelo inicial tem de fornecer)

1.4 As três dificuldades, reenunciadas

Dificuldade prática	Propriedade matemática	Onde é tratada
F é caro	EDP hiperbólica em $\mathbb{R}^d \times [0, T]$	Caps. 3, 9
J não é convexa	oscilação de F em m (fase)	Caps. 5, 6
$\dim \mathcal{M}$ é grande	F' compacto, $F'^* F'$ nunca formada	Caps. 6, 8

O que fica deste capítulo

- $F : \mathcal{M} \rightarrow \mathcal{D}$ é não linear, Fréchet-diferenciável, com derivada F' (operador de Born) compacta.
- “Mal posto” cobre três falhas distintas, com remédios distintos; confundi-las é o erro metodológico mais comum.
- $|\mathbf{k}_m| = (4\pi/\lambda) \sin(\theta/2)$ determina, antes de qualquer algoritmo, quais escalas do modelo o experimento pode enxergar — e a lacuna espectral que o modelo inicial precisa preencher.

Problemas

1. Mostre que, se F é Fréchet-diferenciável, então é Gâteaux-diferenciável, e exiba a razão pela qual a recíproca falha. Por que essa distinção é exatamente o que o teste de Taylor mede?
2. Um levantamento tem $f \in [3, 30]$ Hz, $c = 2500$ m/s, e ângulos de espalhamento em $[40^\circ, 170^\circ]$. Calcule a faixa de $|\mathbf{k}_m|$ coberta e o comprimento de onda de modelo mais longo e mais curto recuperáveis.
3. No mesmo levantamento, quanto seria preciso baixar $f_{\min}$ para obter o mesmo $|\mathbf{k}_m|$ mínimo que se obteria reduzindo $\theta_{\min}$ de 40° para 20° ?
4. Explique, usando (1.4), por que um dado exclusivamente de reflexão em afastamento curto não restringe a tendência de velocidade por mais iterações que se faça.

Respostas. (1) Fréchet exige que o resto seja $o(\|\delta m\|)$ *uniformemente* na direção; Gâteaux exige apenas direção a direção, e o limite pode não ser uniforme nem linear em δm . O

teste de Taylor verifica a taxa $\mathcal{O}(\alpha^2)$, isto é, exatamente a uniformidade do resto. (2) $|\mathbf{k}_m| = (4\pi f/c) \sin(\theta/2)$; mínimo com $f = 3$, $\theta = 40^\circ$: $(4\pi \cdot 3/2500) \sin 20^\circ \approx 5,2 \times 10^{-3}$ rad/m, ou $\lambda_m \approx 1,2$ km; máximo com $f = 30$, $\theta = 170^\circ$: $(4\pi \cdot 30/2500) \sin 85^\circ \approx 0,150$ rad/m, ou $\lambda_m \approx 42$ m. (3) $\sin 20^\circ / \sin 10^\circ \approx 1,97$, logo seria preciso baixar $f_{\min}$ de 3 para $\approx 1,5$ Hz — o que ilustra por que abrir a aquisição é frequentemente mais barato que baixar a frequência. (4) Afastamento curto $\Rightarrow \theta \approx \pi \Rightarrow |\mathbf{k}_m|$ próximo do máximo. As componentes de baixo número de onda simplesmente não são medidas, e nenhuma iteração cria dado.

Capítulo 2

Física, parametrização e o limite acústico

A ideia deste capítulo, em uma frase

A escolha da física e a escolha da *parametrização* são decisões distintas, e a segunda é tão consequente quanto a primeira: parâmetros diferentes que descrevem o *mesmo* meio produzem problemas inversos com condicionamento e *crosstalk* radicalmente diferentes.

Antes de usar: leis constitutivas, classes de simetria e perturbação singular

Lei constitutiva. A dinâmica de um meio contínuo separa-se em duas partes: o balanço de momento, que é universal ($\rho \partial_t v_i = \partial_j \sigma_{ij} + f_i$), e a *lei constitutiva*, que é onde o material entra. Toda a hierarquia de físicas deste volume — acústica, elástica, viscoelástica, anisotrópica — é uma escolha de lei constitutiva, com o balanço de momento intacto.

Tensor de rigidez e simetria. Em geral $\sigma_{ij} = c_{ijkl} \varepsilon_{kl}$, com c_{ijkl} tendo 21 componentes independentes (simetria trigonal do tensor mais a existência de uma energia de deformação). Impor simetrias reduz esse número: isotropia deixa 2 (λ, μ); VTI deixa 5; ortorrômbico, 9. **Cada simetria imposta é uma hipótese física com custo**, exatamente como $\mu = 0$.

Perturbação regular *versus* singular. Se fazer um parâmetro tender a zero apenas muda os coeficientes da solução, a perturbação é *regular*. Se ela muda a *natureza* do problema — a ordem do sistema, o número de modos, o tipo de condição de contorno admissível — ela é *singular*, e o limite não é uniforme.

$\mu \rightarrow 0$ é **singular**: um modo de propagação inteiro (a onda S) desaparece, e a condição de contorno na superfície livre muda de natureza (de “tração nula”, três condições, para “pressão nula”, uma). É por isso que o erro cometido pela aproximação acústica **não** é uniformemente pequeno em v_s : ele é pequeno onde as ondas S são pouco excitadas e $\mathcal{O}(1)$ onde elas dominam, independentemente de quão pequeno seja v_s/v_p . Essa observação explica por que a FWI acústica funciona bem no mar e mal em terra, e por que não existe “fator de correção” que conserte o caso terrestre.

2.1 A hierarquia

Modelo	Campos (2D)	Parâm.	O que acrescenta
Acústico, ρ const.	p	1	cinemática P
Acústico, ρ variável	p	2	amplitude de reflexão correta
Viscoacústico	p + memória	2–3	dissipação + dispersão
Elástico isotrópico	$v_x, v_z, \sigma_{xx}, \sigma_{zz}, \sigma_{xz}$	3	ondas S, conversões, AVO
Elástico VTI	idem	5	anisotropia polar
Viscoelástico	+ variáveis de memória	5–7	tudo acima

O ponto de partida é sempre o mesmo par:

$$\rho \partial_t v_i = \partial_j \sigma_{ij} + f_i, \quad (2.1)$$

$$\partial_t \sigma_{ij} = \lambda \delta_{ij} \partial_k v_k + \mu (\partial_j v_i + \partial_i v_j), \quad (2.2)$$

com $v_p = \sqrt{(\lambda + 2\mu)/\rho}$ e $v_s = \sqrt{\mu/\rho}$.

Impondo $\mu = 0$ segue, nesta ordem: $\sigma_{xz} \equiv 0$; $\sigma_{xx} = \sigma_{zz}$; a definição $p = -(\sigma_{xx} + \sigma_{zz})/2$; e o sistema de primeira ordem

$$\rho \partial_t \mathbf{v} = -\nabla p, \quad \partial_t p = -K \nabla \cdot \mathbf{v} + s, \quad (2.3)$$

que, eliminando $\mathbf{v}$, dá

$$\frac{1}{K} \partial_{tt} p = \nabla \cdot \left(\frac{1}{\rho} \nabla p \right) + \partial_t s. \quad (2.4)$$

A fonte muda de significado na eliminação

O termo-fonte de (2.3) aparece em (2.4) *derivado no tempo*. Escrever “+s” em (2.4) é redefinir a fonte — prática universal e quase nunca declarada. Consequência: dois códigos corretos, um de primeira e outro de segunda ordem, alimentados pela mesma ondaleta, produzem traços que diferem por uma derivada temporal.

Medido no código do curso: correlação +0,12 entre os traços brutos, +0,85 após derivar um deles. Sem parâmetro de ajuste.

2.2 Parametrização: a decisão que a literatura subestima

O mesmo meio acústico pode ser descrito por (K, ρ) , (c, ρ) , $(I_p = \rho c, c)$, $(m = 1/c^2, \rho)$, e outras. Fisicamente equivalentes; *numericamente*, não.

Por que a escolha muda o problema

Se $\mathbf{q} = \Phi(\mathbf{p})$ é uma mudança de parâmetros com jacobiana Φ' , então

$$\mathbf{g}_p = \Phi'^T \mathbf{g}_q, \quad H_p = \Phi'^T H_q \Phi' + (\text{termo com } \partial^2 \Phi).$$

Ou seja: uma mudança de parâmetros é uma **mudança de base com congruência na Hessiana**. Ela não altera o mínimo, mas altera:

- o **condicionamento** (autovalores de H), e portanto a velocidade de convergência de todo método de primeira ordem;

- os **termos fora da diagonal de bloco** entre parâmetros diferentes — isto é, o **crosstalk**;
- o significado de “suave” na regularização (suavizar c não é suavizar $1/c^2$).

Um método de Newton *exato* seria invariante por reparametrização linear; nenhum método que se usa na prática é. Por isso a escolha importa tanto.

Duas escolhas com justificativa clara:

$m = 1/c^2$ **para o gradiente**. A equação é *linear* em m , logo $\partial \mathcal{A}/\partial m = \partial_{tt}$, e a fórmula do gradiente sai sem regra da cadeia. Conversão: $\partial J/\partial c = (-2/c^3) \partial J/\partial m$ — note o sinal, que **inverte** o sentido da atualização.

(I_p, c) **para inversão com densidade**. A justificativa é a §2.3: nessa base, cada parâmetro imprime a sua assinatura em uma faixa de ângulos *diferente*, e o *crosstalk* cai.

2.3 Padrões de radiação: a dedução

Monópolo e dipólo: de onde vem a separação de ângulos (cf. Tarantola, 1986; Operto *et al.*, 2013)

Linearize (2.4) em torno de um meio homogêneo de referência (K_0, ρ_0) , com perturbações $\delta\kappa$ (onde $\kappa = 1/K$) e $\delta\rho$. Na aproximação de Born, o campo espalhado por um elemento de volume em $\mathbf{x}$ tem dois termos:

- o termo em $\delta\kappa$ entra multiplicando $\partial_{tt}p_0$, que é um escalar — espalhamento **isotrópico** (monópolo);
- o termo em $\delta(1/\rho)$ entra dentro de um divergente aplicado a ∇p_0 , ou seja, envolve o produto das *direções* de propagação incidente e espalhada — espalhamento **dipolar**, proporcional a $\cos\theta$.

O padrão de radiação do espalhamento P–P é portanto

$$f(\theta) \propto \frac{\delta\kappa}{\kappa} + \frac{\delta\rho}{\rho} \cos\theta \quad (2.5)$$

com θ o ângulo de espalhamento.

A consequência, e por que (I_p, c) é a base natural

Reescreva (2.5) em velocidade e impedância. Com $I_p = \rho c$ e $\kappa = 1/(\rho c^2) = 1/(I_p c)$:

$$\frac{\delta\kappa}{\kappa} = -\frac{\delta I_p}{I_p} - \frac{\delta c}{c}, \quad \frac{\delta\rho}{\rho} = \frac{\delta I_p}{I_p} - \frac{\delta c}{c},$$

e portanto


$$f(\theta) \propto \frac{\delta I_p}{I_p} (\cos\theta - 1) - \frac{\delta c}{c} (1 + \cos\theta). \quad (2.6)$$

Leia os dois coeficientes:

Parâmetro	Padrão	Zera em	Máximo em
I_p (impedância)	$\cos\theta - 1$	$\theta = 0$ (transmissão)	$\theta = \pi$ (reflexão)
c (velocidade)	$-(1 + \cos\theta)$	$\theta = \pi$ (reflexão)	$\theta = 0$ (transmissão)

Os dois padrões são **complementares**: onde um é máximo o outro é nulo. Essa é a justificativa quantitativa da prática consagrada: *reflexões de afastamento curto restringem impedância; ondas mergulhantes de afastamento longo restringem velocidade*. E casa exatamente com (1.4): $\theta \rightarrow \pi$ é número de onda alto (a interface), $\theta \rightarrow 0$ é número de onda baixo (o fundo).

Na base (κ, ρ) , ao contrário, os dois padrões se *superpõem* em boa parte da faixa angular — e essa superposição é o *crosstalk*. Ver Capítulo 11.



Padrões de radiação P-P de (2.6), em coordenadas polares no ângulo de espalhamento θ (medido a partir da direção de propagação incidente, à direita). A impedância radia para trás (reflexão); a velocidade radia para a frente (transmissão).

2.4 A fonte como incógnita

Em dado real a ondaleta é desconhecida. Como F é *linear* na fonte, o problema conjunto $\min_{m,w} J(m, w)$ admite **projeção variável** (Golub–Pereyra): elimine w analiticamente,

$$w^*(\omega) = \frac{\sum_r \overline{g_r(\omega)} d_{\text{obs},r}(\omega)}{\sum_r |g_r(\omega)|^2 + \epsilon}, \quad (2.7)$$

e minimize o funcional reduzido $\tilde{J}(m) = J(m, w^*(m))$. O gradiente de $\tilde{J}$ *não* precisa de termo extra em w — exatamente porque w^* é ótimo, o que faz $\partial J / \partial w = 0$ ali. É o mesmo argumento do envelope theorem.

O que a estimativa de fonte absorve sem avisar

w^* é um filtro de casamento entre sintético e observado. Ele absorverá, indistintamente: a assinatura real da fonte, o efeito de *ghost*, a resposta do instrumento, e **o erro de física que a sua equação não modela**.

Sintoma diagnóstico: uma ondaleta estimada que muda significativamente entre bandas de frequência ou entre tiros não é uma ondaleta — é o seu erro de modelagem, disfarçado.

O que fica deste capítulo

- $\mu \rightarrow 0$ é perturbação *singular*: o erro acústico não é uniformemente pequeno, e não há fator de correção.
- Reparametrizar é uma congruência na Hessiana: muda condicionamento e *crosstalk*, não o mínimo.

- $f(\theta) \propto \delta\kappa/\kappa + (\delta\rho/\rho) \cos \theta$ — e, em (I_p, c) , os padrões ficam complementares. É o argumento quantitativo para “reflexão dá impedância, transmissão dá velocidade”.
- A fonte estimada por projeção variável é grátis no gradiente — e absorve erro de física silenciosamente.

Capítulo 3

Análise numérica do problema direto

A ideia deste capítulo, em uma frase

Consistência mais estabilidade equivale a convergência — esse é o teorema. O que ele *não* diz é a que taxa, nem com qual erro de fase; e em FWI é o erro de fase, não o de amplitude, que estraga a inversão.

Antes de usar: consistência, estabilidade, convergência e o símbolo de um operador

Consistência: o esquema discreto, aplicado à solução exata, deixa um resíduo (erro de truncamento) que tende a zero com $\Delta h, \Delta t$. É uma afirmação sobre a *fórmula*.

Estabilidade: a solução discreta não amplifica sem limite ao longo dos passos. É uma afirmação sobre a *iteração*.

Teorema de equivalência de Lax. Para um problema linear de valor inicial bem posto e um esquema consistente: *estabilidade* $\Leftrightarrow$ *convergência*. É o resultado que justifica a divisão de trabalho do capítulo — verifica-se consistência por Taylor e estabilidade por von Neumann, e a convergência vem de graça.

Símbolo de um operador de diferenças. Aplicando um operador discreto a e^{ikx} obtém-se e^{ikx} multiplicado por uma função de $k\Delta h$ — o **símbolo**. Para o estêncil de derivada segunda (3.1),

$$\widehat{\partial_{xx}} \rightarrow -\frac{S(k\Delta h)}{\Delta h^2}, \quad S(\theta) = -\left[c_0 + 2 \sum_{j \geq 1} c_j \cos(j\theta)\right],$$

enquanto o operador exato tem símbolo $-k^2$. **Toda a análise de estabilidade e de dispersão é a comparação entre $S(\theta)/\Delta h^2$ e k^2** — consistência é $S(\theta) \rightarrow \theta^2$ quando $\theta \rightarrow 0$, e dispersão é o desvio para θ não pequeno.

3.1 Estênceis: Taylor *versus* otimização de banda

$$\left. \frac{\partial^2 f}{\partial x^2} \right|_i \approx \frac{1}{h^2} \left[c_0 f_i + \sum_{j=1}^N c_j (f_{i+j} + f_{i-j}) \right]. \quad (3.1)$$

Os coeficientes clássicos resolvem as condições de momento

$$c_0 + 2 \sum_j c_j = 0, \quad 2 \sum_j j^2 c_j = 2, \quad \sum_j j^{2\ell} c_j = 0 \quad (\ell = 2, \dots, N),$$

que maximizam a ordem em $\theta \rightarrow 0$. Isso é uma escolha, não a única.

Coeficientes otimizados: trocar ordem por banda

Maximizar a ordem concentra toda a precisão em $\theta \rightarrow 0$, isto é, em ondas muito bem amostradas — que não são as que causam problema. A alternativa é escolher $\{c_j\}$ minimizando

$$\max_{\theta \in [0, \theta_{\max}]} \left| \frac{\sqrt{S(\theta)}}{\theta} - 1 \right|$$

sobre a faixa de θ efetivamente presente na simulação. O resultado tem ordem formal *menor* e erro real *menor* na banda de interesse.

O mesmo raciocínio, aplicado ao esquema completo em espaço e tempo, produz os esquemas ditos “de baixa dispersão”. Em FWI o ganho é real: permite G menor, e G entra ao cubo no custo 2D.

3.2 Estabilidade e dispersão, na forma completa

Com *leap-frog* no tempo e o símbolo acima, a substituição $p_i^n = \xi^n e^{ik \cdot x_i}$ leva a $\xi^2 - (2 - X)\xi + 1 = 0$, com $X = (c^2 \Delta t^2 / \Delta h^2) \sum_{\text{eixos}} S(k_j \Delta h)$. O produto das raízes vale 1, logo $|\xi| = 1$ exatamente quando elas são complexas conjugadas, isto é quando $0 \leq X \leq 4$:

$$C = \frac{c_{\max} \Delta t}{\Delta h} \leq C_{\lim} = \frac{2}{\sqrt{n_{\dim} (|c_0| + 2 \sum_j |c_j|)}}, \quad (3.2)$$

e, escrevendo $\xi = e^{-i\omega \Delta t}$, a relação de dispersão

$$\frac{4}{\Delta t^2} \sin^2 \frac{\omega \Delta t}{2} = \frac{c^2}{\Delta h^2} \sum_{\text{eixos}} S(k_j \Delta h). \quad (3.3)$$

Ordem	$ c_0 + 2 \sum_j c_j $	$C_{\lim}$ (2D)	$C_{\lim}$ (3D)
$\mathcal{O}(2)$	4,000	0,7071	0,5774
$\mathcal{O}(4)$	5,333	0,6124	0,5000
$\mathcal{O}(8)$	6,502	0,5546	0,4529

Os dois erros têm sinais opostos, e a curva espacial não é conservadora

O estêncil espacial *atrasa* a fase; o *leap-frog* a *adianta*. Medidas do curso, em $\mathcal{O}(4)$ com $G = 6$: a curva semi-discreta prevê $c_{\text{num}}/c = 0,9939$; o esquema completo (3.3) dá 0,9980 com $C = 0,3$ (erro *menor* que o previsto) e 1,0081 com $C = 0,551$ (erro *maior*). Em $\mathcal{O}(8)$ com $G = 5$, $C = 0,5$: a curva espacial promete 0,07% e o esquema entrega 1,6% — o erro espacial sumiu e sobrou o temporal, sozinho.

Verificação independente no propagador do curso: velocidade de fase relativa medida 1,0146, contra 1,0160 da relação completa e 0,9993 da curva espacial. A relação completa acerta; a curva espacial erra o sinal do desvio.

Anisotropia numérica

A soma sobre eixos em (3.3) não é isotrópica: para $\mathbf{k}$ ao longo de um eixo da malha, a soma tem um termo $S(k\Delta h)$; para $\mathbf{k}$ a 45° , tem dois termos $S(k\Delta h/\sqrt{2})$. Como S é não linear, os dois casos dão velocidades de fase diferentes: **a malha tem uma direção preferencial**. Consequência em FWI: o erro de tempo de trânsito depende do ângulo de propagação, e portanto do afastamento. Isso é um erro *sistemático e coerente* — exatamente o tipo que a inversão converte em estrutura. Por isso o dimensionamento de G deve considerar a direção pior, e não a média.

3.3 Energia discreta e conservação

Por que o *leap-frog* é uma boa escolha em FWI

Para o sistema semi-discreto sem fonte $M\ddot{\mathbf{p}} = -K\mathbf{p}$, com M diagonal positiva e K simétrica positiva semidefinida (o que o estêncil centrado garante), o *leap-frog* conserva **exatamente** a quantidade

$$E^{n+1/2} = \frac{1}{2} (\mathbf{v}^{n+1/2})^T M \mathbf{v}^{n+1/2} + \frac{1}{2} (\mathbf{p}^{n+1})^T K \mathbf{p}^n, \quad \mathbf{v}^{n+1/2} = \frac{\mathbf{p}^{n+1} - \mathbf{p}^n}{\Delta t}, \quad (3.4)$$

no sentido de que $E^{n+1/2} = E^{n-1/2}$ para todo n — o que se verifica substituindo o esquema diretamente em (3.4).

O termo cruzado $\mathbf{p}^{n+1} K \mathbf{p}^n$ não é uma forma quadrática em um único instante, e é justamente aí que a CFL reaparece: escrevendo-o em torno do ponto médio, $E^{n+1/2}$ é **positiva definida se e somente se**

$$\Delta t^2 \lambda_{\max}(M^{-1}K) < 4,$$

que é *exatamente* a condição (3.2). Ou seja: a CFL não é apenas “o esquema não explode” — é a condição para que exista uma energia discreta conservada e positiva. Acima dela, $E^{n+1/2}$ continua conservada, mas deixa de ser positiva *definida*, e a solução pode crescer sem violar a conservação.

Isso importa em FWI por duas razões. Primeira: sem deriva de energia, um registro longo não acumula erro de amplitude sistemático. Segunda: um esquema conservativo e simétrico tem adjunto discreto igual a ele mesmo rodado ao contrário, o que torna o gradiente exato até arredondamento — §3.4.

3.4 Adjunto discreto *versus* adjunto contínuo

Derivar-e-discretizar *versus* discretizar-e-derivar

Há duas rotas para o gradiente:

(a) **Contínua** (*optimize-then-discretize*): deriva-se a equação adjunta no contínuo (Cap. 6) e discretiza-se *ela*. O resultado é o gradiente de um funcional próximo ao discreto, mas não exatamente dele.

(b) **Discreta** (*discretize-then-optimize*): discretiza-se primeiro, e deriva-se o *programa* — literalmente o adjunto do algoritmo. O resultado é o gradiente **exato** do J discreto que o código realmente avalia.

A diferença é $\mathcal{O}(\Delta t^p)$, portanto some no refinamento. Mas o **teste de Taylor do Capí-**

tulo 7 mede o gradiente do J discreto — e por isso só a rota (b) passa no teste com razão 1,0000. Uma razão estável em, digamos, 0,997 pode ser exatamente esta discrepância, e não um *bug*.

Como decidir se é discrepância ou *bug*: refine Δt e Δh . Discrepância contínuo/discreto *encolhe*; *bug* não.

Para esquemas auto-adjuntos e centrados — laplaciano simétrico, *leap-frog*, absorção diagonal de Cerjan — as duas rotas coincidem, e essa é uma razão técnica forte para preferir esse conjunto de escolhas num código de pesquisa. Com CPML, não coincidem.

O que fica deste capítulo

- Lax: consistência + estabilidade = convergência. O símbolo $S(\theta)$ carrega as duas análises.
- Maximizar ordem não é o mesmo que minimizar erro na banda usada — daí os estênceis otimizados.
- Perto da CFL, o erro de dispersão é dominado pelo tempo, e tem sinal oposto ao espacial.
- A malha é anisotrópica: o erro de fase depende do ângulo, e portanto do afastamento — erro coerente, o pior tipo para FWI.
- Esquemas auto-adjuntos fazem adjunto contínuo e discreto coincidirem.

Capítulo 4

Domínio truncado e aquisição

A ideia deste capítulo, em uma frase

A camada perfeitamente casada não é um truque numérico: é uma continuação analítica da equação para coordenadas complexas. Entender isso explica de uma vez por que ela não reflete, por que a versão clássica falha em incidência rasante, e por que o seu adjunto dá trabalho.

Antes de usar: continuação analítica e estiramento complexo de coordenada

A observação de partida. Uma onda plana harmônica e^{ikx} é uma função *inteira* de x : faz sentido avaliá-la em x complexo. E se $x \rightarrow x + i\eta$ com $\eta > 0$ e $k > 0$,

$$e^{ik(x+i\eta)} = e^{ikx} e^{-k\eta},$$

isto é: **a onda decai**, sem que nada tenha mudado na equação. Ela continua sendo a mesma solução da mesma EDP, apenas avaliada fora do eixo real.

Estiramento de coordenada. Formalize com

$$\tilde{x}(x) = \int_0^x s(x') dx', \quad s(x) = 1 + \frac{\sigma(x)}{i\omega},$$

e substitua $\partial_x \rightarrow s(x)^{-1} \partial_x$ na equação. Onde $\sigma = 0$ (domínio físico) nada muda; onde $\sigma > 0$ (a moldura), a solução é a continuação analítica, que decai.

Por que não há reflexão na interface. A equação é a mesma dos dois lados — só a coordenada foi estirada. Não existe contraste de impedância, e portanto não existe reflexão, *para qualquer ângulo e qualquer frequência*. Daí o nome: *perfectly matched*. A reflexão que se observa na prática vem inteiramente da **discretização** de σ — por isso σ é crescido suavemente (tipicamente polinomial) em vez de ligado de uma vez.

4.1 PML clássica, e por que ela falha em incidência rasante

O termo que a CPML acrescenta

Para uma onda plana com componente $k_x = (\omega/c) \cos \phi$ (ϕ o ângulo com a normal à face),

o fator de decaimento através da moldura é

$$\exp\left[-\frac{\cos\phi}{c} \int \sigma(x') dx'\right].$$

Note o que *não* aparece: ω . O decaimento é **independente da frequência** — bom. Mas ele carrega $\cos\phi$: em incidência **rasante** ($\phi \rightarrow 90^\circ$) o decaimento **some**. A onda atravessa a moldura quase sem ser atenuada, bate na parede externa e volta.

Isso não é detalhe acadêmico: é exatamente a situação das ondas mergulhantes de afastamento longo — as que carregam a informação de baixo número de onda (§1.3) — e das ondas de superfície.

A CPML (*convolutional* PML; Komatitsch & Martin, 2007) generaliza o estiramento para

$$s(x) = \kappa(x) + \frac{\sigma(x)}{\alpha(x) + i\omega}, \quad \kappa \geq 1, \alpha > 0.$$

O κ estica também a parte *real* da coordenada, o que encurta o comprimento de onda aparente dentro da moldura e ataca diretamente o caso rasante. O α — o *deslocamento de frequência* — amortece as componentes evanescentes e de baixíssima frequência, que a PML clássica trata mal.

O preço é o nome: $1/(\alpha + i\omega)$ no domínio do tempo é uma **convolução**, implementada com variáveis de memória adicionais atualizadas recursivamente — mais campos, mais estado.

Medidas do curso, comparando cada caso com uma referência em domínio grande (a diferença é, por construção, só artefato):

Cerjan		CPML	
n_{abs}	reflexão	n_{pml}	reflexão
0	−6,9 dB	0	−11,2 dB
10	−8,5 dB	5	−20,1 dB
20	−13,3 dB	10	−51,5 dB
30	−16,5 dB	20	−69,6 dB
45	−18,4 dB	30	−77,3 dB

Descontando a linha $n = 0$ de cada experimento (que é o espelho, já atenuado por espalhamento geométrico): Cerjan com 45 pontos fica 11,5 dB abaixo do seu espelho; CPML com 10 pontos fica 40,3 dB abaixo do dela.

4.2 O adjunto de uma camada absorvente

O erro silencioso mais sofisticado deste volume

O Capítulo 6 mostra que a condição de contorno do problema adjunto é o *adjunto* da condição do problema direto. Para Dirichlet e Neumann homogêneas, elas coincidem. Para uma camada absorvente, **não**.

Cerjan. O *taper* é um operador *diagonal* — multiplica cada amostra por um escalar positivo. Toda matriz diagonal é simétrica, logo auto-adjunta. Rodar o mesmo *sponge* na retropropagação é exatamente correto. É por isso que um código didático ou de pesquisa, em que o teste de gradiente precisa fechar em 1,0000, ganha muito usando Cerjan apesar de ele ser inferior como absorvedor.

CPML. O sistema estendido (campos + variáveis de memória) não é simétrico: as equações de memória são recursões de primeira ordem no tempo, e $\partial_t^* = -\partial_t$. O adjunto correto exige transpor o sistema *inteiro*, variáveis de memória incluídas, e integrá-lo em tempo revertido. O atalho comum — “rode a mesma CPML ao contrário” — é uma aproximação.

Qual é o tamanho do erro? Ele fica confinado à moldura, onde o campo já está atenuado, e portanto contamina pouco o gradiente no domínio físico. Na prática de produção é aceito. Mas ele *aparece* no teste de Taylor como uma razão estável ligeiramente diferente de 1 — e, como toda discrepância sistemática, é indistinguível de um *bug* até que se faça o teste de refinamento da §3.4.

Recomendação prática: verifique o gradiente com Cerjan (onde a razão deve fechar em 1,0000) e só depois troque para CPML, registrando de quanto a razão se afasta. Assim o desvio residual fica *atribuído*, em vez de desconhecido.

4.3 Superfície livre

A condição $p = 0$ em $z = 0$ é imposta corretamente pelo **método das imagens**: estenda o campo para $z < 0$ com $p(-z, t) = -p(z, t)$. A antissimetria garante $p = 0$ exatamente em $z = 0$ e alimenta o estêncil com valores consistentes.

O erro de posicionamento de meia moldura

Zerar as N primeiras linhas da malha (o alcance do estêncil) *parece* implementar $p = 0$, e coloca a superfície efetiva em $z = (N - 1)\Delta h$. Com $\mathcal{O}(8)$ e $\Delta h = 10$ m, isso é um deslocamento de 30 m em *todas* as múltiplas e no *ghost* — um erro cinemático sistemático que a FWI converterá fielmente em estrutura.

4.4 Aquisição como amostragem do espaço de números de onda

A §1.3 mostrou que cada tripla (fonte, receptor, frequência) amostra um $\mathbf{k}_m$. A geometria de aquisição é, portanto, um **esquema de amostragem** no espaço de números de onda do modelo, e as decisões de campo têm tradução direta:

Decisão de aquisição	Efeito em $\mathbf{k}_m$	O que melhora
aumentar $f_{\max}$	estende $ \mathbf{k}_m $ para cima	resolução
baixar $f_{\min}$	estende para baixo	preenche a lacuna espectral
aumentar o afastamento	alcança θ pequeno	escalas grandes, profundidade
adensar receptores	evita <i>aliasing</i> em $\mathbf{k}_m$	artefatos
adensar tiros	mais amostras por $\mathbf{k}_m$	razão sinal/ruído

Por que “mais receptores” não ilumina mais fundo

Profundidade de investigação é governada pelo *menor* θ alcançável, isto é, pela abertura. Adensar receptores dentro da mesma abertura acrescenta amostras dos *mesmos* $\mathbf{k}_m$ — melhora condicionamento e ruído, e não acrescenta nenhuma componente nova. Daí a regra $z_{\max} \approx x_{\text{off}}^{\max}/3$ a $/2$, que não depende da densidade.

2D contra 3D: uma correção que é frequentemente esquecida

Um código 2D resolve o problema de uma *fonte linear* infinita fora do plano, não de uma fonte pontual. As consequências no dado sintético: espalhamento geométrico $r^{-1/2}$ em vez de r^{-1} , e uma rotação de fase de 45° com escalonamento espectral $\propto \sqrt{\omega}$.

Inverter dado 3D real com um operador 2D sem a correção 2,5D coloca esse erro inteiro no resíduo — e ele é *coerente*, portanto vira modelo.

A razão entre as duas funções de Green, em meio homogêneo, é $G_{2D}/G_{3D} \propto \sqrt{r/\omega} e^{i\pi/4}$. Daí a receita: para trazer dado **3D ao regime 2D**, multiplique por $\sqrt{t}$ e aplique uma **meia-integração** — filtro $\propto (i\omega)^{-1/2}$, equivalente a convolver com $1/\sqrt{\pi t}$ —, que é o que introduz a cauda que a fonte linear tem e a pontual não. O caminho oposto (levar sintéticos 2D ao regime 3D) usa a **meia-derivada** $\sqrt{i\omega}$. Trocar os dois inverte o sinal da rotação de fase — 90° de erro, sistemático.

A correção é aproximada, e exata só para meio homogêneo; ver Schäfer *et al.* (2014) para a comparação entre as variantes e os resíduos que sobram.

O que fica deste capítulo

- PML é continuação analítica em coordenada complexa; a reflexão residual é artefato de discretização, não do método.
- A PML clássica perde eficácia em incidência rasante ($\cos \phi \rightarrow 0$); a CPML corrige com κ e α , ao custo de variáveis de memória.
- Cerjan é diagonal, logo auto-adjunto: o teste de gradiente fecha em 1,0000. CPML não é — verifique com Cerjan, depois troque e registre o desvio.
- A geometria de aquisição é um esquema de amostragem em $\mathbf{k}_m$; abertura controla escala grande, banda controla resolução.

Parte II — O problema inverso

Capítulo 5

Geometria do funcional e funcionais alternativos

A ideia deste capítulo, em uma frase

A não convexidade do L_2 não é acidente nem defeito de implementação: é consequência direta de comparar sinais oscilatórios amostra a amostra. Cada funcional alternativo é uma tentativa de trocar essa comparação por outra que seja convexa em relação a deslocamento — e cada um paga um preço identificável.

Antes de usar: a geometria de “comparar sinais deslocados”

Considere o caso mais simples possível: dois sinais idênticos separados por um deslocamento τ , e o desajuste como função de τ :

$$\Phi(\tau) = \frac{1}{2} \int [d(t - \tau) - d(t)]^2 dt = \|d\|^2 - R_{dd}(\tau),$$

com R_{dd} a **autocorrelação** de d .

Este resultado de uma linha contém tudo. A forma de Φ é a autocorrelação invertida — e a autocorrelação de um sinal oscilatório **oscila**. Logo Φ tem máximos e mínimos locais espaçados de aproximadamente um período.

Consequência inescapável: enquanto o desajuste for uma *comparação amostra a amostra* entre sinais oscilatórios, ele será não convexo em deslocamento. Não há escolha de otimizador, pré-condicionador ou regularizador que conserte isso — só trocar a comparação.

Medido para uma Ricker. Calculando $\Phi(\tau)$ numericamente: a divisa entre “corrige certo” e “corrige errado” cai em $\tau \approx 0,43 T$, e há um **mínimo local** em $\tau \approx 0,90 T$. A regra de meio ciclo ($T/2$) é portanto ligeiramente **otimista**, e o poço em que a inversão cai está pouco antes de um período completo.

O que “convexo em deslocamento” significa. Queremos um Φ com um único mínimo em $\tau = 0$ e crescimento monotônico — idealmente $\Phi(\tau) \propto \tau^2$. É esse o critério pelo qual os funcionais das próximas seções devem ser julgados.




Figura 5.1: $J(c)$ varrido para quatro frequências, meio homogêneo, $c_{\text{verd}} = 2000$ m/s. A largura do vale central escala com $1/f$, como prevê (5.1).

5.1 O L_2 e o critério de meio ciclo

Com $\delta t \approx -L \delta c / c^2$ para um percurso L , o critério $|\delta t| < T/2$ vira

$$|\delta c| < \frac{c^2}{2fL}. \quad (5.1)$$

Validação medida no curso (vale de atração varrido numericamente):

f_0 (Hz)	vale medido (m/s)	semilargura prevista	semilargura medida
3,0	1710 a 2489	422	389
6,0	1858 a 2192	211	167
12,0	1908 a 2118	105	105
25,0	1945 a 2069	51	62

5.2 Funcionais alternativos e suas fontes adjuntas

Trocar o funcional muda *uma única coisa* no código: a **fonte adjunta** $f_{\text{adj}} = \partial J / \partial d_{\text{cal}}$ injetada nos receptores (Cap. 6). Vale, portanto, escrever cada uma explicitamente.

Envoltória

Com $\mathcal{H}$ a transformada de Hilbert e $E = \sqrt{d^2 + (\mathcal{H}d)^2}$ a envoltória, $J_{\text{env}} = \frac{1}{2} \int (E_{\text{cal}} - E_{\text{obs}})^2$.

A fonte adjunta da envoltória

De $E^2 = d^2 + (\mathcal{H}d)^2$ segue $E \delta E = d \delta d + (\mathcal{H}d) \mathcal{H}(\delta d)$. Com $\Delta E = E_{\text{cal}} - E_{\text{obs}}$,

$$\delta J = \int \frac{\Delta E}{E} \left[d \delta d + (\mathcal{H}d) \mathcal{H}(\delta d) \right] dt.$$

Usando que $\mathcal{H}$ é **anti-auto-adjunta** ($\int f \mathcal{H}g = -\int \mathcal{H}f g$), o segundo termo passa para δd e

$$f_{\text{adj}}^{\text{env}} = \frac{\Delta E}{E} d - \mathcal{H} \left[\frac{\Delta E}{E} \mathcal{H}d \right]. \quad (5.2)$$

Preço. A envoltória descarta a fase fina, que é justamente o que dá resolução. Usa-se nas primeiras bandas e troca-se pelo L_2 depois.

Tempo de trânsito por correlação cruzada

Seja ΔT o atraso que maximiza a correlação entre sintético e observado numa janela, e $J = \frac{1}{2} \sum (\Delta T)^2$. A fonte adjunta (Luo & Schuster, 1991; Tromp *et al.*, 2005, eqs. 42 e 45) é

$$f_{\text{adj}}^{\text{cc}}(t) = -\frac{\Delta T}{N} \partial_t d_{\text{cal}}(T - t), \quad N = \int_0^T [\partial_t d_{\text{cal}}(t)]^2 dt. \quad (5.3)$$

Duas formas da normalização, e três sinais para acertar

Não é raro ver a normalização escrita como $N = \int d_{\text{cal}} \partial_{tt} d_{\text{cal}} dt$. Integrando por partes, com os termos de fronteira nulos,

$$\int_0^T d \partial_{tt} d dt = - \int_0^T (\partial_t d)^2 dt,$$

ou seja: as duas expressões são a mesma coisa **a menos de um sinal**. Some a isso a convenção adotada para ΔT (observado menos sintético, ou o contrário) e o sentido do tempo em que a fonte adjunta é injetada, e há *três* sinais independentes para acertar.

Use a forma (5.3), em que $N > 0$ por construção, e **fixe o sinal com o teste do Capítulo 7**, nunca por inspeção. Um sinal trocado aqui produz uma inversão que *sobe* o funcional com total confiança — e, como o Volume 2 insiste, isso não se parece com erro.

Preço. Exige *janelamento* — é preciso identificar *qual* evento se está comparando. Isso reintroduz interpretação humana, que era justamente o que a FWI prometia eliminar. Em compensação, $\Phi(\tau) = \tau^2$ exatamente: perfeitamente convexa em deslocamento, dentro da janela.

Inversão adaptativa (AWI)

Estime o filtro de Wiener u que leva o sintético ao observado, $u = \arg \min_u \|u * d_{\text{cal}} - d_{\text{obs}}\|^2$, e penalize o *espalhamento* desse filtro:

$$J_{\text{AWI}} = \frac{\|Tu\|^2}{\|u\|^2}, \quad T = \text{diag}(t) \quad (\text{Warner \& Guasch, 2016}). \quad (5.4)$$

A ideia é elegante: se o modelo estiver certo, u é uma delta em $t = 0$ e $J = 0$; se estiver errado, u concentra-se em $t = \tau \neq 0$ e J cresce como τ^2 — **sem precisar janelar**, porque o filtro encontra o atraso sozinho. O denominador torna J invariante a escala.

Preço. Um problema de mínimos quadrados adicional por traço, e um parâmetro de regularização na estimativa de u .

Transporte ótimo

Por que o transporte ótimo é o candidato natural, e por que é difícil

Para duas densidades de probabilidade μ, ν em $\mathbb{R}$, a distância de Wasserstein quadrática é

$$W_2^2(\mu, \nu) = \inf_{\pi} \int |x - y|^2 d\pi(x, y),$$

com π percorrendo os acoplamentos de μ e ν . Em 1D ela tem forma fechada via funções de distribuição acumuladas.

A propriedade decisiva: para uma translação pura, $W_2(\mu, \mu(\cdot - \tau)) = |\tau|$, logo $W_2^2 = \tau^2$ — **exatamente convexa em deslocamento**, para qualquer τ , sem janela e sem limite de meio ciclo. É o comportamento que se queria desde o início deste capítulo.

O obstáculo: W_2 é definida para medidas **positivas** e de **massa igual**. Um traço sísmico oscila em torno de zero e não é nenhuma das duas coisas. Os contornos usados na literatura — cada um com o seu custo — são: separar as partes positiva e negativa; transformar por $d \mapsto e^{\beta d}$ ou $d \mapsto d^2$ (não lineares, e a convexidade em deslocamento *não* é preservada por uma transformação arbitrária); ou aplicar OT no *gráfico* do traço (*graph-space OT*), que preserva a propriedade ao custo de um problema de atribuição por traço.

A leitura honesta: o transporte ótimo resolve o problema de deslocamento de forma limpa *no caso idealizado*, e a dificuldade toda migra para a transformação que torna o dado admissível. Nenhuma dessas transformações é neutra.

5.3 Domínio estendido: mudar o espaço em vez do funcional

WRI: relaxar a EDP

Todos os funcionais acima permanecem na forma *reduzida*: a EDP é satisfeita exatamente, e a não convexidade fica em J . A alternativa estrutural é relaxar essa restrição:

$$\min_{m, u} \frac{1}{2} \|Ru - d_{\text{obs}}\|^2 + \frac{\mu}{2} \|\mathcal{A}(m)u - f\|^2. \quad (5.5)$$

Para m fixo, (5.5) é **quadrática** em u : resolve-se em um passo (um problema de mínimos quadrados aumentado). Para u fixo, o resíduo da EDP é **linear** em m (lembre que a equação é linear em $m = 1/c^2$), de modo que a atualização de m também é um problema linear.

O ganho: o campo u não é mais obrigado a ser uma solução física do modelo atual. Ele pode *já* ajustar o dado, e o resíduo da EDP passa a indicar onde o modelo precisa mudar — um caminho que contorna o $|\delta t| > T/2$ em vez de enfrentá-lo.

O preço, e ele é sério: armazenar e resolver para u em todo o domínio e todo o tempo, para cada tiro. Em 3D isso é proibitivo com a tecnologia atual, e é por isso que WRI é, hoje, sobretudo um resultado 2D. E μ é mais um parâmetro livre, cuja trajetória de continuação (μ crescendo até recuperar a forma reduzida) precisa ser projetada.

Ordem de prioridade, que não muda com o nível de sofisticação

1. Baixe a frequência inicial.
2. Melhore o modelo inicial.
3. *Só então* troque o funcional ou estenda o domínio.

Cada item desta lista introduz mais parâmetros livres que o anterior, e portanto mais maneiras de produzir um resultado que parece bom e não é.

O que fica deste capítulo

- $\Phi(\tau) = \|d\|^2 - R_{dd}(\tau)$: a não convexidade é a autocorrelação do dado. Para uma Ricker, divisa em $0,43 T$ e mínimo local em $0,90 T$.
- Cada funcional alternativo se reduz a uma fonte adjunta diferente — deduzida aqui para envoltória e correlação cruzada.
- W_2^2 é exatamente convexa em translação, mas exige positividade: a dificuldade migra para a transformação do dado.
- WRI muda o *espaço* em vez do funcional; custo de memória proibitivo em 3D.

Capítulo 6

Estado adjunto, Born e núcleos de sensibilidade

A ideia deste capítulo, em uma frase

Três objetos que a literatura trata como assuntos separados — o método do estado adjunto, a aproximação de Born e a migração reversa no tempo — são a *mesma* coisa vista de três ângulos: respectivamente, o algoritmo que aplica F'^* , a fórmula explícita de F' , e a interpretação de F'^*r como imagem. Este capítulo estabelece a equivalência.

Antes de usar: distribuições, função de Green e a série de Born

Distribuições. $\delta(\mathbf{x}-\mathbf{x}_0)$ não é uma função: é o funcional linear $\varphi \mapsto \varphi(\mathbf{x}_0)$. A utilidade aqui é dupla: representa fontes e receptores pontuais, e permite escrever “avaliar no receptor” como uma integral — o que torna legítimo derivar sob o sinal de integral na dedução seguinte.

Função de Green. Para o operador de onda $\mathcal{A}(m) = m \partial_{tt} - \nabla^2$, a função de Green $G(\mathbf{x}, t; \mathbf{x}', t')$ resolve

$$\mathcal{A}(m) G = \delta(\mathbf{x} - \mathbf{x}') \delta(t - t'),$$

com condições iniciais nulas. Ela é o *núcleo* do operador inverso: $u = \mathcal{A}^{-1}f$ escreve-se $u(\mathbf{x}, t) = \int G * f$.

Duas propriedades são usadas adiante. **Reciprocidade:** $G(\mathbf{x}, t; \mathbf{x}', t') = G(\mathbf{x}', t; \mathbf{x}, t')$ — trocar fonte e receptor não muda nada, e é por isso que retropropagar a partir dos receptores faz sentido físico. **Causalidade:** $G = 0$ para $t < t'$, o que faz a integral temporal ter limites finitos.

Série de Born. Escreva $m = m_0 + \delta m$. Como $\mathcal{A}(m) = \mathcal{A}(m_0) + \delta m \partial_{tt}$, a identidade $\mathcal{A}(m)u = f$ com $u = u_0 + \delta u$ dá exatamente

$$\mathcal{A}(m_0) \delta u = -\delta m \partial_{tt} u = -\delta m \partial_{tt} u_0 - \delta m \partial_{tt} \delta u.$$

Iterando, obtém-se a série de Neumann (série de Born): o primeiro termo é espalhamento simples, o segundo é espalhamento duplo, e assim por diante. **Truncar no primeiro termo é a aproximação de Born**, e é *exatamente* a linearização $F'(m_0)\delta m$ — não uma aproximação adicional.

A série converge quando o espalhamento é fraco. Em FWI ela não converge para contrastes fortes — e é por isso que a FWI *não* é uma migração de mínimos quadrados: ela reintroduz, a cada iteração, os termos de ordem superior, resolvendo de novo a EDP completa.

6.1 O operador de Born, explicitamente

No domínio da frequência, com $\mathcal{A}_\omega(m) = -\omega^2 m - \nabla^2$, perturbar $m \rightarrow m + \delta m$ dá $\mathcal{A}_\omega \delta \hat{u} = \omega^2 \delta m \hat{u}_0$, e portanto

$$[F'(m) \delta m](\mathbf{x}_r, \omega) = \omega^2 \int_{\Omega} G(\mathbf{x}_r, \mathbf{x}; \omega) \delta m(\mathbf{x}) \hat{u}_0(\mathbf{x}, \omega) d\mathbf{x} \quad (6.1)$$

Esta é a **integral de espalhamento**. Lida como algoritmo: para cada ponto $\mathbf{x}$, tome o campo incidente $\hat{u}_0$ ali, multiplique pela perturbação, e propague até o receptor com G .

As duas maneiras de calcular o gradiente, e por que uma é usada

De (6.1), o adjunto sai por inspeção, usando reciprocidade:

$$[F'^* r](\mathbf{x}) = \text{Re} \int d\omega \omega^2 \overline{\hat{u}_0(\mathbf{x}, \omega)} \sum_r \overline{G(\mathbf{x}, \mathbf{x}_r; \omega)} \hat{r}(\mathbf{x}_r, \omega). \quad (6.2)$$

Duas implementações são possíveis, e a escolha é puramente de custo:

(i) **Integral de espalhamento.** Calcule e armazene $G(\mathbf{x}, \mathbf{x}_r)$ para *cada* receptor — n_r funções de Green — e some. Custo: n_r modelagens por tiro.

(ii) **Estado adjunto.** Reconheça que $\sum_r \overline{G(\mathbf{x}, \mathbf{x}_r)} \hat{r}(\mathbf{x}_r)$ é a *solução de uma única equação de onda* com todos os resíduos como fontes simultâneas. Custo: **1** modelagem por tiro.

A economia é n_r — tipicamente 10^2 a 10^3 . **O método do estado adjunto não é uma aproximação da integral de espalhamento: é a mesma quantidade, avaliada por uma associação mais econômica dos fatores.** A distinção é a mesma entre $(\mathbf{a}^T B) \mathbf{c}$ e $\mathbf{a}^T (B \mathbf{c})$.

6.2 A dedução pelo Lagrangiano, com os termos de fronteira

Dedução completa

Com a restrição $\mathcal{F}(p, m) = m \partial_{tt} p - \nabla^2 p - s = 0$ e condições iniciais nulas,

$$\mathcal{L} = J(p) + \int_{\Omega} \int_0^T \lambda [m \partial_{tt} p - \nabla^2 p - s] dt d\mathbf{x}.$$

Variação em p . Com $J = \frac{1}{2} \iint \sum_r \delta(\mathbf{x} - \mathbf{x}_r) (p - d_{\text{obs}})^2$,

$$\delta \mathcal{L} = \iint \left[\underbrace{\sum_r \delta(\mathbf{x} - \mathbf{x}_r) r}_{\text{de } J} + m \partial_{tt} \lambda - \nabla^2 \lambda \right] \delta p + \mathcal{B}_t + \mathcal{B}_x,$$

onde, após integrar por partes duas vezes em t e aplicar a segunda identidade de Green em $\mathbf{x}$,

$$\mathcal{B}_t = \int_{\Omega} \left[\lambda m \partial_t \delta p - m \partial_t \lambda \delta p \right]_{t=0}^{t=T} d\mathbf{x}, \quad \mathcal{B}_x = - \int_0^T \oint_{\partial \Omega} (\lambda \partial_n \delta p - \delta p \partial_n \lambda) dS dt.$$

$\mathcal{B}_t$. Em $t = 0$ ele se anula porque as condições iniciais são fixas: $\delta p = \partial_t \delta p = 0$. Em $t = T$, δp e $\partial_t \delta p$ são *livres*, logo a única maneira de anular é impor

$$\lambda(\cdot, T) = \partial_t \lambda(\cdot, T) = 0.$$

É daí que vêm as condições finais — não de convenção.

$\mathcal{B}_x$. Anula-se se λ satisfizer, em $\partial\Omega$, a condição **adjunta** à do problema direto. Dirichlet homogênea ($p = 0$) e Neumann homogênea são auto-adjuntas; uma camada absorvente não é (Cap. 4).

Equação adjunta. Anulando o colchete:

$$m \partial_{tt} \lambda - \nabla^2 \lambda = - \sum_r r(t) \delta(\mathbf{x} - \mathbf{x}_r), \quad \lambda(\cdot, T) = \partial_t \lambda(\cdot, T) = 0. \quad (6.3)$$

Gradiente. Sobra o termo explícito em m :

$$\frac{\partial J}{\partial m}(\mathbf{x}) = \int_0^T \lambda(\mathbf{x}, t) \partial_{tt} p(\mathbf{x}, t) dt, \quad (6.4)$$

somado sobre tiros, e com pesos de quadratura $\Delta h^d \Delta t$ na forma discreta.

Por que o operador de onda acústico é auto-adjunto

Compare (6.3) com o problema direto: *mesma* equação. A razão é estrutural: $\partial_{tt}^* = \partial_{tt}$ (duas integrações por partes, dois sinais que se cancelam) e $(\nabla^2)^* = \nabla^2$ com contorno homogêneo. Um operador só com derivadas de ordem *par* é auto-adjunto.

Basta uma derivada *ímpar* para quebrar: $\partial_t^* = -\partial_t$. É o caso do termo dissipativo viscoacústico (Cap. 11), do sistema de primeira ordem velocidade–tensão (em que o adjunto troca o sinal do acoplamento), e da CPML.

6.3 Núcleos de sensibilidade

Substituindo em (6.4) as representações por função de Green de p e de λ , o gradiente escreve-se como uma soma, sobre pares fonte–receptor e frequências, de **núcleos de sensibilidade**

$$K^{sr}(\mathbf{x}, \omega) = \text{Re} \left[\omega^2 \overline{\hat{w}(\omega)} \overline{G(\mathbf{x}, \mathbf{x}_s; \omega)} \overline{G(\mathbf{x}, \mathbf{x}_r; \omega)} \hat{r}(\mathbf{x}_r, \omega) \right], \quad (6.5)$$

com $\hat{w}$ a ondaleta e $\hat{r}$ o resíduo naquele receptor.

Escrevendo $G \sim A e^{i\omega T}$, o produto dos dois conjugados carrega a fase $-\omega[T_s(\mathbf{x}) + T_r(\mathbf{x})]$, e o resíduo carrega $+\omega t$. A fase total de (6.5) é portanto $\omega[t - T_s(\mathbf{x}) - T_r(\mathbf{x})]$ — e é a sua estacionariedade que seleciona a geometria.

A geometria que a fase estacionária impõe

Quando a fase de (6.5) varia rápido com ω , a integral sobre a banda cancela. Sobram os pontos em que ela é *estacionária*, isto é $t \approx T_s(\mathbf{x}) + T_r(\mathbf{x})$ para os tempos t em que o resíduo tem energia. Duas geometrias saem disso:

Isócronas (ondas espalhadas/refletidas). O lugar $T_s(\mathbf{x}) + T_r(\mathbf{x}) = t_{\text{obs}}$ é, em meio homogêneo, uma **elipse** com focos na fonte e no receptor. É o arco que aparece nas figuras de gradiente.

Banana (ondas transmitidas). Para uma chegada direta, a região de fase estacionária é um tubo em torno do raio geométrico, com largura $\sim \sqrt{\lambda L}$ — a **zona de Fresnel**.

O “buraco” no meio da banana. Para um desajuste de tempo de trânsito puro (correlação cruzada), a sensibilidade *anula-se sobre o próprio raio* e é máxima num anel ao redor — o núcleo *banana-doughnut* (Marquering *et al.*, 1999; Tromp *et al.*, 2005). Não é curiosidade: contradiz frontalmente a intuição da teoria de raios, segundo a qual a sensibilidade estaria

concentrada no raio. A resolução finita da FWI é consequência direta desta estrutura — a onda é sensível a um *volume*.




Figura 6.1: Gradiente adjunto calculado pelo código do curso: um tiro (esquerda), sete tiros somados (centro), suavizado (direita). Os arcos são as isócronas previstas pela análise de fase estacionária; a soma sobre tiros é o que colapsa a ambiguidade.

6.4 Decomposição do gradiente: tomográfico e de migração

Duas contribuições com números de onda opostos

A correlação (6.4) soma contribuições de *todos* os pontos onde os dois campos coincidem. Elas se separam naturalmente em duas famílias, com propriedades opostas:

(a) **Contribuição de migração** (ou “de reflexão”). O campo direto *descendo* encontra o campo adjunto *subindo*, num ponto de refletor. O ângulo de espalhamento é próximo de π , e por (1.4) o número de onda impresso é **alto**: o gradiente desenha a *interface*. É, literalmente, a condição de imagem da RTM.

(b) **Contribuição tomográfica**. Os dois campos viajam aproximadamente na *mesma* direção ao longo do trajeto que liga fonte e receptor — ângulo de espalhamento próximo de zero, número de onda **baixo**. O gradiente atualiza o *fundo* de velocidade, ao longo dos “arcos de banana”.

Em um único gradiente as duas estão **superpostas**, e têm amplitudes muito diferentes: a de migração domina, porque as reflexões são eventos bem localizados e de alta frequência.

Por que isso é um problema prático, e não apenas uma taxonomia

O que a FWI mais precisa construir — e não consegue — é o *fundo* de velocidade, a parte de baixo número de onda que preenche a lacuna espectral da §1.3. Essa informação está na contribuição tomográfica (b), que é a mais fraca das duas.

Resultado: com dado dominado por reflexões (aquisição de afastamento curto), o gradiente é essencialmente uma imagem de migração. A inversão acrescenta detalhe de alta frequência sobre um fundo **errado**, e o detalhe fica no lugar errado — com J caindo o tempo todo.

Sintoma reconhecível: o modelo final parece uma migração sobreposta ao modelo inicial, com os refletores nítidos e a tendência de velocidade praticamente intocada.

RWI: separar as duas em vez de somar

A **inversão de forma de onda por reflexão** (RWI, e a família de métodos de análise de velocidade por equação de onda) explora a separação explicitamente. O esquema comum:

1. construa uma *refletividade* a partir do modelo atual (uma migração);
2. gere o campo refletido com essa refletividade, tratando-a como fonte secundária;
3. correlacione o campo *refletido* com o adjunto — o que isola a contribuição (b), tomográfica, porque ambos percorrem o mesmo trajeto descendente;
4. atualize apenas o fundo de velocidade com esse gradiente, mantendo a refletividade fixa; alterne.

O ganho é claro: constrói-se o baixo número de onda a partir de *reflexões*, sem depender de ondas mergulhantes — isto é, sem depender de afastamento longo.

O preço também: a separação entre “fundo” e “refletividade” é uma escolha do usuário (tipicamente um corte de número de onda), e o resultado depende dela. É mais um parâmetro que precisa ser declarado.

6.5 Gradiente multiparâmetro

Para um vetor de parâmetros $\mathbf{p} = (p_1, \dots, p_K)$, o mesmo Lagrangiano dá *um* campo adjunto e K gradientes,

$$\frac{\partial J}{\partial p_k}(\mathbf{x}) = \int_0^T \lambda \frac{\partial \mathcal{A}}{\partial p_k} p \, dt, \quad (6.6)$$

isto é: o custo **não** cresce com o número de parâmetros — só a correlação final é refeita com um operador diferente.

Onde a regra da cadeia costuma ser esquecida

Se o código inverte em $\mathbf{q} = \Phi(\mathbf{p})$ mas propaga em $\mathbf{p}$, o gradiente correto é $\Phi'^T \mathbf{g}_p$ — com a **jacobiana completa**, não termo a termo. Exemplo concreto: num solver elástico parametrizado por (v_p, v_s, ρ) , a densidade entra em λ , em μ e no termo de inércia, de modo que $\partial J / \partial \rho$ tem três contribuições. Manter apenas uma produz um gradiente estável e errado — a assinatura típica de razão constante $\neq 1$ no teste do Capítulo 7.

Um caso instrutivo: em alguns códigos elásticos, o gradiente de v_s sai identicamente nulo quando $v_s = 0$ no modelo. Isso *não* é propriedade do adjunto: é a regra da cadeia, porque $\partial \mu / \partial v_s = 2\rho v_s$ se anula. A distinção importa, porque sugere o conserto certo (reparametrizar) em vez do errado (procurar *bug* no adjunto).

6.6 Adjunto do programa e *checkpointing*

O gradiente (6.4) exige p e λ no mesmo instante, com sentidos de tempo opostos.

Revolve: o ótimo é conhecido

Com n passos de tempo e memória para c estados, o algoritmo *revolve* (Griewank & Walther) atinge o ótimo teórico do compromisso memória×recomputação: com c pontos de controle e r sweeps extras de recomputação, ele cobre

$$n = \binom{c+r}{c}$$

passos. A leitura prática: como o binomial cresce muito rápido, um número *logarítmico* de pontos de controle basta para um fator de recomputação pequeno — tipicamente 2 a 3 modelagens extras.

Consequência em 3D. Um modelo $500 \times 500 \times 300$ com $n_t = 5000$ exigiria $\sim 1,5$ TB por tiro para guardar tudo. Com *revolve* e algumas dezenas de pontos de controle, cai para dezenas de GB ao custo de $\sim 2\times$ em computação. É por isso que todo código de FWI 3D usa *checkpointing*.

E a alternativa que não serve sempre. Reconstruir o campo direto propagando-o ao contrário a partir do estado final custa memória $\mathcal{O}(\text{contorno})$ e é exata *se* o operador for reversível no tempo. Em meio dissipativo **não é**: reverter a dissipação é amplificar, e o erro de arredondamento cresce exponencialmente. Ver §11.3.

O que fica deste capítulo

- Born é F' exatamente (truncar a série de Neumann no 1º termo); estado adjunto é F'^* avaliado com associação econômica; RTM é F'^*r interpretado como imagem.
- As condições finais do adjunto saem do termo de fronteira em $t = T$, e as condições de contorno adjuntas do termo em $\partial\Omega$.
- Fase estacionária dá as isócronas (reflexão), a banana (transmissão) e o buraco central no núcleo de tempo de trânsito.
- Multiparâmetro custa o mesmo em propagação; o que muda é a regra da cadeia — e é onde os erros acontecem.

Problemas

1. Deduza (6.1) partindo de $\mathcal{A}_\omega(m)\hat{u} = \hat{s}$ e mantendo apenas o primeiro termo da série de Neumann. Onde exatamente entra a hipótese de espalhamento fraco?
2. Verifique, a partir de (6.1), que F'^* dado por (6.2) satisfaz $\langle F'\delta m, r \rangle = \langle \delta m, F'^*r \rangle$. Qual propriedade de G é usada?
3. Mostre que, para o operador $m\partial_{tt} - \nabla^2$ com condições homogêneas, o adjunto é ele mesmo. Repita para $m\partial_{tt} + b\partial_t - \nabla^2$ e identifique o que muda.
4. Um código elástico parametrizado em (v_p, v_s, ρ) devolve $\partial J/\partial v_s \equiv 0$ num modelo com $v_s = 0$. Isso é *bug*? Justifique com a regra da cadeia e proponha a reparametrização que evita o problema.

Respostas. (1) O termo descartado é $-\delta m \partial_{tt} \delta u$, de segunda ordem em δm : a hipótese é que a onda espalhada seja pequena diante da incidente ao longo de *todo* o percurso — o que falha em contrastes fortes, e não apenas em contrastes locais. (2) Reciprocidade, $G(\mathbf{x}_r, \mathbf{x}) = G(\mathbf{x}, \mathbf{x}_r)$; sem ela, o adjunto exigiria uma função de Green distinta e a retropropagação a partir dos receptores não seria legítima. (3) $\partial_{tt}^* = \partial_{tt}$ e $(\nabla^2)^* = \nabla^2$; com o termo $b\partial_t$, como $\partial_t^* = -\partial_t$, o adjunto é $m\partial_{tt} - b\partial_t - \nabla^2$ — que, na variável revertida $\tau = T - t$, volta a ser

dissipativo. (4) Não é *bug*: $\partial\mu/\partial v_s = 2\rho v_s$ anula-se em $v_s = 0$, de modo que o zero vem da regra da cadeia, não do adjunto. Parametrizar em μ (ou em $I_s = \rho v_s$) mantém sensibilidade não nula.

Capítulo 7

Verificação

A ideia deste capítulo, em uma frase

Há dois testes independentes, e eles verificam coisas diferentes: o teste do produto escalar verifica que o *adjunto* está correto; o teste de Taylor verifica que a *linearização* está correta. Passar num não implica passar no outro.

Antes de usar: o teste do produto escalar

Se $A : \mathcal{H}_1 \rightarrow \mathcal{H}_2$ é linear e A^* é o seu adjunto, então, por definição,

$$\langle Au, v \rangle_{\mathcal{H}_2} = \langle u, A^*v \rangle_{\mathcal{H}_1} \quad \text{para todos } u, v.$$

Isso dá um teste numérico **exato** (até arredondamento): sorteie u e v aleatórios, calcule os dois lados, compare.

Três propriedades tornam este teste valioso:

1. **Não há parâmetro a escolher.** Diferente do teste de Taylor, não existe α a calibrar nem regime assintótico a atingir. A igualdade vale exatamente.
2. **A tolerância é a precisão de máquina.** Em `float64`, discrepância relativa acima de $\sim 10^{-12}$ é *bug*, ponto final.
3. **Vetores aleatórios são a escolha certa aqui** — ao contrário do teste de Taylor, onde uma direção aleatória é ruim. A razão: aqui queremos excitar *todos* os modos, e um vetor aleatório tem componente em todos com probabilidade 1.

7.1 Os quatro testes, e o que cada um pega

Teste	Verifica	Não pega
Produto escalar	que o operador implementado como “adjunto” é de fato o adjunto do implementado como “direto”	se o “direto” é a linearização certa de F
Taylor	que $\mathbf{g}$ é a derivada de Fréchet do J que o código avalia	erro de escala comum a J e $\mathbf{g}$
Direcional	o mesmo, num número só; é o teste do dia a dia	ruído numérico confunde
Pontual	onde está o erro	nada, isoladamente

Protocolo completo para um código novo

1. **Produto escalar** no par (modelagem de Born, migração). Deve fechar em precisão de máquina. *Antes* de qualquer teste de gradiente.
2. **Taylor** em J : $E_1 \sim \mathcal{O}(\alpha^2)$.
3. **Direcional** com 5–6 valores de α em duas ordens de grandeza; razão estável em 1.
4. **Refinamento**: repita com Δt e Δh menores. Se a razão se aproxima de 1, o desvio era discrepância contínuo/discreto (§3.4); se não muda, é *bug*.
5. **Multiparâmetro**: repita o direcional com $\mathbf{h}$ ativo em *um* parâmetro de cada vez, e depois em combinação. Erros de regra da cadeia só aparecem no segundo caso.

7.2 Os números de um caso real

Teste de Taylor no propagador do curso:

α	E_0	E_1	ordem E_0	ordem E_1
0,4	$2,285 \times 10^{-6}$	$4,578 \times 10^{-7}$	—	—
0,2	$1,028 \times 10^{-6}$	$1,146 \times 10^{-7}$	1,15	2,00
0,1	$4,855 \times 10^{-7}$	$2,867 \times 10^{-8}$	1,08	2,00
0,05	$2,355 \times 10^{-7}$	$7,116 \times 10^{-9}$	1,04	2,01
0,025	$1,160 \times 10^{-7}$	$1,756 \times 10^{-9}$	1,02	2,02

E o caso em que ele *reprovou*: razão direcional 0,9118, estável em todos os α ao longo de uma faixa de $40\times$. Estabilidade descarta ruído; o teste pontual localizou a região (razão 0,99 no miolo, 0,72 perto da superfície). A causa: o operador de extensão do modelo para a moldura, E , aplicado no caminho de ida sem o correspondente E^T na volta.

A regra geral, na forma precisa

Se o que é propagado é $\tilde{\mathbf{m}} = E \mathbf{m}$ para um operador linear E qualquer — extensão de bordas, interpolação entre malhas, suavização, mudança de base, conversão de unidade — então

$$\nabla_{\mathbf{m}} J = E^T \nabla_{\tilde{\mathbf{m}}} J.$$

E^T de uma *replicação* é uma *soma*; E^T de uma *interpolação* é um *espalhamento*; E^T de um recorte é um preenchimento com zeros. Trocar E^T pelo inverso “intuitivo” da operação (recortar no lugar de somar) é o erro canônico, e produz exatamente o sintoma acima.

O que fica deste capítulo

- O teste do produto escalar verifica o *adjunto* e fecha em precisão de máquina; o de Taylor verifica a *linearização*. Passar num não implica passar no outro.
- Vetores aleatórios são certos no teste do produto escalar e errados no direcional (onde a direção deve ser suave).
- Refinar $\Delta t, \Delta h$ separa discrepância contínuo/discreto (encolhe) de *bug* (não encolhe).
- $\nabla_{\mathbf{m}} J = E^T \nabla_{\tilde{\mathbf{m}}} J$ para todo pré-processamento linear E — e E^T de uma replicação é uma soma, não um recorte.




Figura 7.1: Esquerda: teste de Taylor em log-log com as retas de referência de inclinação 1 e 2. Direita: razão da derivada direcional, faixa verde de $\pm 2\%$.

Problemas

1. Mostre que, se o operador “direto” implementado é A e o “adjunto” implementado é $B \neq A^*$, o teste de Taylor ainda pode passar com razão 1 para uma direção particular $\mathbf{h}$. Qual propriedade de $\mathbf{h}$ torna isso possível, e por que o teste do produto escalar com vetores aleatórios não tem esse ponto cego?
2. Um código aplica suavização gaussiana S ao modelo antes de propagar, e aplica S também ao gradiente. Isso está certo? Sob qual condição?
3. O teste direcional dá razão 0,5000 em todos os α . Aponte os dois *bugs* mais prováveis.

Respostas. (1) Se $\mathbf{h}$ pertencer ao subespaço em que B e A^* coincidem — típico quando o erro está confinado a uma região (bordas, moldura) e $\mathbf{h}$ tem pouca energia ali. Um vetor aleatório tem componente em todos os modos com probabilidade 1, e por isso não tem esse ponto cego. (2) Certo *porque* o núcleo gaussiano é simétrico, logo $S^T = S$; se o filtro fosse assimétrico (causal, por exemplo) seria errado. Aplicar por acaso a operação certa não é o mesmo que aplicar o adjunto. (3) Fator 2: ou a diferença centrada foi implementada com 2α onde devia ser α (ou vice-versa), ou o funcional foi definido com $\frac{1}{2}\|r\|^2$ e o gradiente derivado de $\|r\|^2$.

Capítulo 8

Otimização de segunda ordem e a Hessiana

A ideia deste capítulo, em uma frase

A Hessiana de FWI não pode ser formada, mas pode ser *aplicada* a um vetor pelo custo de duas modelagens adicionais. Isso basta para métodos de Newton truncado — e, de quebra, dá a ferramenta quantitativa para análise de resolução e para diagnosticar *crosstalk*.

Antes de usar: métodos de Krylov e por que “aplicar” basta

A observação central. Para resolver $H\delta = -\mathbf{g}$, o método dos gradientes conjugados nunca acessa H elemento a elemento: ele só precisa de produtos $H\mathbf{v}$. O mesmo vale para GMRES, Lanczos, e para estimativa de autovalores.

Formalmente, após k iterações o CG minimiza a forma quadrática sobre o **subespaço de Krylov**

$$\mathcal{K}_k = \text{span}\{\mathbf{g}, H\mathbf{g}, H^2\mathbf{g}, \dots, H^{k-1}\mathbf{g}\},$$

que é construído apenas com aplicações sucessivas.

Por que isso muda tudo em FWI. H tem $N^2 \sim 10^{12}$ entradas — impossível. Mas $H\mathbf{v}$, como veremos, custa duas modelagens. Com 5 a 15 iterações de CG por passo de Newton, isso é comparável ao custo de algumas iterações de l-BFGS — e entrega curvatura *exata* em vez de estimada por histórico.

Truncamento e curvatura negativa. Como J não é convexa, H pode ter autovalores negativos, e o CG falha nesse caso. Duas saídas padrão: parar o CG assim que detectar $\mathbf{v}^T H\mathbf{v} \leq 0$ (e usar a direção acumulada até ali, que ainda é de descida); ou usar a Hessiana de Gauss–Newton, que é semidefinida positiva por construção. O primeiro é “Newton truncado”; o segundo, “Gauss–Newton truncado”.

8.1 Estrutura da Hessiana

Com $J = \frac{1}{2}\|\mathbf{r}(\mathbf{m})\|^2$ e $J' = \partial\mathbf{r}/\partial\mathbf{m} = F'$:

$$\mathbf{g} = F'^*\mathbf{r}, \quad H = \underbrace{F'^*F'}_{H_1 = H_{\text{GN}}} + \underbrace{\sum_i r_i \nabla^2 r_i}_{H_2}. \quad (8.1)$$

O que cada bloco significa fisicamente

$H_1 = F'^* F'$ (**Gauss–Newton**). É o operador *migração o modelagem de Born*. Na diagonal, a **iluminação** de cada ponto; fora da diagonal, o quanto uma perturbação num ponto *imita* o efeito de uma perturbação em outro — ou seja, a **ambiguidade geométrica** do experimento. Em multiparâmetro, os blocos fora da diagonal entre parâmetros são literalmente o *crosstalk* (Cap. 11).

Inverter H_1 corrige dois defeitos de uma vez: reequilibra a iluminação (diagonal) e **desfoca** a imagem (fora da diagonal) — é por isso que Gauss–Newton produz modelos visivelmente mais nítidos que gradiente puro, e não apenas mais rápidos.

H_2 (**termo de segunda ordem**). Contém a informação sobre **espalhamento múltiplo**: é o que distingue “uma reflexão de segunda ordem” de “uma interface nova mais profunda”. Ele é pequeno quando os resíduos são pequenos (por isso Gauss–Newton fica bom perto da convergência) e *não* é pequeno no início, nem em presença de múltiplas fortes — onde justamente ele seria mais útil. Ignorá-lo é defensável; ignorar que se ignorou, não.

8.2 Produto Hessiana–vetor pelo adjunto de segunda ordem

Quatro propagações, e o gradiente já pagou duas

Aplicar H a uma direção δm equivale a derivar o gradiente na direção δm . Diferenciando o sistema (estado, adjunto, gradiente) obtém-se quatro problemas em cascata:

1. **Estado:** $\mathcal{A}(m)p = s$ (já calculado para **g**)
2. **Adjunto:** $\mathcal{A}^* \lambda = -R^* \mathbf{r}$ (já calculado para **g**)
3. **Tangente linear** (Born): $\mathcal{A}(m) \delta p = -\delta m \partial_{tt} p$ (*nova*)
4. **Adjunto de segunda ordem:** $\mathcal{A}^* \delta \lambda = -R^* R \delta p - \delta m \partial_{tt} \lambda$ (*nova*)

e então

$$[H \delta m](\mathbf{x}) = \int_0^T \left[\lambda \partial_{tt} \delta p + \delta \lambda \partial_{tt} p \right] dt. \quad (8.2)$$

O primeiro termo do lado direito de (4) gera H_1 ; o segundo gera H_2 . **Omitir o termo $-\delta m \partial_{tt} \lambda$ em (4) produz exatamente H_{GN}** — uma linha de código separa os dois métodos, o que é conveniente e também uma fonte de confusão na literatura.

Custo: 2 propagações adicionais por produto, por tiro. Com k iterações de CG por passo de Newton, o passo custa $\sim 2(1+k)$ propagações por tiro.

8.3 Função de espalhamento de ponto e resolução

Medindo resolução sem conhecer a resposta

Aplicar H_{GN} a uma perturbação pontual $\delta_{\mathbf{x}_0}$: o resultado $H_{\text{GN}} \delta_{\mathbf{x}_0}$ é a coluna de H_{GN} em $\mathbf{x}_0$, conhecida como **função de espalhamento de ponto** (PSF).

Ela responde, quantitativamente: *se houvesse uma anomalia pontual aqui, como ela apareceria na inversão linearizada?* A largura da PSF é a resolução local; a sua orientação revela a direção preferencial de iluminação; a sua amplitude revela zonas cegas.

Três propriedades tornam a PSF a ferramenta certa:

- é calculável com o *modelo estimado*, sem conhecer a verdade — portanto serve em dado real;
- respeita a física e a geometria reais (ao contrário de testes de “tabuleiro de xadrez”, que dependem do padrão escolhido);
- custa 2 propagações por tiro por ponto avaliado, o que permite mapear a resolução em alguns pontos-chave a custo modesto.

Ela é também a confirmação empírica da análise de §1.3: a transformada de Fourier da PSF é, essencialmente, a cobertura de $\mathbf{k}_m$ naquele ponto.

8.4 Pré-condicionamento, revisitado

O pseudo-Hessiano de Shin *et al.* aproxima $\text{diag}(H_{\text{GN}})$ pela energia do campo direto:

$$P_{ii}^{-1} \approx \int_0^T [\partial_{tt} p(\mathbf{x}_i, t)]^2 dt + \epsilon. \quad (8.3)$$

O que essa aproximação descarta, exatamente

Duas coisas, e vale saber quais. **(1)** Os termos fora da diagonal — isto é, o desfoque; a correção é só de iluminação, não de resolução. **(2)** A propagação de cada ponto *até os receptores*: a diagonal exata de $F'^* F'$ envolve também $|G(\mathbf{x}_r, \mathbf{x})|^2$, que o pseudo-Hessiano ignora.

Ainda assim é o pré-condicionador padrão, porque custa zero (o campo direto já está lá) e captura o efeito dominante, que é o decaimento geométrico com a profundidade. Medido no curso: razão de iluminação raso/profundo de $181\times$.

Efeito medido (correlação do gradiente com a perturbação verdadeira): bruto $+0,0390$; mascarado $+0,0830$; mascarado e suavizado $+0,0842$; com compensação de profundidade $+0,0898$. Os valores absolutos são baixos porque um gradiente *não é* o modelo — ele é $F'^* r$, espalhado nas isócronas, e só $H^{-1} F'^* r$ seria uma estimativa do modelo. O que importa é a razão relativa: o tratamento mais que dobra a correlação.

8.5 Otimização estocástica e codificação de fontes

Dois jeitos de não pagar por todos os tiros

Subconjunto aleatório. Sorteie $n_{\text{sub}} \ll n_s$ tiros por iteração. O gradiente resultante é um *estimador não viesado* do gradiente completo: $\mathbb{E}[\mathbf{g}_{\text{sub}}] = \mathbf{g}$. A teoria de aproximação estocástica garante convergência sob passos decrescentes; na prática usa-se n_{sub} crescente ao longo das iterações (*sample size scheduling*), começando barato e terminando preciso.

Codificação de fontes (*source encoding*). Some todos os tiros em um único “supertiro”, cada um multiplicado por um peso aleatório ε_s (sinal ± 1 , ou fase aleatória). Como $\mathbb{E}[\varepsilon_s \varepsilon_{s'}] = \delta_{ss'}$, os termos cruzados têm média zero e o gradiente do supertiro é não viesado. O custo cai por um fator n_s .

O preço, em ambos: os termos cruzados não são zero em cada realização — são ruído de

crosstalk que decai como $1/\sqrt{n_{\text{real}}}$. E a codificação exige que todos os tiros compartilhem a mesma geometria de receptores (aquisição fixa), o que exclui boa parte do dado marinho rebocado sem re-datumação.

O que fica deste capítulo

- $H = F'^*F' + \sum_i r_i \nabla^2 r_i$: o primeiro bloco é iluminação + desfoque, o segundo é espalhamento múltiplo.
- $H\mathbf{v}$ custa 2 propagações extras (adjunto de segunda ordem); com Krylov, isso basta para Newton truncado.
- A PSF mede resolução local sem conhecer a verdade, e é a verificação empírica da cobertura de $\mathbf{k}_m$.
- Estimadores estocásticos são não viesados; o preço é ruído de *crosstalk* $\propto 1/\sqrt{n_{\text{real}}}$.

Problemas

1. Mostre que $H_{\text{GN}} = F'^*F'$ é semidefinida positiva, e explique por que isso garante que a direção de Gauss–Newton seja de descida (quando o sistema é resolvido exatamente).
2. Estime o custo, em modelagens por tiro, de um passo de Gauss–Newton truncado com 8 iterações de CG, e compare com 8 iterações de l-BFGS supondo busca linear de 2 avaliações.
3. A PSF num ponto profundo sai alongada na vertical. Que propriedade da aquisição isso revela, e por que (1.4) já permitia prevê-lo?
4. Com codificação de fontes, o ruído de *crosstalk* decai como $1/\sqrt{n_{\text{real}}}$. Quantas realizações seriam necessárias para que ele caia 20 dB abaixo do nível inicial? Compare esse custo com o de inverter os tiros individualmente.

Respostas. (1) $\mathbf{v}^T F'^*F'\mathbf{v} = \|F'\mathbf{v}\|^2 \geq 0$; com H_{GN} positiva definida, $\langle \mathbf{g}, -H_{\text{GN}}^{-1}\mathbf{g} \rangle < 0$. (2) Gauss–Newton truncado: 2 (gradiente) + 2×8 (produtos $H\mathbf{v}$) = 18 modelagens por tiro, mais a busca linear, para *um* passo; l-BFGS: $8 \times (2 + 2) = 32$ para 8 passos, busca linear já incluída. A comparação justa depende de quantos passos de l-BFGS equivalem a um de Newton — que é precisamente o que se mede, e depende do condicionamento. (3) Iluminação predominantemente vertical, isto é, ângulos de espalhamento concentrados perto de π : por (1.4) os $\mathbf{k}_m$ disponíveis apontam quase todos na vertical, e a resolução horizontal fica pobre — a PSF alonga na direção *não* coberta. (4) 20 dB é um fator 10 em amplitude, logo $n_{\text{real}} = 100$. Isso só compensa se $n_s \gg 100$; abaixo disso, inverter os tiros separadamente é mais barato e sem viés.

Capítulo 9

Fluxo completo, escalabilidade e reprodutibilidade

A ideia deste capítulo, em uma frase

Em escala de produção, as decisões que determinam o resultado são de engenharia: qual domínio, quais frequências, quanta memória, qual paralelismo. Todas têm uma justificativa teórica — e a mais elegante delas sai diretamente da cobertura de número de onda do Capítulo 1.

Antes de usar: custo de resolver a mesma EDP de dois jeitos

A escolha entre domínio do tempo e da frequência não é de gosto: é uma conta de álgebra linear.

No tempo, a marcha é *explícita*: cada passo é um produto matriz esparsa–vetor, $\mathcal{O}(N)$ operações, sem resolver sistema algum. O custo total é $\mathcal{O}(n_t N)$ por tiro, e a memória é $\mathcal{O}(N)$ — mais o *checkpointing*.

Na frequência, cada ω exige resolver $\mathcal{A}_\omega \hat{u} = \hat{s}$, um sistema linear esparso. Com fatoração direta (LU), paga-se caro *uma vez* e cada tiro adicional custa apenas uma substituição — $\mathcal{O}(N)$. **Com muitos tiros, o custo por tiro tende a zero.** Essa é a vantagem estrutural do domínio da frequência.

Por que ela desaparece em 3D. O custo e a memória de uma fatoração esparsa dependem do *preenchimento* (*fill-in*) dos fatores, que por sua vez depende da estrutura do grafo da matriz. Em 2D, uma boa ordenação (dissecção aninhada) mantém o preenchimento modesto. Em 3D o separador de um cubo n^3 é uma *superfície* n^2 , e a memória dos fatores cresce como $\mathcal{O}(n^4)$: para $n = 500$ isso é muitos terabytes.

Daí a divisão prática: frequência em 2D com muitos tiros, tempo em 3D.

9.1 Domínio do tempo *versus* domínio da frequência

	Tempo	Frequência
Como resolve	marcha explícita em n_t passos	sistema linear esparsa por ω
Custo por tiro	$\mathcal{O}(n_t N)$	fatoração LU reaproveitada por <i>todos</i> os tiros
Memória	campo + <i>checkpointing</i>	fatores LU — cresce muito rápido em 3D
Multiescala	filtrar o dado	escolher as frequências
Atenuação	operadores fracionários ou SLS	trivial: Q complexo na velocidade
Onde domina	3D	2D com muitos tiros

Por que poucas frequências discretas podem bastar

Esta é uma das consequências mais bonitas de (1.4), e a justificativa da estratégia de Sirgue & Pratt.

Um *único* ω , combinado com *toda* a faixa de ângulos de espalhamento disponível $[\theta_{\min}, \theta_{\max}]$, já cobre uma **faixa contínua** de números de onda:

$$|\mathbf{k}_m| \in \left[\frac{2\omega}{c} \sin \frac{\theta_{\min}}{2}, \frac{2\omega}{c} \sin \frac{\theta_{\max}}{2} \right].$$

Há, portanto, **redundância** entre frequência e ângulo: um dado $|\mathbf{k}_m|$ pode ser alcançado por muitos pares (ω, θ) . Inverter todas as frequências é desperdiçar essa redundância.

A estratégia é escolher $\omega_1 < \omega_2 < \dots$ de modo que as faixas cobertas se *encostem* sem lacuna:

$$\frac{2\omega_{j+1}}{c} \sin \frac{\theta_{\min}}{2} \leq \frac{2\omega_j}{c} \sin \frac{\theta_{\max}}{2} \implies \frac{\omega_{j+1}}{\omega_j} \leq \frac{\sin(\theta_{\max}/2)}{\sin(\theta_{\min}/2)}.$$

O espaçamento é **geométrico**, e o passo depende só da *abertura angular*. Aquisição de abertura larga permite passos maiores — menos frequências, menos custo. É o mesmo compromisso frequência↔abertura de §1.3, agora como regra de projeto.

9.2 O fluxo, e a ordem que não muda

```

1  # --- antes de qualquer inversao ---
2  1. preparar dado (direta, multiplas, 2.5D se for o caso, wavelet)
3  2. modelo inicial + caixa de velocidades fisicamente plausivel
4  3. dimensionar dh, dt, moldura (Caps. 3, 4)
5  4. TESTE DO PRODUTO ESCALAR no par Born/migracao (Cap. 7)
6  5. TESTE DE TAYLOR no gradiente (Cap. 7)
7
8  # --- multiescala ---
9  6. para cada banda (ou grupo de frequencias):
10     reestimar a wavelet por projecao variavel (Cap. 2)
11     reiniciar o historico do quase-Newton
12     iterar: gradiente -> preconditionar -> direcao -> busca
13             -> projetar na caixa (Caps. 6, 8, 10)
14
15  # --- depois ---
16  7. PSF em pontos-chave: mapa de resolucao (Cap. 8)
17  8. analise de residuo; relatorio com erro INICIAL (Cap. 12)

```

9.3 Resultados medidos, e o fracasso que não parece fracasso

Estudo de robustez do curso: quatro modelos iniciais, monoescala (25 Hz) contra multiescala (5/12/25 Hz), mesmo número total de iterações.

Modelo inicial	erro ini.	mono	multi	vantagem
linear suave	7,96%	7,34%	7,07%	+0,27 pp
linear lento (viesado)	16,68%	17,57%	17,34%	+0,24 pp
constante	16,32%	16,10%	16,06%	+0,04 pp
suavizado forte	4,95%	4,01%	3,70%	+0,31 pp

Leia a segunda linha

Erro inicial 16,68%, erro final 17,57%: **a inversão piorou o modelo**, com J caindo monotonicamente o tempo todo. Ela convergiu para um mínimo local e, no caminho, destruiu informação que já se tinha.

Em termos da §1.3: um erro de $\sim 16\%$ com $c \approx 2300$ m/s e percursos de 1–2 km fica na borda ou fora do vale de atração *já a 5 Hz* — e aí nenhuma ordem de bandas resgata. A vantagem da multiescala *não* cresceu com a degradação do inicial, contrariando a expectativa comum, porque ela só resgata o que a banda mais baixa alcança.

Nota metodológica: sem reportar o erro inicial, essa linha seria indistinguível de um sucesso.

9.4 Reprodutibilidade

O mínimo para que um resultado de FWI seja verificável

- **Modelo inicial**, com o seu erro relativo — e como ele foi obtido;
- **banda por estágio**, tipo e ordem do filtro, e se ele foi aplicado aos dois lados;
- **discretização**: Δh , Δt , ordem, G resultante, tipo e espessura da moldura;
- **resultado do teste de gradiente**, com o número;
- **regularização**: forma, peso, e *como o peso foi escolhido* (curva em L? erro de modelo? — se foi o segundo, dizer);
- **tratamento do gradiente**: máscaras, suavização, pré-condicionador;
- **critério de parada**, e número de modelagens gasto;
- **curva de convergência com eixo de custo**, perfis, mapa de erro, e o **resíduo final** (não só o valor de J).

Um trabalho que omite o erro do modelo inicial não permite avaliar se a inversão agregou alguma coisa.

O que fica deste capítulo

- Tempo escala bem em 3D; frequência amortiza a fatoração entre tiros e domina em 2D — o divisor de águas é o preenchimento dos fatores.

- Redundância entre ω e θ em (1.4) justifica inverter *poucas* frequências, com espaçamento geométrico ditado pela abertura angular.
- A ordem do fluxo é rígida em um ponto: verificação de gradiente antes da primeira inversão.
- Um relatório sem o erro do modelo inicial não permite avaliar se a inversão agregou informação — e o estudo de robustez mostra um caso em que ela *destruiu*.

Capítulo 10

Regularização, priors e inferência

A ideia deste capítulo, em uma frase

Toda regularização é um prior disfarçado, e reconhecer isso muda o que se pode afirmar sobre o resultado. A formulação bayesiana dá, de graça, a interpretação dos pesos e uma estimativa de incerteza — válida, e vale entender exatamente até onde.

Antes de usar: Bayes, MAP e a aproximação de Laplace

Bayes. Com $\mathbf{m}$ os parâmetros e $\mathbf{d}$ o dado,

$$\underbrace{\pi(\mathbf{m} | \mathbf{d})}_{\text{posterior}} \propto \underbrace{\pi(\mathbf{d} | \mathbf{m})}_{\text{verossimilhança}} \underbrace{\pi(\mathbf{m})}_{\text{prior}}.$$

Verossimilhança gaussiana. Se o ruído é gaussiano de covariância C_d , $-\log \pi(\mathbf{d} | \mathbf{m}) = \frac{1}{2} \|F(\mathbf{m}) - \mathbf{d}\|_{C_d^{-1}}^2 + \text{const}$, onde $\|v\|_{C_d^{-1}}^2 = v^T C_d^{-1} v$. O L_2 simples da Parte II é o caso $C_d = \sigma^2 I$: ruído branco, mesma variância em todo traço e todo instante — hipótese quase nunca verdadeira e quase nunca declarada.

Prior gaussiano. Com $\pi(\mathbf{m}) \propto \exp[-\frac{1}{2} \|\mathbf{m} - \mathbf{m}_{\text{pr}}\|_{C_m^{-1}}^2]$,

$$-\log \pi(\mathbf{m} | \mathbf{d}) = \frac{1}{2} \|F(\mathbf{m}) - \mathbf{d}\|_{C_d^{-1}}^2 + \frac{1}{2} \|\mathbf{m} - \mathbf{m}_{\text{pr}}\|_{C_m^{-1}}^2 + \text{const}.$$

Maximizar o posterior (estimativa **MAP**) é *exatamente* minimizar o funcional regularizado. Portanto:

escolher R e λ é escolher um prior, queira-se ou não.

Aproximação de Laplace. Expandindo $-\log \pi$ em torno do MAP até segunda ordem, o posterior é aproximado por uma gaussiana com

$$C_{\text{post}} \approx H_{\text{MAP}}^{-1}, \quad H_{\text{MAP}} = F'^* C_d^{-1} F' + C_m^{-1} + (\text{termo de 2ª ordem}).$$

A Hessiana é a covariância a posteriori inversa. É a mesma matriz do Capítulo 8, agora com leitura estatística: direção de autovalor grande = bem determinada; autovalor pequeno = o dado não disse nada, e o prior é quem responde.

10.1 Tradução: regularizador $\leftrightarrow$ prior

Regularizador	Prior equivalente	Afirmação implícita
$\frac{\lambda}{2} \ \mathbf{m} - \mathbf{m}_{\text{pr}}\ ^2$	gaussiano, $C_m^{-1} = \lambda I$	“desvios do prior são pequenos e independentes”
$\frac{\lambda}{2} \int \nabla m ^2$ (Tikhonov)	gaussiano com $C_m^{-1} = \lambda D^T D$	“o modelo é suave”
$\lambda \int \nabla m $ (TV)	laplaciano nos gradientes	“o modelo é constante por pedaços”
caixa $v \in [v_{\min}, v_{\max}]$	prior uniforme com suporte compacto	“fora disso é impossível”
parada antecipada	prior implícito, dependente do otimizador	— (não controlável)

A última linha é a mais perigosa

Parada antecipada é regularização: ela restringe a solução ao subespaço de Krylov percorrido até ali, tipicamente as direções de maior autovalor de H — isto é, as escalas grandes. O efeito é real e frequentemente benéfico.

O problema é que esse prior **não é declarável, não é reprodutível e depende do otimizador**: trocar l-BFGS por gradiente conjugado muda a regularização efetiva sem que ninguém anote. É a razão pela qual o critério de parada deve entrar no relatório junto com λ .

10.2 A curva em L, e o resultado que contraria a expectativa

Calibre λ por $\lambda = \eta J_{\text{dados}}(\mathbf{m}_0)/R(\mathbf{m}_0)$ com $\eta \approx 0,02$, e refine pelo cotovelo da curva em L (ajuste *versus* penalidade, ambos em log).




Figura 10.1: Curva em L medida no curso. O cotovelo é o ponto a partir do qual se passa a pagar ajuste por suavidade.

Experimento do curso com relação sinal/ruído de 0 dB:

Variante	Erro final	Correlação
modelo inicial	4,75%	0,9554
sem regularização	3,60%	0,9699
Tikhonov	4,42%	0,9595
TV	4,39%	0,9613
só suavização do gradiente	3,56%	0,9709

A leitura bayesiana do resultado

A regularização explícita *piorou*. Na linguagem deste capítulo: o prior estava **errado para este problema**.

O erro residual não era rugosidade — era falta de *contraste*, isto é, amplitude insuficiente nos degraus. Um prior de suavidade penaliza exatamente a quantidade que ainda faltava construir. Somando a isso os priors *implícitos* já presentes (modelo inicial suave, poucas iterações, bandas baixas, suavização do gradiente), o posterior ficou dominado pelo prior, e o dado deixou de mandar.

Sobre-regularização é um diagnóstico, não uma opinião: se afrouxar λ melhora simultaneamente J_{dados} e o erro de modelo, o prior estava apertado demais.

10.3 O que é honesto dizer sobre incerteza em FWI

A aproximação de Laplace é local, e essa é a limitação decisiva

$C_{\text{post}} \approx H^{-1}$ descreve a curvatura em torno de *um* mínimo. Ela quantifica corretamente:

- quais direções do modelo o dado restringe e quais não — autovalores pequenos de H são o espaço nulo prático;
- como o ruído do dado se propaga para o modelo, *dado* que estamos na bacia certa.

E **não** quantifica, de forma nenhuma:

- a probabilidade de estarmos na bacia *errada* — que é, na prática, a maior fonte de erro em FWI;
- erro de modelagem (física faltante), que é determinístico e coerente, não ruído;
- erro na ondaleta da fonte, a menos que ela entre como parâmetro.

Uma barra de erro derivada de H^{-1} é portanto uma afirmação **condicional**: “supondo que o mínimo encontrado é o certo, e que a física está certa, a incerteza é esta”. Reportá-la sem esse condicional é enganoso, e é comum.

O que se faz na prática, em ordem de custo

1. **PSF** em pontos-chave (Cap. 8): resolução local, barato, e não exige conhecer a verdade.
2. **Autovetores dominantes de H** por Lanczos ou SVD aleatorizada, usando os produtos $H\mathbf{v}$ do adjunto de segunda ordem. Em problemas de FWI o espectro de $F'^*C_d^{-1}F'$ decai rápido, de modo que uma aproximação de posto baixo captura bem C_{post} — é o que torna a UQ bayesiana viável apesar do tamanho.
3. **Ensemble de inversões**: varie modelo inicial, banda inicial, λ , subconjunto de tiros. A dispersão entre os resultados amostra justamente o que H^{-1} *não* captura — inclusive bacias diferentes. É caro e é o único diagnóstico honesto sobre mínimos locais.
4. **Passeios pelo espaço nulo**: perturbe o modelo final ao longo de direções de autovalor pequeno e verifique que o dado praticamente não muda. Isso exhibe *explicitamente* modelos alternativos que explicam o dado igualmente bem.
5. **MCMC** em FWI de escala real: inviável hoje. Resultados existentes são 2D, de baixa dimensão (modelo reparametrizado com poucas dezenas a poucos milhares de parâme-

tros) ou com substitutos (*surrogates*). Trate afirmações de “UQ completa” em 3D com ceticismo, e pergunte qual era a dimensão efetiva.

O que fica deste capítulo

- MAP = mínimos quadrados regularizados: escolher R e λ é escolher um prior.
- $C_{\text{post}} \approx H^{-1}$ — a Hessiana da otimização é a precisão a posteriori.
- Priors implícitos (parada antecipada, modelo inicial, multiescala) frequentemente dominam o explícito.
- Incerteza de Laplace é condicional à bacia e à física; o único diagnóstico honesto sobre mínimos locais é o ensemble.

Parte III — Os limites

Capítulo 11

Multiparâmetro, atenuação e anisotropia

A ideia deste capítulo, em uma frase

Em inversão multiparâmetro, o obstáculo não é calcular gradientes — isso custa o mesmo. O obstáculo é que os blocos fora da diagonal da Hessiana não são desprezíveis, e o algoritmo atribui ao parâmetro errado um efeito que pertencia a outro.

11.1 *Crosstalk*, definido com precisão

O que *crosstalk* é

Com dois parâmetros (p_1, p_2) , a Hessiana de Gauss–Newton tem estrutura de blocos

$$H_{\text{GN}} = \begin{pmatrix} F_1'^* F_1' & F_1'^* F_2' \\ F_2'^* F_1' & F_2'^* F_2' \end{pmatrix},$$

com $F_k' = \partial F / \partial p_k$. O passo de Gauss–Newton exige inverter essa matriz *inteira*.

O gradiente, por si, ignora os blocos fora da diagonal: ele atribui a p_1 toda a variação de dado compatível com F_1' , inclusive a parcela causada de fato por p_2 . ***Crosstalk* é precisamente a magnitude relativa de $F_1'^* F_2'$** — e o produto interno $\langle F_1' \delta p_1, F_2' \delta p_2 \rangle$ mede o quanto os dois parâmetros produzem dado parecido.

Consequências, todas verificáveis:

- se os padrões de radiação dos dois parâmetros forem *ortogonais* na faixa angular *iluminada*, o bloco cruzado é pequeno e o *crosstalk* é baixo;
- se a aquisição não cobrir os ângulos que separam os dois, nenhum algoritmo os separa — é limitação de *dado*, não de método;
- reparametrizar (§2.2) é literalmente aplicar uma congruência $\Phi'^T H \Phi'$ escolhida para reduzir os blocos cruzados.

Do Capítulo 2, para o caso acústico com densidade:

$$f(\theta) \propto \frac{\delta I_p}{I_p} (\cos \theta - 1) - \frac{\delta c}{c} (1 + \cos \theta),$$

padrões complementares — é *por isso* que (I_p, c) tem menos *crosstalk* que (κ, ρ) . A escolha de

parametrização é a principal ferramenta contra *crosstalk*, e ela é grátis.

A ambiguidade em números

Meio 1	Meio 2	R
$c = 2000, \rho = 2,00$	$c = 2400, \rho = 2,00$	+0,0909
$c = 2000, \rho = 2,00$	$c = 2000, \rho = 2,40$	+0,0909
$c = 2000, \rho = 2,00$	$c = 2400, \rho = 1,67$	+0,0010

As duas primeiras linhas produzem reflexão idêntica em incidência normal por causas diferentes; a terceira produz reflexão praticamente nula com 20% de contraste em velocidade. **Em incidência normal, $\theta = \pi$, e apenas I_p radia** — exatamente o que (2.6) prevê. Separar c de ρ exige ângulos intermediários, isto é, afastamento.

11.2 Extensões da física: o que cada uma custa

Extensão	Parâmetros	Custo	Resolve
Acústica	v_p	1×	cinemática P
Acústica + ρ	v_p, ρ	1×	amplitude de reflexão
Viscoacústica	v_p, Q	2–4×	dissipação e dispersão
Elástica	v_p, v_s, ρ	3–5×	ondas S, conversões, AVO
Viscoelástica	$+Q_p, Q_s$	6–10×	tudo acima
VTI / TTI	$+\epsilon, \delta$ (+ eixo)	2–3×	folhelhos, fraturas

Anisotropia: o parâmetro que não se inverte

Em meio VTI, a cinemática de afastamento curto é governada por $v_{nmo} = v_{p0}\sqrt{1+2\delta}$ e a de afastamento longo por $v_{hor} = v_{p0}\sqrt{1+2\epsilon}$. Com dado de superfície, v_{p0} , ϵ e δ são **fortemente acoplados**: há combinações que produzem praticamente o mesmo dado.

A prática consagrada — fixar ϵ e δ a partir de poços ou de análise prévia, e inverter apenas v_{p0} — não é preguiça: é reconhecer que os blocos cruzados são grandes demais para a cobertura angular disponível. **E é uma decisão que precisa ser declarada**, porque o erro em ϵ, δ vai inteiro para v_{p0} .

Antes de usar: causalidade, analiticidade e Kramers–Kronig

A seção seguinte usa um resultado que é, na origem, de análise complexa — e que é a razão pela qual não se pode “corrigir só a amplitude” de um dado atenuado.

Resposta de um meio linear. Cada componente de frequência é multiplicada por um número complexo $\chi(\omega)$: o módulo muda a amplitude, o argumento muda a fase.

Causalidade $\Rightarrow$ analiticidade. Se a resposta ao impulso $\chi(t)$ se anula para $t < 0$, então $\chi(\omega) = \int_0^\infty \chi(t)e^{i\omega t} dt$ converge e é **analítica no semiplano superior** $\text{Im } \omega > 0$ — porque ali $e^{i\omega t}$ decai para $t > 0$. É a causalidade, e nada mais, que produz a analiticidade.

Kramers–Kronig. Aplicando a fórmula integral de Cauchy a uma função analítica no semiplano superior, as partes real e imaginária deixam de ser independentes: cada uma é a transformada de Hilbert da outra.

O enunciado em português. *Não existe* meio causal que absorva energia de forma

dependente da frequência sem alterar a velocidade de fase. Dissipação e dispersão são a mesma propriedade vista de dois ângulos. Um propagador sem perdas usado sobre dado atenuado erra *simultaneamente* a amplitude e a fase — e a FWI é governada por fase.

Leis de potência. Adiante aparece $c(\omega) \propto \omega^\gamma$ com $\gamma \sim 10^{-3}$. Um expoente tão pequeno é quase uma constante — razão pela qual o efeito é invisível numa modelagem isolada e reaparece como erro de tempo de trânsito *acumulado* em percursos longos.

11.3 O adjunto viscoacústico

Dois enunciados que a literatura aplicada frequentemente troca

(1) **A propagação adjunta é estável.** Um operador viscoacústico contém derivadas de ordem *ímpar* (inteira ou fracionária) no tempo, e $\partial_t^* = -\partial_t$. O problema adjunto é anticausal: escrito na variável revertida $\tau = T - t$, a inversão do sentido do tempo e a troca de sinal do adjunto *se cancelam*, e λ obedece a uma equação **dissipativa** em τ . Integra-se sem problema algum.

(2) **Reconstruir o campo *direto* de trás para frente é que explode.** A economia de memória que recupera p propagando-o ao contrário a partir do estado final exige rodar a dissipação *ao contrário*, isto é, **amplificar** — e o que é amplificado inclui o erro de arredondamento, exponencialmente.

Conclusão operacional: em meio atenuante, use *checkpointing* para p e integre λ normalmente. Não é o adjunto que é instável.

Um terceiro caso, distinto dos dois: a FWI *compensada em Q* deliberadamente usa um operador amplificador para restaurar amplitudes perdidas. Aí a amplificação é intencional e precisa de controle explícito de banda (filtros de estabilização), porque senão o ruído de alta frequência domina. Confundir esse caso com (1) ou (2) é a origem da afirmação circulante de que “o adjunto viscoacústico amplifica” — ele não amplifica.

Constant- Q de Kjartansson

$$\gamma = \frac{1}{\pi} \arctan \frac{1}{Q}, \quad c(\omega) = c_0 \left(\frac{\omega}{\omega_{\text{ref}}} \right)^\gamma, \quad A(\omega) = \exp \left[-\frac{\omega L}{2Qc(\omega)} \right], \quad (11.1)$$

sendo o fator $1/(2Q)$ válido para $Q \gg 1$ (a forma exata traz $\tan(\pi\gamma/2)$; a diferença medida é 0,25% em $Q = 10$ e 0,06% em $Q = 20$).

Efeito sobre uma Ricker de 20 Hz após 1500 m, medido no curso:

Q	γ	amplitude rel.	f de pico (Hz)
10 000	$3,2 \times 10^{-5}$	1,0000	20,0
200	$1,59 \times 10^{-3}$	0,7738	18,8
100	$3,18 \times 10^{-3}$	0,6008	17,8
50	$6,37 \times 10^{-3}$	0,3713	15,9
20	$1,59 \times 10^{-2}$	0,1056	11,5

E o erro de fase acumulado leva a *cycle skipping* quando $|\delta t| > T/2$: com $Q = 100$, $L = 6$ km e $f = 60$ Hz, $|\delta t| = 10,5$ ms contra $T/2 = 8,3$ ms — já fora. O risco cresce com percurso longo, frequência alta e Q baixo, os três juntos.




Figura 11.1: Modelo constant- Q : pulso, espectro e dispersão da velocidade de fase. Os três efeitos — perda de amplitude, descida da frequência de pico e mudança de velocidade — são inseparáveis, por causalidade.

11.4 O princípio que organiza o capítulo

O que a FWI não consegue explicar pela física, ela explica mexendo no modelo. Formalmente: se o dado contém uma componente Δ fora da imagem de F , o mínimo de $\frac{1}{2}\|F(m) - d\|^2$ é alcançado projetando d sobre a imagem de F — e a projeção de um erro *coerente* não é ruído: é uma estrutura legítima do espaço de modelos. Isso explica por que erro de física produz modelos plausíveis em vez de artefatos óbvios: a estrutura fabricada é, por construção, a mais compatível com a física adotada.

Como decidir de qual física você precisa

1. **Olhe o resíduo, não J .** Estrutura coerente no resíduo final é a assinatura de física faltando. Resíduo de aspecto aleatório significa que se chegou ao limite do dado.
2. **Espectro contra afastamento.** Sintético com alta frequência que o dado já perdeu $\Rightarrow$ atenuação não modelada.
3. **Amplitude contra afastamento.** Decaimento mais rápido no dado $\Rightarrow$ dissipação ou espalhamento 3D.
4. **Eventos ausentes.** Energia em tempos onde o acústico não produz nada $\Rightarrow$ ondas S, conversões ou múltiplas.
5. **Teste de física cruzada.** Gere o dado com a física completa, inverta com a simples, meça o erro de modelo. É a medida direta do custo da aproximação — e o único experimento que a justifica ou a condena.

E o custo do caminho inverso: mais física significa mais parâmetros, mais *crosstalk*, mais mínimos locais e mais dificuldade em atribuir um resultado a uma causa. A pergunta certa não é “qual é a física mais completa?”, e sim “qual é a mais simples que explica o meu dado?”

O que fica deste capítulo

- *Crosstalk* é a magnitude dos blocos $F'_1 * F'_2$ da Hessiana — uma quantidade calculável, não uma metáfora.
- Padrões de radiação complementares (como I_p e c) reduzem *crosstalk*; a reparametrização

é a ferramenta mais barata contra ele, e não remove a ambiguidade — realoca.

- Se a aquisição não cobre os ângulos que separam dois parâmetros, nenhum método os separa. É limitação de dado.
- O adjunto viscoacústico é estável; instável é reconstruir o campo *direto* ao contrário. São afirmações diferentes, e confundi-las é comum.
- Causalidade amarra dissipação a dispersão: não existe correção de amplitude que dispense corrigir a fase.

Problemas

1. Deduza (2.6) a partir de (2.5) e das relações $\kappa = 1/(I_p c)$, $\rho = I_p/c$.
2. Usando (2.6), determine o ângulo de espalhamento em que a sensibilidade a c e a I_p têm a mesma magnitude. O que isso diz sobre a faixa de afastamentos que melhor separa os dois?
3. Um meio tem $Q = 60$, e o alvo está a 4 km de percurso, com $c_0 = 2200$ m/s e $f_{\text{ref}} = 15$ Hz. Estime o erro de tempo de trânsito em 40 Hz e compare com $T/2$.
4. Explique por que fixar ϵ e δ em inversão VTI é uma decisão sobre a Hessiana, e não sobre a física.

Respostas. (1) Substitua $\delta\kappa/\kappa = -\delta I_p/I_p - \delta c/c$ e $\delta\rho/\rho = \delta I_p/I_p - \delta c/c$ em (2.5) e agrupe. (2) $|\cos\theta - 1| = |1 + \cos\theta| \Rightarrow \cos\theta = 0 \Rightarrow \theta = 90^\circ$: ângulos intermediários — nem incidência normal (só I_p) nem transmissão pura (só c). É o regime de afastamento médio a longo. (3) $\gamma = \arctan(1/60)/\pi \approx 5,3 \times 10^{-3}$; $\delta t \approx (L/c_0)[1 - (f/f_{\text{ref}})^{-\gamma}] = (4000/2200)[1 - (40/15)^{-0,0053}] \approx 9,4$ ms, contra $T/2 = 12,5$ ms em 40 Hz: dentro do limite, mas com pouca margem — e o erro de *amplitude* é adicional. (4) Porque a física VTI é perfeitamente bem definida com os três parâmetros; o que impede invertê-los juntos é o mau condicionamento dos blocos cruzados para a cobertura angular disponível. Fixar é uma escolha de regularização (um prior infinitamente forte), e deve ser declarada como tal.

Capítulo 12

Diagnóstico e o que ainda não se sabe

A ideia deste capítulo, em uma frase

Um resultado de FWI não se valida mostrando que ele é bonito. Valida-se tentando derrubá-lo — e registrando o que sobreviveu. Este capítulo organiza os testes disponíveis e delimita, com honestidade, o que nenhum deles decide.

12.1 A hierarquia de diagnósticos

Diagnóstico	Responde	Custo
Teste do produto escalar	o adjunto está certo?	desprezível
Teste de Taylor	o gradiente é a derivada do J avaliado?	~ 10 modelagens
Resíduo final (imagem, não norma)	falta física?	zero (já existe)
Espectro/amplitude <i>versus</i> afastamento	atenuação, 3D, elasticidade?	zero
PSF em pontos-chave	qual é a resolução <i>aqui</i> ?	2 propagações/tiro por ponto
Espectro de H (Lanczos)	quais direções o dado não restringe?	$k \times$ produtos $H\mathbf{v}$
Passeio pelo espaço nulo	existem modelos alternativos igualmente bons?	1 modelagem por perturbação
Reiniciação de banda mais baixa	houve <i>cycle skipping</i> ?	uma inversão inteira
<i>Ensemble</i> (inicial, banda, λ , tiros)	o resultado é do dado ou das escolhas?	várias inversões

A assimetria que define a prática

Os dois primeiros testes são **conclusivos**: há uma resposta certa, e o código passa ou não. Todos os demais são **indicativos**: reduzem a probabilidade de estar errado, sem eliminá-la. Daí a regra prática: *os testes conclusivos são obrigatórios e baratos; os indicativos são caros e nenhum é suficiente sozinho*. Um trabalho que reporta muitos diagnósticos indicativos e nenhum conclusivo não estabeleceu nada sobre a correção do código.

12.2 Sintomas e causas

Sintoma	Investigar, nesta ordem
J não cai	gradiente (teste de Taylor); direção de descida ($\langle \mathbf{g}, \mathbf{d} \rangle < 0?$); sinal e parâmetro do gradiente; escala do passo inicial
J cai, modelo errado	<i>cycle skipping</i> (reinicie mais baixo); m_0 fora do vale (Eq. 5.1); física faltando (resíduo coerente?); ondaleta absorvendo erro; bordas
só o raso atualiza	máscara de aquisição; pré-condicionamento; abertura insuficiente (e isso nenhum algoritmo resolve)
NaN	CFL; modelo fora da caixa <i>dentro</i> da busca linear
cauda oscilatória	G insuficiente; se G já é alto, é Δt ; confirme em meio homogêneo
razão de Taylor estável $\neq 1$	adjunto de um pré-processamento omitido (E^T); adjunto de CPML; discrepância contínuo/discreto (teste refinando)
gradiente de um parâmetro idêntico a zero	regra da cadeia, não adjunto — verifique $\partial \mathcal{A} / \partial p_k$

12.3 O que se sabe que não se sabe

Problemas abertos, enunciados sem otimismo

- 1. Não há garantia de convergência global.** Nenhum funcional alternativo conhecido é convexo em $\mathbf{m}$ — apenas mais bem comportado em relação a *deslocamento*, que é uma propriedade bem mais fraca. Transporte ótimo, AWI e envoltória ampliam bacias de atração; nenhum elimina mínimos locais.
- 2. A lacuna espectral é propriedade do dado.** Por (1.4), nenhuma escolha de algoritmo cria informação abaixo de $(4\pi f_{\min}/c) \sin(\theta_{\min}/2)$. Isso é um limite de *aquisição*, e só se resolve em campo — fontes de baixa frequência ou aberturas maiores.
- 3. Erro de modelagem não é ruído.** A formulação estatística padrão assume ruído aleatório; física faltante é *determinística e coerente*. Tratar as duas com a mesma covariância C_d é teoricamente indefensável e universalmente praticado. Existe literatura sobre covariância de erro de modelo; ela não é rotina.
- 4. UQ em escala real está fora de alcance.** A aproximação de Laplace é local e condicional à bacia; MCMC em dimensão realista é inviável. O que se reporta hoje como “incerteza” em FWI 3D é, quase sempre, variabilidade sobre escolhas metodológicas — o que é útil e *não* é uma distribuição a posteriori.
- 5. Multiparâmetro segue limitado por ângulo, não por algoritmo.** Se dois parâmetros produzem dado indistinguível na faixa angular iluminada, nenhuma regularização, parametrização ou método de segunda ordem os separa. Reparametrizar realoca a ambiguidade; não a remove.
- 6. Escolher a física continua sendo julgamento.** Existem diagnósticos (§11.5) mas não existe critério automático que decida se vale pagar por viscoelasticidade num dado específico.

As cinco perguntas, na versão deste volume

1. O teste do produto escalar e o de Taylor passaram? Com quais números?
2. Qual era o erro do modelo inicial, e como ele foi obtido?
3. O resíduo final é incoerente? (Se tem estrutura, falta física — não houve convergência,

houve parada.)

4. Qual é a PSF nos pontos de interesse? A feição que estou interpretando é maior que ela?
5. O resultado sobrevive a mudanças de banda inicial, modelo inicial e λ ? Se não, quem determinou a resposta foi a escolha, não o dado.

O que fica deste capítulo

- Dois diagnósticos são *conclusivos* (produto escalar, Taylor) e baratos; todos os demais são indicativos e caros.
- A PSF é a única medida local de resolução que não exige conhecer a verdade — e portanto a única que serve em dado real.
- Barras de erro de Laplace são condicionais à bacia e à física; sem esse condicional, são enganosas.
- O que permanece aberto não é detalhe de implementação: convergência global, lacuna espectral, erro de modelagem como ruído, UQ em escala real, e ambiguidade multiparâmetro limitada por ângulo.

Capítulo A

Notação

Símbolo	Significado
$\mathcal{M}, \mathcal{D}$	espaços de Hilbert de modelos e de dados
$\mathbf{m}, m = 1/c^2$	modelo; vagarosidade ao quadrado
F, F', F'^*	operador direto; derivada de Fréchet (Born); seu adjunto
$\mathcal{A}(m)$	operador de onda; $\mathcal{A}_\omega = -\omega^2 m - \nabla^2$
R	operador de restrição aos receptores
G	função de Green
$\lambda(\mathbf{x}, t)$	campo adjunto
$\delta p, \delta \lambda$	campos tangente linear e adjunto de 2ª ordem
$H, H_{\text{GN}} = F'^* F'$	Hessiana e sua aproximação de Gauss–Newton
$C_d, C_m, C_{\text{post}}$	covariâncias do ruído, do prior e a posteriori
$\mathbf{k}_i, \mathbf{k}_s, \mathbf{k}_m$	números de onda incidente, espalhado e do modelo
θ	ângulo de espalhamento ($\pi =$ retroespalhamento)
$\vartheta = \pi - \theta$	ângulo de abertura fonte–receptor
$S(\theta)$	símbolo do estêncil espacial
C, C_{lim}, G	Courant, seu limite, e pontos por comprimento de onda
$s(x)$	fator de estiramento complexo da PML
γ, Q	expoente de Kjartansson e fator de qualidade
$I_p = \rho c, \kappa = 1/K$	impedância e compressibilidade
E	operador linear de pré-processamento do modelo
$\mathcal{H}$	transformada de Hilbert
W_2	distância de Wasserstein quadrática

Colisões herdadas da literatura

λ é parâmetro de Lamé, campo adjunto, peso de regularização e comprimento de onda; μ é módulo de cisalhamento e parâmetro de penalidade da WRI; G é função de Green e pontos por comprimento de onda; J é o funcional e $J' = F'$ a jacobiana do *resíduo*. O contexto resolve, mas a colisão é da área.

Capítulo B

Identidades usadas

Integração por partes no tempo.

$$\int_0^T \lambda \partial_{tt} \varphi \, dt = [\lambda \partial_t \varphi - \partial_t \lambda \varphi]_0^T + \int_0^T \partial_{tt} \lambda \varphi \, dt.$$

Segunda identidade de Green.

$$\int_{\Omega} (\lambda \nabla^2 \varphi - \varphi \nabla^2 \lambda) \, d\mathbf{x} = \oint_{\partial\Omega} (\lambda \partial_n \varphi - \varphi \partial_n \lambda) \, dS.$$

Adjuntos elementares. $\partial_t^* = -\partial_t$; $\partial_{tt}^* = \partial_{tt}$; $(\nabla^2)^* = \nabla^2$ com contorno homogêneo; $\mathcal{H}^* = -\mathcal{H}$; $D^* = D^T$ para qualquer matriz. **Toda matriz diagonal é auto-adjunta** — daí o Cerjan.

Transformada de Fourier (convenção usada). $\hat{w}(f) = \int w(t) e^{-2\pi i f t} \, dt$; $\widehat{\partial_t w} = i\omega \hat{w}$ com $\omega = 2\pi f$; $\widehat{w(\cdot - t_0)} = \hat{w} e^{-2\pi i f t_0}$.

Espectro da Ricker. $|W(f)| = (2/\sqrt{\pi})(f^2/f_0^3)e^{-f^2/f_0^2}$; pico em f_0 ; -6 dB em $1,63f_0$; -20 dB em $2,21f_0$ (raízes de $u e^{1-u} = \eta$ com $u = (f/f_0)^2$).

Estabilidade e dispersão (leap-frog + estêncil centrado).

$$C_{\text{lim}} = \frac{2}{\sqrt{n_{\text{dim}}(|c_0| + 2 \sum_j |c_j|)}}, \quad \frac{4}{\Delta t^2} \sin^2 \frac{\omega \Delta t}{2} = \frac{c^2}{\Delta h^2} \sum_j S(k_j \Delta h).$$

Cobertura de número de onda. $|\mathbf{k}_m| = (4\pi/\lambda) \sin(\theta/2)$.

Radiação P–P acústica. $f(\theta) \propto \delta\kappa/\kappa + (\delta\rho/\rho) \cos \theta$; em (I_p, c) , $f(\theta) \propto (\delta I_p/I_p)(\cos \theta - 1) - (\delta c/c)(1 + \cos \theta)$.

Desajuste sob deslocamento puro. $\Phi(\tau) = \|d\|^2 - R_{dd}(\tau)$.

Capítulo C

Referências

1. ASNAASHARI, A. *et al.* *Regularized seismic full waveform inversion with prior model information*. *Geophysics*, v. 78, n. 2, p. R25–R36, 2013.
2. BUNKS, C.; SALECK, F. M.; ZALESKI, S.; CHAVENT, G. *Multiscale seismic waveform inversion*. *Geophysics*, v. 60, n. 5, p. 1457–1473, 1995.
3. CARCIONE, J. M. *Wave Fields in Real Media*. 4. ed. Elsevier, 2022.
4. CERJAN, C. *et al.* *A nonreflecting boundary condition for discrete acoustic and elastic wave equations*. *Geophysics*, v. 50, n. 4, p. 705–708, 1985.
5. FICHTNER, A. *Full Seismic Waveform Modelling and Inversion*. Springer, 2011.
6. GRIEWANK, A.; WALTHER, A. *Algorithm 799: revolve — an implementation of checkpointing for the reverse or adjoint mode of computational differentiation*. *ACM TOMS*, v. 26, n. 1, p. 19–45, 2000.
7. KJARTANSSON, E. *Constant-Q wave propagation and attenuation*. *JGR*, v. 84, p. 4737–4748, 1979.
8. GRIEWANK, A.; WALTHER, A. *Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation*. 2. ed. SIAM, 2008. — o tratamento completo do resultado de checkpointing ótimo.
9. KOMATITSCH, D.; MARTIN, R. *An unsplit convolutional perfectly matched layer improved at grazing incidence for the seismic wave equation*. *Geophysics*, v. 72, n. 5, p. SM155–SM167, 2007.
10. LUO, Y.; SCHUSTER, G. T. *Wave-equation traveltime inversion*. *Geophysics*, v. 56, n. 5, p. 645–653, 1991.
11. MÉTIVIER, L.; BROSSIER, R.; VIRIEUX, J.; OPERTO, S. *Full waveform inversion and the truncated Newton method*. *SIAM Journal on Scientific Computing*, v. 35, n. 2, p. B401–B437, 2013.
12. MÉTIVIER, L. *et al.* *Measuring the misfit between seismograms using an optimal transport distance*. *Geophysical Journal International*, v. 205, n. 1, p. 345–377, 2016.
13. MARQUERING, H.; DAHLEN, F. A.; NOLET, G. *Three-dimensional sensitivity kernels for finite-frequency traveltimes: the banana-doughnut paradox*. *Geophysical Journal International*, v. 137, n. 3, p. 805–815, 1999.
14. NOCEDAL, J.; WRIGHT, S. J. *Numerical Optimization*. 2. ed. Springer, 2006.
15. OPERTO, S. *et al.* *A guided tour of multiparameter full-waveform inversion with multicomponent data*. *The Leading Edge*, v. 32, n. 9, p. 1040–1054, 2013.

16. PLESSIX, R.-E. *A review of the adjoint-state method for computing the gradient of a functional with geophysical applications*. GJI, v. 167, n. 2, p. 495–503, 2006.
17. PRATT, R. G. *Seismic waveform inversion in the frequency domain, Part 1*. Geophysics, v. 64, n. 3, p. 888–901, 1999.
18. SCHÄFER, M.; GROOS, L.; FORBRIGER, T.; BOHLEN, T. *Line-source simulation for shallow-seismic data. Part 2: full-waveform inversion — a synthetic 2-D case study*. Geophysical Journal International, v. 198, n. 3, p. 1405–1418, 2014.
19. SHIN, C.; JANG, S.; MIN, D.-J. *Improved amplitude preservation for prestack depth migration by inverse scattering theory*. Geophysical Prospecting, v. 49, n. 5, p. 592–606, 2001.
20. SIRGUE, L.; PRATT, R. G. *Efficient waveform inversion and imaging: a strategy for selecting temporal frequencies*. Geophysics, v. 69, n. 1, p. 231–248, 2004.
21. SYMES, W. W. *Migration velocity analysis and waveform inversion*. Geophysical Prospecting, v. 56, n. 6, p. 765–790, 2008.
22. TARANTOLA, A. *Inversion of seismic reflection data in the acoustic approximation*. Geophysics, v. 49, n. 8, p. 1259–1266, 1984.
23. TARANTOLA, A. *A strategy for nonlinear elastic inversion of seismic reflection data*. Geophysics, v. 51, n. 10, p. 1893–1903, 1986.
24. TARANTOLA, A. *Inverse Problem Theory and Methods for Model Parameter Estimation*. SIAM, 2005.
25. TROMP, J.; TAPE, C.; LIU, Q. *Seismic tomography, adjoint methods, time reversal and banana-doughnut kernels*. GJI, v. 160, n. 1, p. 195–216, 2005.
26. VAN LEEUWEN, T.; HERRMANN, F. J. *Mitigating local minima in full-waveform inversion by expanding the search space*. GJI, v. 195, n. 1, p. 661–667, 2013.
27. VIRIEUX, J.; OPERTO, S. *An overview of full-waveform inversion in exploration geophysics*. Geophysics, v. 74, n. 6, p. WCC1–WCC26, 2009.
28. VIRIEUX, J. *et al. An Introduction to Full Waveform Inversion*. SEG, 2017.
29. WARNER, M.; GUASCH, L. *Adaptive waveform inversion: theory*. Geophysics, v. 81, n. 6, p. R429–R445, 2016.
30. WU, R.-S.; TOKSÖZ, M. N. *Diffraction tomography and multisource holography applied to seismic imaging*. Geophysics, v. 52, n. 1, p. 11–25, 1987.